

Online Convex Optimization based tuning of Mixture of Experts for Sports Outcome Prediction

Αναφορά προόδου: τι έχει υλοποιηθεί

[Ονοματεπώνυμο φοιτητή]

29 Σεπτεμβρίου 2026

1 Σύνοψη

Η εργασία δεν εκπαιδεύει ένα ακόμη μοντέλο πρόβλεψης πάνω σε στατιστικά αγώνων — αυτό το κάνουν ήδη οι στοιχηματικές εταιρείες, με ασύγκριτα περισσότερα δεδομένα και υπολογιστική ισχύ από μια διπλωματική. Αντ' αυτού αντιμετωπίζει **κάθε στοιχηματική εταιρεία ως έναν *expert*** που δίνει πιθανότητες (p_H, p_D, p_A) για το αποτέλεσμα κάθε αγώνα, και μαθαίνει **online** — αγώνα προς αγώνα, χωρίς επανεκπαίδευση πάνω στο παρελθόν — πώς να τους συνδυάζει σε ένα μείγμα που τους ξεπερνά. Αυτό είναι το κλασικό πλαίσιο *prediction with expert advice* / *Online Convex Optimization* (OCO), και δίνει θεωρητικές εγγυήσεις regret χωρίς καμία στατιστική υπόθεση για την κατανομή των δεδομένων.

Τι υπάρχει αυτή τη στιγμή:

- Πλήρες pipeline που τρέχει end-to-end πάνω σε **76.584 αγώνες**, 22 πρωταθλήματα, 10 σεζόν (2016/17–2025/26), **26 bookmakers** ως experts.
- Τρεις αλγόριθμοι OCO (**Hedge**, **OGD**, **FTRL**), γενικευμένοι ώστε να δουλεύουν με bookmakers μερικής κάλυψης (αναγωγή *Sleeping Experts*).
- Δεύτερο στάδιο OCO για **βαθμονόμηση** (online temperature scaling), και τρίτο για το **μέγεθος στοιχήματος** (online Kelly).
- **Στατιστικός έλεγχος** με moving block bootstrap σε κάθε σύγκριση — κανένα συμπέρασμα δεν στηρίζεται σε «φαίνεται καλύτερο».
- **9 επεκτάσεις** και **4 έλεγχοι μεθοδολογικής ευρωστίας**, ο καθένας απαντά ένα συγκεκριμένο ερώτημα (κατάλογος στον Πίνακα 1).

Τα τρία κύρια ευρήματα, σε μία γραμμή το καθένα:

1. Το μείγμα ξεπερνά **στατιστικά σημαντικά** κάθε μεμονωμένο **bookmaker** εκτός ενός: του PSC (Pinnacle, closing odds). Στη διαμόρφωση που έχει πλέον επιλεγεί ως καλύτερη — panel μόνο από closing αποδόσεις — η **διαφορά από τον PSC παύει να είναι στατιστικά σημαντική** ($p = 0,234$), δηλαδή το μείγμα τον φτάνει χωρίς να τον ξεπερνά αποδεδειγμένα.
2. Η **βαθμονόμηση βοηθάει σημαντικά** και στους 4 αλγορίθμους — το «δεύτερο στάδιο OCO» δεν είναι διακοσμητικό.
3. Καλύτερο log-loss **δεν** σημαίνει κέρδος: η οικονομική προσομοίωση δίνει σημαντική άκρη σε 3

από 11 bookmakers και τίποτα στους υπόλοιπους 8 — η άκρη υπάρχει απέναντι σε συγκεκριμένους bookmakers, όχι ως γενική στρατηγική.

2 Δεδομένα

Πηγή: football-data.co.uk, ενότητα «Main Leagues» (η ενότητα «Extra Leagues» έχει άλλη μορφή και συνήθως δεν περιέχει αποδόσεις, οπότε είναι εκτός σκοπού).

- **22 πρωταθλήματα:** Αγγλία $\times 5$, Σκωτία $\times 4$, Γερμανία/Ιταλία/Ισπανία/Γαλλία $\times 2$, Ολλανδία/Βέλγιο/Πορτογαλία/Τουρκία/Ελλάδα $\times 1$.
- **10 σεζόν** (2016/17–2025/26), **76.639 αγώνες**, από τους οποίους **76.584** έχουν τουλάχιστον μία χρήσιμη απόδοση — αυτοί είναι οι «γύροι» πάνω στους οποίους τρέχουν όλοι οι αλγόριθμοι.
- **26 ανεξάρτητοι bookmakers** μετά τον καθαρισμό: αποκλείονται οι συγκεντρωτικές στήλες (Max/Avg, Betbrain) ως μη ανεξάρτητοι experts, και συγχωνεύεται ένα γνωστό rebrand (VC Bet $\rightarrow$ BetVictor) σε μία συνεχή ταυτότητα.
- Η κάλυψη ανά bookmaker κυμαίνεται από **6,9%** (CLC) έως **99,8%** (B365) — εξ ου και η ανάγκη για την αναγωγή Sleeping Experts. Συγκρίσεις θεωρούνται αξιόπιστες μόνο για κάλυψη $\geq 70\%$ («Tier A»), και οι bookmakers ενεργοί σε μία μόνο σεζόν επισημαίνονται ρητά ως μη συγκρίσιμοι.

Το panel χωρίζεται καθαρά σε **13 opening** και **13 closing** αποδόσεις (η σύμβαση του football-data.co.uk: κατάληξη «C» σημαίνει την απόδοση κλεισίματος του ίδιου bookmaker) — διάκριση που αποδείχθηκε ουσιώδης, βλ. §6.

3 Μεθοδολογικός σκελετός

De-vig. Οι δημοσιευμένες αποδόσεις περιέχουν το περιθώριο κέρδους του bookmaker (overround): τα αντίστροφα τους αθροίζουν σε > 1 . Μετατρέπονται σε πιθανότητες με proportional normalization, $p_i = (1/o_i) / \sum_j (1/o_j)$. Η επιλογή αυτή ελέγχθηκε ανεξάρτητα με τη μέθοδο του Shin (1992), βλ. §6.

Πρώτο στάδιο OCO: τα βάρη του μείγματος. Hedge (πολλαπλασιαστικά βάρη), OGD (projected gradient descent στο simplex) και FTRL (L2 regularizer). Και οι τρεις δουλεύουν με learning rate $\eta_t \propto 1/\sqrt{t}$, χωρίς κανένα hyperparameter προς συντονισμό σε validation set.

Sleeping Experts / Specialists. Οι κλασικοί αλγόριθμοι υποθέτουν ότι κάθε expert δίνει πρόβλεψη σε κάθε γύρο, που εδώ δεν ισχύει (πολλοί bookmakers καλύπτουν $< 30\%$ των αγώνων). Χρησιμοποιείται η κλασική αναγωγή (Freund, Schapire, Singer & Warmuth, 1997): κάθε expert κρατά μόνιμη κατάσταση, σε κάθε γύρο χρησιμοποιούνται και επανακανονικοποιούνται μόνο οι «ξύπνιοι», και η κατάσταση των «κοιμισμένων» παγώνει. Η εγγύηση regret μετράται τότε μόνο στους γύρους όπου ο κάθε expert ήταν πραγματικά ενεργός.

Δεύτερο στάδιο OCO: βαθμονόμηση. Διαγνωστικά βρέθηκε το γνωστό *favorite-longshot bias* σε όλες τις σειρές, μείγματα συμπεριλαμβανομένων: οι μικρές πιθανότητες είναι συστηματικά υπερεκτιμώμενες και οι μεγάλες υποεκτιμώμενες. Η διόρθωση γίνεται με online temperature scaling, $\tilde{p}_k \propto p_k^s$: η συνάρτηση απώλειας ως προς s είναι log-sum-exp μιας γραμμικής συνάρτησης, άρα *κυρτή*, οπότε το s μαθαίνεται με απλό projected OGD σε μία διάσταση — ίδια συνταγή OCO, νέο στάδιο. Το learning rate επιλέγεται *αποκλειστικά* στο χρονολογικά πρώτο 75% των γύρων, ώστε τα αναφερόμενα νούμερα να μην έχουν δει ποτέ το validation κομμάτι.

Τρίτο στάδιο OCO (πείραμα): το μέγεθος στοιχήματος. Αντί να μπαίνει η εκτιμώμενη πιθανότητα στον κλειστό τύπο Kelly, το ποσοστό f μαθαίνεται online με projected OGD πάνω στην (κυρτή) απώλεια αρνητικού log-πλούτου — η οπτική *Online Portfolio Selection* (Cover, 1991).

Στατιστική σημαντικότητα. Οι διαφορές log-loss είναι της τάξης 10^{-4} , οπότε κάθε σύγκριση περνά από **moving block bootstrap** (2.000 δείγματα, μήκος block $\approx n^{1/3}$). Ο λόγος που δεν χρησιμοποιείται απλό t-test ή i.i.d. bootstrap: οι απώλειες διαδοχικών αγώνων δεν είναι ανεξάρτητες (ένα αγωνιστικό διήμερο με πολλές ανατροπές χτυπά ταυτόχρονα κάθε προγνώστη), οπότε η δειγματοληψία μεμονωμένων γύρων θα υποεκτιμούσε τη διασπορά. Το block bootstrap δειγματοληπτεί συνεχόμενα μπλοκ και διατηρεί αυτή τη βραχυχρόνια εξάρτηση — η ίδια ιδέα με το κλασικό τεστ Diebold–Mariano, χωρίς ασυμπτωτική υπόθεση κανονικότητας.

4 Τι έχει υλοποιηθεί

Το project είναι μια ακολουθία αυτόνομων σεναρίων Python που επικοινωνούν μέσω αρχείων CSV, με ένα κοινό αρχείο-βιβλιοθήκη (`sleeping_experts.py`) απ' όπου 15 άλλα εισάγουν φόρτωση δεδομένων και αλγόριθμους. Κάθε επέκταση είναι ξεχωριστό αρχείο και απαντά ένα ερώτημα.

Πίνακας 1: Τι υπάρχει και τι ερώτημα απαντά.

Συνιστώσα	Ερώτημα / περιεχόμενο
Πυρήνας	
Αγωγός δεδομένων	Κατέβασμα 220 αρχείων, de-vig, συγχώνευση rebrand, δύο εναλλακτικές κανονικοποιήσεις σε ένα πέρασμα.
Hedge / OGD / FTRL + Sleeping Experts	Ποιος αλγόριθμος OCO συνδυάζει καλύτερα τους experts, και πώς συγκρίνεται με τον καθένα τους χωριστά.
Ανάλυση βαθμονόμησης	Είναι οι πιθανότητες αξιόπιστες; (Διάγνωση: όχι — favorite-longshot bias.)
Διόρθωση βαθμονόμησης	Το διορθώνει το online temperature scaling;
Τελική κατάταξη	Μία αυθεντική κατάταξη, raw και βαθμονομημένη, υπολογισμένες με τον ίδιο τρόπο ώστε να συγκρίνονται δίκαια.
Έλεγχοι σημαντικότητας	Μπαταρία 12 συγκρίσεων με moving block bootstrap.
Επεκτάσεις	
Fixed-Share	Διορθώνει το «παγωμένο πλεονέκτημα»: σπάνιοι experts κρατούν διογκωμένο βάρος επειδή τίποτα δεν το διαβρώνει όσο κοιμούνται.
Contextual experts	Βοηθάει η εκμάθηση χωριστών βαρών ανά πρωτάθλημα;
Value betting	Θα έβγαζε λεφτά ένας πραγματικός bettor; (Kelly, leave-one-bookmaker-out.)
Online Kelly	Βοηθάει να μαθαίνεται και το ποσό του στοιχήματος online;
Ακρίβεια ανά κατηγορία	Ποιος είναι καλός σε 1, ποιος σε X, ποιος σε 2 χωριστά.
Χρονικές τάσεις	Γίνεται η αγορά πιο αξιόπιστη με τα χρόνια; (Mann-Kendall.)
Παράθυρο pooling	Αλλάζουν τα συμπεράσματα με 5ετία αντί 10ετίας;
Βαθμονόμηση ανά σεζόν	Βοηθάει το reset της βαθμονόμησης κάθε σεζόν;
Warm-start βαθμονόμηση	Και αν μεταφέρεται η θερμοκρασία της προηγούμενης σεζόν;
Έλεγχοι ευρωστίας	
Shin έναντι proportional de-vig	Είναι τα ευρήματα artifact της μεθόδου de-vig;
Opening έναντι closing	Κάνει καλύτερο μείγμα η τελική τιμή της αγοράς από την αρχική;
Μεταφορά ποιότητας	Προβλέπει η «οξύτητα» στο closing την οξύτητα στο opening;

Συνιστώσα	Ερώτημα / περιεχόμενο
Έλεγχος look-ahead bias	Ήταν το σχέδιο leave-one-out πραγματικά αιτιακό; (Όχι σε μία περίπτωση — διορθώθηκε, βλ. §6.)

5 Κύρια ευρήματα

5.1 Κατάταξη

Σειρά	Τύπος	Raw log-loss	Βαθμονομημένο
PSC (Pinnacle, closing)	bookmaker	0,99714	0,99685
OGD	αλγόριθμος	0,99745	0,99693
Hedge	αλγόριθμος	0,99845	0,99776
FTRL	αλγόριθμος	0,99850	0,99780
Uniform average	baseline	0,99886	0,99813
VC_BV	bookmaker	1,00075	1,00026
WH	bookmaker	1,00119	1,00048
PS	bookmaker	1,00083	1,00055
IW	bookmaker	1,00186	1,00061
BW	bookmaker	1,00140	1,00065
B365	bookmaker	1,00113	1,00073


Πίνακας 2: Tier-A κατάταξη (κάλυψη $\geq 70\%$), ταξινομημένη κατά βαθμονομημένο log-loss. Χαμηλότερο = καλύτερο. Πηγή: `results/final_ranking_table.csv`.

5.2 Τι είναι στατιστικά σημαντικό

- Και οι τέσσερις μέθοδοι μείγματος ξεπερνούν σημαντικά την ομοιόμορφη μέση τιμή (OGD: $-0,00141$ · Hedge $-0,00041$ · FTRL $-0,00037$, όλα $p < 0,001$). Το **OGD** είναι ο καλύτερος των τριών, σημαντικά καλύτερο και από Hedge ($-0,00100$) και από FTRL ($-0,00104$), και ξεπερνά σημαντικά και τον B365C ($-0,00063$), όλα με $p < 0,001$.
- Ο PSC εξακολουθεί να ξεπερνά σημαντικά το OGD, αλλά η διαφορά συρρικνώθηκε 2,6 φορές μετά τη ρύθμιση του βήματος: $+0,00065$ πριν τη βαθμονόμηση (95% CI $[+0,00044, +0,00086]$) και $+0,00043$ μετά, έναντι $+0,00149$ και $+0,00114$ με το παλιό βήμα. Το ειλικρινές συμπέρασμα παραμένει: το μείγμα ξεπερνά κάθε bookmaker εκτός του καλύτερου «sharp», όχι όλους.
- Χωρίς καμία στήλη Pinnacle στο panel, το μείγμα κερδίζει τους πάντες: με 24 experts και οι τέσσερις αλγόριθμοι κατατάσσονται πάνω από όλους τους εναπομείναντες Tier-A bookmakers (OGD 0,99782 έναντι VC_BV 0,99987, στους ίδιους 54.877 αγώνες), και το OGD τους ξεπερνά σημαντικά και τους πέντε. Άρα ο περιορισμός αφορά μία εξαιρετική εταιρεία, όχι τη μέθοδο — και η Pinnacle δεν είναι καν προσβάσιμη σε πολλές χώρες. Με μία επιφύλαξη, βλ. §5.3.
- Η βαθμονόμηση βοηθάει σημαντικά σε όλους τους αλγόριθμους (raw μείον βαθμονομημένο: $+0,00053$ έως $+0,00073$, όλα $p < 0,001$).

5.3 Η καλύτερη διαμόρφωση: το μείγμα φτάνει τον PSC

Τέσσερα πράγματα είχαν μετρηθεί χωριστά και ποτέ μαζί: το διορθωμένο βήμα του OGD, το closing-only panel που κερδίζει το πλήρες, το Shin de-vig που κερδίζει την απλή κανονικοποίηση στο raw log-loss, και η βαθμονόμηση. Το pipeline έτρεχε με το πλήρες panel και την απλή κανονικοποίηση,



Σχήμα 1: Κάθε σειρά: κενός κύκλος = raw log-loss, γεμάτος = μετά τη βαθμονόμηση. Η επιλογή dot/slope plot αντί ραβδογράμματος είναι σκόπιμη: τα log-loss μαζεύονται γύρω από το 1,0 χωρίς ουσιαστικό μηδέν, οπότε ένα ραβδόγραμμα με κομμένο άξονα θα μεγαλοποιούσε οπτικά μικροσκοπικές διαφορές.

δηλαδή άφηνε δύο από τα τέσσερα έξω. Η στοίβαξη έγινε με δύο προφυλάξεις που το project έχει πληρώσει στο παρελθόν:

1. Κάθε διαμόρφωση βαθμολογείται στους *ιδίους* αγώνες — την τομή της κάλυψης όλων με του PSC, 71.818 γύροι. Τα panel έχουν διαφορετική κάλυψη, και log-loss πάνω σε διαφορετικό σύνολο αγώνων δεν είναι συγκρίσιμο. Η *εκπαίδευση* χρησιμοποιεί κανονικά όλο το διαθέσιμο εύρος κάθε διαμόρφωσης· μόνο η βαθμολόγηση περιορίζεται.
2. Το να διαλέγεις διαμόρφωση κοιτώντας αυτά τα νούμερα *είναι* επιλογή, οπότε όλα αναφέρονται δύο φορές: πλήρες δείγμα (περιγραφικά) και χρονική ουρά 25% που η επιλογή δεν είδε ποτέ.

Τα ζευγαρωτά τεστ δείχνουν καθαρά ποιος παράγοντας δουλεύει:

- **Το panel κάνει όλη τη δουλειά.** Η διαμόρφωση A κερδίζει το baseline κατά $-0,00036$ ($p < 0,001$)· το closing-only με απλή κανονικοποίηση κερδίζει σχεδόν ταυτόσημα ($-0,00034$, $p < 0,001$).
- **Το Shin μόνο του δεν προσφέρει τίποτα μετρήσιμο** πάνω στο πλήρες panel ($+0,00004$, $p = 0,181$) — συνεπές με το εύρημα ότι Shin και βαθμονόμηση διορθώνουν το ίδιο bias, οπότε η δεύτερη το απορροφά.

Διαμόρφωση	πλήρες	train 75%	held-out 25%
PSC μόνος του	0,99685	0,99746	0,99502
A: closing-only + Shin	0,99692	0,99754	0,99507
closing-only, απλή κανονικοποίηση	0,99693	0,99756	0,99506
baseline: πλήρες panel, απλή	0,99728	0,99801	0,99508
πλήρες panel, Shin	0,99731	0,99804	0,99512

Πίνακας 3: Βαθμονομημένο log-loss OGD ανά διαμόρφωση, ίδιοι 71.818 αγώνες σε κάθε γραμμή. Πηγή: `results/best_configuration.csv`.

- **Έναντι του PSC:** το baseline χάνει σημαντικά ($+0,00043$, $p < 0,001$), ενώ η A *ισοπαλεί* ($+0,00007$, $p = 0,234$). Αυτή είναι η ουσιαστική αλλαγή στην κεντρική αφήγηση της εργασίας.
- Μια πέμπτη διαμόρφωση (A χωρίς τους bookmakers μίας σεζόν) βγήκε οριακά χειρότερη και απορρίφθηκε.

Στην held-out ουρά και οι πέντε γραμμές μαζεύονται σε λιγότερο από 0,0001 μεταξύ τους. Η ουρά επομένως *επιβεβαιώνει* την ισοπαλία με τον PSC, δεν αναδεικνύει νικητή — και δεν θα ήταν έντιμο να παρουσιαστεί ως νίκη.

Η ίδια διαμόρφωση χωρίς Pinnacle: εδώ η μάθηση *εξαφανίζεται*. Το πείραμα αφαίρεσης της Pinnacle επαναλήφθηκε με την ίδια πειθαρχία (κοινοί αγώνες, train/held-out), σε δύο panel. Στο πλήρες το αποτέλεσμα αντέχει: σε 54.877 κοινούς γύρους, και οι τέσσερις αλγόριθμοι πάνω από όλους τους bookmakers, το OGD κερδίζει σημαντικά και τους πέντε ($-0,0018$ έως $-0,0032$, $p < 0,001$). Στο closing-only panel όμως μένουν 12 experts και μόνο 32.210 κοινοί αγώνες, και:

- Το OGD βγαίνει #1 (0,99919) αλλά κερδίζει σημαντικά μόνο τους 3 από τους 5 (WHC, IWC, BWC). Ο B365C ($p = 0,505$) και ο VC_BVC ($p = 0,284$) είναι ισοπαλίες, και στην held-out ουρά ο VC_BVC περνάει μπροστά.
- Το OGD (0,99919) γίνεται πρακτικά *ταυτόσημο* με τον απλό μέσο όρο (0,99921) — δηλαδή η μαθημένη στάθμιση παύει να προσφέρει τίποτα.

Αυτό δεν αναιρεί το εύρημα του πλήρους panel, το εξειδικεύει: χωρίς την Pinnacle οι closing bookmakers είναι υπερβολικά όμοιοι μεταξύ τους, οπότε δεν μένει ποιοτική διαφορά για να μαθευτεί. Η διαμόρφωση αναφοράς είναι δηλαδή η καλύτερη εν μέρει *επειδή* περιέχει τον καλύτερο odds-setter της αγοράς.

5.4 Τι δεν δούλεψε (και γιατί αξίζει να αναφερθεί)

Τέσσερις επεκτάσεις έδωσαν αρνητικό αποτέλεσμα. Τις κρατώ ρητά, γιατί η καθεμία αποκλείει μια εύλογη υπόθεση:

- **Εξειδίκευση ανά πρωτάθλημα δεν βοηθάει:** το ενιαίο μοντέλο ξεπερνά τους ειδικούς συνολικά ($+0,00058$, $p < 0,001$) και μάλιστα σε *κάθε* μία από τις 6 λίγκες. Δύο εύλογες αιτίες: κάθε λίγκα έχει μόνο 2.231–3.800 αγώνες (πολύ λίγοι για να συγκλίνει ο online αλγόριθμος μόνος του), και οι ειδικοί καταλήγουν να *εμπιστεύονται τους ίδιους experts* με το ενιαίο μοντέλο (ο PSC είναι πρώτος σε 4 από τις 6 λίγκες), δηλαδή δεν βρίσκουν κάτι τοπικό.
- **Βαθμονόμηση ανά σεζόν δεν βοηθάει,** ούτε στην παραλλαγή «warm-start» που μεταφέρει τη θερμοκρασία της προηγούμενης σεζόν: και οι δύο κερδίζουν σημαντικά το raw, αλλά είναι στατιστικά *αδιάκριτες* από την ενιαία global βαθμονόμηση. Ίδια αφήγηση bias–variance με την εξειδίκευση ανά λίγκα, σε άλλη διάσταση.

- **To Fixed-Share δουλεύει, αλλά κοστίζει:** περιορίζει όντως τα διογκωμένα βάρη (CLC: 0,240 $\rightarrow$ 0,064 για $\alpha = 0,01$ · οι τέσσερις bookmakers ενεργοί μόνο στη σεζόν 2024/25 από 0,164–0,177 σε ακριβώς 0,100, δηλαδή στην ισοτιμία του συνόλου τους), με μικρό αλλά υπαρκτό κόστος στο συνολικό log-loss (0,99845 $\rightarrow$ 0,99885).
- **Το να μαθαίνεται το ποσό Kelly online χάνει** από τον κλειστό τύπο, σε 17 από 20 συγκρίσεις σημαντικά (και στις υπόλοιπες 3 χάνει, απλώς όχι σημαντικά). Η εξήγηση είναι διδακτική: ο online learner ξεκινά τυφλός ($f = 0$) και μαθαίνει μόνο από πραγματοποιημένα κερδοφόρα/ζημιογόνα αποτελέσματα με συντηρητικό, worst-case-ασφαλή ρυθμό, ενώ ο κλειστός τύπος χρησιμοποιεί κατευθείαν την ήδη διαθέσιμη εκτίμηση πιθανότητας χωρίς κόστος εκκίνησης. Συμπέρασμα: η αξία του OCO εδώ είναι στο *στάδιο πρόβλεψης*, όχι στο να ξαναμαθαίνει κάτι που ο κλειστός τύπος δίνει δωρεάν.

5.5 Οικονομικός έλεγχος: βοηθάει το καλύτερο log-loss;

Όχι αυτόματα — και αυτό είναι από τα πιο ουσιαστικά ευρήματα. Καλύτερο proper scoring rule δεν συνεπάγεται εκμεταλλεύσιμη άκρη, γιατί πρέπει να ξεπεραστεί και το περιθώριο του bookmaker.

Ο σχεδιασμός είναι Kelly $\frac{1}{4}$, leave-one-bookmaker-out, με βαθμονομημένες πιθανότητες, και το **panel εκπαίδευσης ταιριάζει στη φάση του στόχου**: closing-only panel για closing στόχο, opening-only για opening στόχο. Το δεύτερο είναι απαίτηση αιτιότητας — καμία closing τιμή δεν υπάρχει ακόμα όταν δημοσιεύεται μια τιμή ανοίγματος. Το πρώτο είναι επιλογή ποιότητας, συνεπής με τη διαμόρφωση αναφοράς του §5.3.

Στόχος	Φάση	Στοιχήματα	Κεφάλαιο	log-growth	p
WHC	closing	7.253	84,24×	+0,00061	< 0,001
IW	opening	7.443	7,89×	+0,00028	0,008
BWC	closing	6.920	3,09×	+0,00016	0,042
VC_BVC	closing	4.561	1,58×	+0,00010	0,339
WH	opening	5.931	1,38×	+0,00005	0,545
BW	opening	7.841	1,09×	+0,00001	0,820
B365C	closing	7.643	1,05×	+0,00001	0,968
VC_BV	opening	8.083	0,60×	−0,00006	0,245
PSC	closing	19.497	0,54×	−0,00003	0,368
B365	opening	10.829	0,41×	−0,00008	0,101
PS	opening	26.675	0,26×	−0,00005	0,055

Πίνακας 4: Μέσο log-growth ανά στοίχημα είναι η στήλη σύγκρισης· τα τελικά κεφάλαια δεν συγκρίνονται μεταξύ γραμμών, αφού ο αριθμός στοιχημάτων διαφέρει κατά τάξη μεγέθους.


- **Σημαντική θετική άκρη σε 3:** WHC, IW, BWC.
- **Καμία σημαντική ζημιά.** Ο PSC, ο #1 προγνώστης, βγαίνει ισοπαλία ($p = 0,368$) — το ίδιο αποτέλεσμα που δίνει και η σύγκριση πρόβλεψης στη διαμόρφωση αναφοράς, από ανεξάρτητο δρόμο.
- **Η αντιστοίχιση φάσης δεν είναι λεπτομέρεια.** Με το πλήρες panel αντί για το closing-only, το αποτέλεσμα χειροτερεύει σε *κάθε* έναν από τους πέντε closing στόχους και ο PSC γίνεται σημαντική ζημιά. Προς την άλλη κατεύθυνση, μείγμα εκπαιδευμένο μόνο σε opening χάνει σημαντικά από *κάθε* closing bookmaker (−0,00044 έως −0,00071, όλα $p < 0,001$): παλιότερη πληροφορία εναντίον νεότερης τιμής χάνει πάντα — το οικονομικό ανάλογο της κλίσης της κίνησης γραμμής.

Η ειλικρινής διατύπωση δεν είναι «καμία άκρη έναντι sharp, μεγάλη άκρη έναντι αδύναμων», αλλά:

η ύπαρξη και το μέγεθος της άκρης εξαρτώνται από τον συγκεκριμένο *bookmaker*. Η προσομοίωση δεν μοντελοποιεί όρια λογαριασμού/ρευστότητας, που στην πράξη θα εμποδίζουν τη συστηματική εκμετάλλευση οποιασδήποτε άκρης.

5.6 Τρία ακόμη ευρήματα με ανεξάρτητο ενδιαφέρον

- Το **προβάδισμα των closing αποδόσεων** ζει σε ένα πεμπτημόριο. Αν οι αγώνες ταξινομηθούν κατά το πόσο κινήθηκε η γραμμή από το opening στο closing (συνολική μεταβολή των τριών πιθανοτήτων) και χωριστούν σε πεμπτημόρια, η διαφορά closing μείον opening πάει από $-0,00044$ στο χαμηλότερο ($p = 0,052$, μη σημαντική) σε $-0,01158$ στο υψηλότερο ($p < 0,001$) — κλίση $26\times$ μονοτονικά. Όπου η τιμή δεν κινήθηκε, η απόδοση κλεισίματος δεν ξέρει τίποτα παραπάνω από την αρχική. Το «τα closing είναι καλύτερα» δεν είναι ιδιότητα της χρονικής στιγμής, είναι ιδιότητα της πληροφορίας που έφτασε στο ενδιάμεσο.
- Οι **ισοπαλίες είναι πρακτικά απρόβλεπτες** ως *argmax* πρόβλεψη: η καλύτερη σειρά (PSC) πιάνει μόλις 0,70% των πραγματικών ισοπαλιών, το OGD 0,30% — παρότι οι ισοπαλίες είναι $\sim 26\%$ των αγώνων. Επιβεβαιώνει ποσοτικά ένα γνωστό φαινόμενο της ποδοσφαιρικής πρόβλεψης.
- Η **αγορά δεν γίνεται πιο ακριβής, γίνεται πιο ακριβή**: σε 10 σεζόν δεν υπάρχει σημαντική τάση σε log-loss ή ECE (όλα τα Mann-Kendall $p > 0,37$), αλλά το **overround αυξάνεται σημαντικά**, από $\sim 4,4\%$ σε $\sim 6,0\%$ ($p = 0,0007$) — το αντίθετο από την αφήγηση «ώρμη, πιο ανταγωνιστική αγορά».




Σχήμα 2: Ανά σεζόν, περιορισμένο στους 4 bookmakers που υπάρχουν σε όλες τις 10 σεζόν ώστε οι διαφορές να μην συγχέονται με αλλαγές κάλυψης. Αριστερά/δεξιά: καμία σημαντική τάση. Μέση: το περιθώριο ανεβαίνει σταθερά.

6 Έλεγχοι αξιοπιστίας

Το μεγαλύτερο μέρος της πρόσφατης δουλειάς δεν πρόσθεσε νέα ευρήματα, αλλά έλεγξε αν τα υπάρχοντα αντέχουν.

Η μέθοδος *de-vig* δεν αλλάζει την ιστορία. Ξαναφτιάχτηκε ολόκληρο το dataset με τη μέθοδο του Shin (1992) (μοντελοποιεί μια αναλογία «insider» στοιχηματιστών και μετακινεί μάζα από τα outsider προς τα φαβορί, αντί να μοιράζει το περιθώριο ομοιόμορφα) και ξανατρέχτηκε η βασική σύγκριση. Η **κατάταξη είναι ταυτόσημη** (PSC #1, μετά OGD>Hedge>FTL>Uniform). Το Shin βελτιώνει σημαντικά τα raw log-loss και Brier σε όλες τις 11 οντότητες ($p < 0,0001$) και σχεδόν υποδιπλασιάζει

το ECE (-35% έως -57% π.χ. OGD: $0,0091 \rightarrow 0,0043$) — αλλά το πλεονέκτημα σε μεγάλο βαθμό εξαφανίζεται μετά τη βαθμονόμηση, και συμμετρικά η βαθμονόμηση παύει να είναι σημαντική για 9 από 11 σειρές όταν έχει ήδη εφαρμοστεί Shin (έναντι 11/11 σημαντικές με proportional normalization). Ερμηνεία: οι δύο μέθοδοι διορθώνουν το ίδιο favorite-longshot bias με διαφορετικό μηχανισμό — μία ανά αγώνα, cross-sectional, η άλλη online κατά μήκος της ιστορίας — οπότε μόλις γίνει η μία, η άλλη γίνεται σε μεγάλο βαθμό περιττή.



Σχήμα 3: Απόκλιση βαθμονόμησης (πραγματική — προβλεπόμενη συχνότητα) ανά bin: proportional normalization (αριστερά) έναντι Shin (δεξιά). Το εύρος συρρικνώνεται δραματικά — οπτική επιβεβαίωση ότι το Shin κάνει μηχανιστικά αυτό που υπόσχεται.

Οι αποδόσεις κλεισίματος κερδίζουν, και οι opening βλάπτουν το μείγμα. Και για τους 4 αλγόριθμους, ένα μείγμα μόνο από closing bookmakers είναι σημαντικά καλύτερο από ένα μόνο από opening ($\sim 0,0034-0,0036$ χαμηλότερο log-loss) — αναμενόμενο, αφού η τιμή κλεισίματος έχει απορροφήσει την πληροφορία της κίνησης της αγοράς. Λιγότερο αναμενόμενο: το closing-only μείγμα κερδίζει σημαντικά και το πλήρες panel των 26, ενώ το opening-only χάνει σημαντικά από αυτό. Δηλαδή η σειρά $\text{closing} < \text{πλήρες} < \text{opening}$ ισχύει με στατιστική βεβαιότητα, που σημαίνει ότι οι opening bookmakers είναι καθαρό βάρος για το μείγμα και όχι χρήσιμη διαφοροποίηση. Στη συνολική κατάταξη, το «OGD (closing)» είναι ο καλύτερα ταξινομημένος αλγόριθμος στο #3 συνολικά, πίσω μόνο από τον PSC και μία σειρά μονής σεζόν. Αυτό το εύρημα είναι και ο λόγος που το closing-only panel επιλέχθηκε τελικά ως η διαμόρφωση αναφοράς (§5.3).

Η αιτιότητα του panel στο value betting. Ένα σχέδιο leave-one-out δεν αρκεί να βγάλει τη στήλη του στόχου: για opening στόχο πρέπει να φύγει όλη η closing πλευρά, γιατί καμία closing τιμή δεν υπάρχει ακόμα όταν δημοσιεύεται μια τιμή ανοίγματος. Αν μείνουν μέσα, το μοντέλο στοιχηματίζει γνωρίζοντας πού θα κλείσει η αγορά, και το αποτέλεσμα είναι τελικά κεφάλαια τάξης $10^6-10^9 \times$, δηλαδή καθαρό τεχνούργημα. Με το panel σωστά περιορισμένο δεν μένει μετρήσιμη άκρη σε αυτή την περίπτωση ($+0,00004$, $p = 0,439$ βαθμονομημένο). Το σχέδιο τρέχει σε πλήρες grid 108 γραμμών (2 κανονικοποιήσεις $\times 3$ τύποι panel $\times$ κάθε στόχος), ώστε κάθε συνδυασμό να μπορεί κανείς να τον δει.

Το βάθος ιστορίας αλλάζει συμπεράσματα. Με 10 σεζόν, και οι τρεις αλγόριθμοι ξεπερνούν σημαντικά την ομοιόμορφη μέση τιμή: στο μισό χρονικό παράθυρο μόνο το OGD το πετυχαίνει. Αυτό μετρήθηκε απομονωμένα (ίδιο panel 22 λιγκών, μόνο το χρονικό παράθυρο αλλάζει), ώστε το αποτέλεσμα να μην συγχέεται με την επέκταση σε περισσότερα πρωταθλήματα.

Η ανάγνωση των βαρών ενός κοιμισμένου expert. Λόγω της αναγωγής Sleeping Experts, ο πίνακας βαρών $W[t, i]$ συμπληρώνεται μόνο για τους ξύπνιους experts κάθε γύρου. Άρα η τελευταία γραμμή $W[-1]$ δεν είναι «το τελικό βάρος κάθε expert»: είναι ακριβώς μηδέν για όποιον δεν κάλυψε τον τελευταίο αγώνα του dataset — 10 από τους 26 bookmakers εδώ, μεταξύ τους ο PSC, ο καλύτερος μεμονωμένος προγνώστης. Η σωστή ποσότητα, και αυτή που αναφέρεται παντού, είναι το βάρος που κρατούσε ο κάθε expert **την τελευταία φορά που ήταν ξύπνιος**. Η διάκριση αφορά μόνο την ανάγνωση της κατάστασης, όχι τους ίδιους τους αλγορίθμους: καμία μετρική ποιότητας πρόβλεψης δεν εξαρτάται από αυτήν.

7 Γνωστοί περιορισμοί

Αναφέρονται ρητά, δεν αποκρύπτονται:

- Η συγχώνευση VC/BetVictor συνάγεται από τη μη επικαλυπτόμενη παρουσία ανά σεζόν, δεν είναι επιβεβαιωμένη από επίσημη πηγή — είναι εύλογο να υπάρχουν κι άλλα μη εντοπισμένα rebrands, ιδίως τώρα με 22 πρωταθλήματα.
- Το log-loss είναι η κύρια μετρική στο μεγαλύτερο μέρος της εργασίας. Το Brier αναλύεται συστηματικά μόνο στη σύγκριση de-vig· το RPS υπολογίζεται παντού αλλά δεν αναλύεται συστηματικά πουθενά.
- Η προσομοίωση value betting αγνοεί όρια λογαριασμού και ρευστότητα.
- Ένα σχέδιο leave-one-out εισάγει look-ahead bias αν το panel δεν περιοριστεί στην πληροφορία που θα ήταν όντως διαθέσιμη τη στιγμή του στοιχήματος. Ο περιορισμός εφαρμόζεται ρητά ανά φάση αγοράς, αλλά δεν αποκλείεται να υπάρχουν άλλα, λιγότερο προφανή κανάλια.
- Οι αιτιώδεις εξηγήσεις για ορισμένα ευρήματα (π.χ. γιατί αυξάνεται το overround) είναι εύλογες, όχι αποδεδειγμένες.

8 Κατάσταση και ερωτήματα προς συζήτηση

Το πλήρες pipeline τρέχει καθαρά end-to-end, και το εκτενές κείμενο (θεωρία, υλοποίηση, όλα τα ευρήματα, χάρτης αρχείων) είναι σε προχωρημένο στάδιο. Τρία ερωτήματα όπου θα ήθελα κατεύθυνση:

1. **Scope της αφήγησης.** Έχουν συσσωρευτεί ~10 follow-up ευρήματα. Πόσα αξίζει να μπουν σε κεντρικό κεφάλαιο και πόσα σε παράρτημα, ώστε το κείμενο να έχει καθαρή, εστιασμένη αφήγηση αντί να διασπείρεται;
2. **Δεύτερο άθλημα.** Θα ενίσχυε ουσιαστικά την εργασία ένα δεύτερο άθλημα (π.χ. μπάσκετ), ώστε να φανεί ότι το πλαίσιο OCO γενικεύεται πέρα από το ποδόσφαιρο; Το κόστος είναι κυρίως νέος αγωγός δεδομένων — οι αλγόριθμοι δεν αλλάζουν.
3. **Baseline προς σύγκριση.** Θα άξιζε ένα πραγματικό Bayesian Model Averaging baseline (συζητείται θεωρητικά, δεν έχει υλοποιηθεί), ως εμπειρικό σημείο σύγκρισης απέναντι στους online αλγορίθμους;

Επιπλέον, ανοιχτά και μικρότερης κλίμακας: συστηματική αναζήτηση για κι άλλα rebrands bookmakers στα 22 πρωταθλήματα, και διερεύνηση του *γιατί* αυξάνεται το overround (θα απαιτούσε δεδομένα εκτός football-data.co.uk).