



ΠΟΛΥΤΕΧΝΕΙΟ ΚΡΗΤΗΣ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΤΗΛΕΠΙΚΟΙΝΩΝΙΩΝ

**Κυρτή Βελτιστοποίηση σε Πραγματικό Χρόνο
Βασισμένη στην Παραμετροποίηση Μείγματος Ειδικών
για την Πρόβλεψη Αποτελεσμάτων Αθλητικών Αγώνων**

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Στέφανος Μουσάδης

ΕΞΕΤΑΣΤΙΚΗ ΕΠΙΤΡΟΠΗ

Αναπληρωτής Καθηγητής Θρασύβουλος Σπυρόπουλος, *Επιβλέπων*

Καθηγητής Μιχαήλ Γ. Λαγουδάκης

Αναπληρωτής Καθηγητής Βασίλειος Σαμολαδάς

Χανιά, 2026

Περίληψη

Η παρούσα εργασία προβλέπει τα αποτελέσματα αθλητικών αγώνων ($1/X/2$) ως πρόβλημα **online μάθησης με συμβουλή ειδικών**, και όχι ως εκπαίδευση στατιστικού μοντέλου. Κάθε στοιχηματικός πάροχος θεωρείται ένας expert που δίνει αποδόσεις για τα τρία ενδεχόμενα, από τις οποίες προκύπτουν πιθανότητες. Ζητούμενο είναι η εύρεση ενός διανύσματος βαρών έτσι ώστε το μείγμα των experts να τους ξεπερνά ατομικά, με μάθηση όχι αναδρομικά πάνω στο παρελθόν, αλλά αγώνα προς αγώνα.

Υλοποιούνται τρία στάδια Κυρτής Βελτιστοποίησης σε Πραγματικό Χρόνο (**Online Convex Optimization**, OCO). Αρχικά κατασκευάζονται τρεις αλγόριθμοι (Hedge, Online Gradient Descent, Follow-The-Regularized-Leader), που με την αναγωγή σε **Sleeping Experts** διαχειρίζονται τους παρόχους μερικής κάλυψης. Έπειτα, με δεύτερο στάδιο OCO, γίνεται βαθμονόμηση μέσω online temperature scaling. Τέλος υπολογίζεται το μέγεθος του στοιχήματος με το κριτήριο Kelly, όπου ο πολλαπλασιαστής του μαθαίνεται online με Online Newton Step. Κάθε σύγκριση ελέγχεται με moving block bootstrap. Το σύνολο δεδομένων καλύπτει 22 πρωταθλήματα, 10 σεζόν και 76.584 αγώνες.

Το μείγμα ξεπερνά στατιστικά σημαντικά κάθε μεμονωμένο bookmaker πλην του σκληρότερου, με τον οποίο ισοπαλεί στη διαμόρφωση που επιλέγεται τελικά. Σε έλεγχο ανάπτυξης με πραγματική χρονική τομή — εκπαίδευση έως το τέλος του 2024, μέτρηση στο 2025–26 — ξεπερνά ή ισοπαλεί με κάθε τιμή της αγοράς: κερδίζει σημαντικά όλες τις τιμές ανοίγματος και ισοπαλεί με όλες τις τιμές κλεισίματος, χωρίς καμία να το ξεπερνά.

Τα τρία γενικότερα ευρήματα είναι ότι η μάθηση αποδίδει μόνο όταν οι experts έχουν ανομοιομορφία στην ποιότητα, ότι η καλύτερη πρόβλεψη δεν μεταφράζεται άμεσα σε κέρδος καθώς η διαφορά ποιότητας υπολείπεται του περιθωρίου της αγοράς, και ότι ένα μέρος της υπεροχής έναντι της ομοιόμορφης μέσης τιμής δεν οφείλεται στη μάθηση αλλά στη γεωμετρία της αναγωγής Sleeping Experts.

Λέξεις-κλειδιά: online κυρτή βελτιστοποίηση, πρόβλεψη με συμβουλή ειδικών, sleeping experts, regret, βαθμονόμηση πιθανοτήτων, αγορές στοιχηματισμού

Abstract

This thesis predicts sports match outcomes (home / draw / away) as a problem of **on-line learning with expert advice**, rather than as the training of a statistical model. Each betting operator is treated as an expert quoting odds on the three outcomes, from which probabilities are derived. The task is to find a weight vector such that the mixture of experts outperforms each of them individually, learning not retrospectively over the past but match by match.

Three stages of **Online Convex Optimization** (OCO) are implemented. First, three algorithms are built (Hedge, Online Gradient Descent, Follow-The-Regularized-Leader), which handle partially covering operators through the **Sleeping Experts** reduction. A second OCO stage then calibrates the mixture via online temperature scaling. Finally the bet size is computed with the Kelly criterion, whose multiplier is itself learned online with Online Newton Step. Every comparison is tested with a moving block bootstrap. The dataset spans 22 leagues, 10 seasons and 76,584 matches.

The mixture significantly outperforms every individual bookmaker except the sharpest, with which it draws level in the configuration ultimately adopted. Under a deployment test with a genuine temporal cut — fitted through the end of 2024, evaluated on 2025–26 — it matches or beats every price in the market: it significantly outperforms all opening prices and draws level with all closing prices, with none of them outperforming it.

The three broader findings are that learning pays only where experts are heterogeneous in quality; that better prediction does not translate directly into profit, since the quality gain falls short of the market's margin; and that part of the advantage over the uniform average is due not to learning but to the geometry of the Sleeping Experts reduction.

Keywords: online convex optimization, prediction with expert advice, sleeping experts, regret, probability calibration, betting markets

Περιεχόμενα

Περίληψη	1
Abstract	2
1 Εισαγωγή	6
1.1 Το πρόβλημα	6
1.2 Γιατί δεν είναι τετριμμένο	6
1.3 Συνεισφορά	7
1.4 Δομή	7
2 Σχετική βιβλιογραφία	8
2.1 Online μάθηση και θεωρία regret	8
2.2 Πρόβλεψη αθλητικών αποτελεσμάτων	9
2.3 Αποδοτικότητα αγορών στοιχηματισμού	9
2.4 Favorite-longshot bias και μετατροπή αποδόσεων	10
2.5 Βαθμονόμηση πιθανοτήτων	10
2.6 Συνδυασμός προβλέψεων	10
2.7 Θέση της παρούσας εργασίας	10
3 Θεωρητικό υπόβαθρο	12
3.1 Online μάθηση και regret	12
3.2 Πρόβλεψη με συμβουλή ειδικών	14
3.3 Από αποδόσεις σε πιθανότητες: de-vig	15
3.4 Μικροδομή της αγοράς στοιχηματισμού	16
3.5 Hedge	17
3.6 Online Gradient Descent	19
3.7 Follow-The-Regularized-Leader	21
3.8 Exp-concavity και ο Aggregating Algorithm	22
3.9 Η αναγωγή Sleeping Experts	23
3.10 Fixed-Share	25
3.11 Μαρκοβιανές αλυσίδες: τρεις διαφορετικές χρήσεις	25
3.12 Bandit online κυρτή βελτιστοποίηση	27
3.13 Κατάλληλοι κανόνες βαθμολόγησης και βαθμονόμηση	28
3.14 Στατιστική σημαντικότητα: moving block bootstrap	30
3.15 Το κριτήριο Kelly	30
3.16 Το μέγεθος του στοιχήματος ως τρίτο στάδιο OCO	32
3.17 Μπεϋζιανή εκδοχή του Kelly και δειγματοληψία MCMC	33

4	Δεδομένα	35
4.1	Πηγή και εύρος	35
4.2	Καθαρισμός	35
4.3	Αποδόσεις ανοίγματος και κλεισίματος	36
5	Μεθοδολογία	37
5.1	Ο τανυστής των experts	37
5.2	Τα τρία στάδια OCO	37
5.3	Πρωτόκολλο επιλογής υπερπαραμέτρων	38
5.4	Ρύθμιση του βήματος	38
5.5	Σύγκριση σειρών με διαφορετική κάλυψη	38
5.6	Έλεγχοι αιτιότητας στο value betting	39
5.7	Έλεγχος ανάπτυξης	39
6	Υλοποίηση	40
6.1	Οργάνωση	40
6.2	Αριθμητικά ζητήματα	41
6.3	Τρία σφάλματα που εντοπίστηκαν	41
6.4	Επαλήθευση	42
7	Αποτελέσματα	43
7.1	Ρύθμιση του βήματος	43
7.2	Κατάταξη στο πλήρες panel	45
7.3	Ποιο panel	47
7.4	Πού ακριβώς υπερέχουν οι τιμές κλεισίματος	48
7.5	Η διαμόρφωση που επιλέγεται	49
7.6	Χωρίς την Pinnacle	51
7.7	Πρόσφατο παράθυρο	52
7.8	Έλεγχος ανάπτυξης	54
7.9	Value betting και το μαθαίνόμενο μέγεθος στοιχήματος	55
7.10	Πόση πληροφορία χρειάζεται η μάθηση; Το bandit πείραμα	58
7.11	Μαρκοβιανή εναλλαγή καθεστώτων αγοράς	61
7.12	Αρνητικά αποτελέσματα	62
8	Συζήτηση	64
8.1	Τι έδειξε η εργασία	64
8.2	Πότε αποδίδει η μάθηση: η ανομοιογένεια ως προϋπόθεση	65
8.3	Η υλική βάση των διαφορών	65
8.4	Ο χαρακτήρας της μεθόδου	66
8.5	Περιορισμοί	67
9	Συμπεράσματα και επεκτάσεις	68
9.1	Συμπεράσματα	68
9.2	Επεκτάσεις	69

A' Πλήρεις πίνακες αποτελεσμάτων	70
A'.1 Κατάταξη και στατιστική σημαντικότητα	70
A'.2 Panel και μέθοδος de-vig	71
A'.3 Διαμορφώσεις	73
A'.4 Χωρίς την Pinnacle	74
A'.5 Πρόσφατο παράθυρο και έλεγχος ανάπτυξης	75
A'.6 Value betting	77
A'.7 Επεκτάσεις και αρνητικά αποτελέσματα	80
Βιβλιογραφία	87

Κεφάλαιο 1

Εισαγωγή

1.1 Το πρόβλημα

Η πρόβλεψη του αποτελέσματος ενός ποδοσφαιρικού αγώνα αντιμετωπίζεται συνήθως ως πρόβλημα επιβλεπόμενης μάθησης: συγκεντρώνονται χαρακτηριστικά των ομάδων και των αγώνων, εκπαιδεύεται ένα μοντέλο, και αξιολογείται σε δεδομένα που δεν έχει δει. Η προσέγγιση αυτή προσκρούει σε έναν πρακτικό φραγμό. Οι στοιχηματικές εταιρείες λύνουν ήδη το ίδιο πρόβλημα, με ασύγκριτα περισσότερα δεδομένα, με ομάδες αναλυτών και με άμεσο οικονομικό κίνητρο να το λύσουν σωστά. Ένα μοντέλο εκπαιδευμένο στο πλαίσιο μιας διπλωματικής δύσκολα θα τις ανταγωνιστεί στο έδαφός τους.

Η εργασία αυτή αλλάζει το ερώτημα. Αντί να χτίζει έναν ακόμη προγνώστη, αντιμετωπίζει *κάθε στοιχηματική εταιρεία ως έναν expert* που δημοσιεύει, πριν από κάθε αγώνα, τις δικές του πιθανότητες (p_H, p_D, p_A) για τα τρία ενδεχόμενα. Το ζητούμενο γίνεται τότε: πώς συνδυάζονται αυτές οι γνώμες, online και χωρίς γνώση του μέλλοντος, ώστε το μείγμα να είναι καλύτερος προγνώστης από τον καθένα τους χωριστά;

Το πλαίσιο που απαντά σε αυτό είναι η *πρόβλεψη με συμβουλή ειδικών* (prediction with expert advice) και, γενικότερα, η *online κυρτή βελτιστοποίηση* (Online Convex Optimization, OCO). Το βασικό του πλεονέκτημα εδώ είναι ότι δίνει εγγυήσεις regret **χωρίς καμία στατιστική υπόθεση** για την κατανομή των δεδομένων: δεν απαιτείται τα αποτελέσματα να προέρχονται από σταθερή κατανομή, ούτε οι experts να είναι ανεξάρτητοι. Αυτό ταιριάζει σε μια αγορά που μεταβάλλεται, όπου εταιρείες εμφανίζονται και εξαφανίζονται και όπου οι τιμές διαμορφώνονται στρατηγικά.

1.2 Γιατί δεν είναι τετριμμένο

Η εφαρμογή του πλαισίου σε πραγματικά δεδομένα συναντά τρεις δυσκολίες που καθορίζουν τη δομή της εργασίας.

Μερική κάλυψη. Οι κλασικοί αλγόριθμοι υποθέτουν ότι κάθε expert δίνει πρόβλεψη σε κάθε γύρο. Στην πράξη, στα δεδομένα που χρησιμοποιούμε, η κάλυψη ανά bookmaker κυμαίνεται από 6,9% έως 99,8% των αγώνων, και αρκετές εταιρείες εμφανίζονται ή εξαφανίζονται στη μέση της δεκαετίας. Χρειάζεται η αναγωγή *Sleeping Experts*, που αντιστοιχίζει σε κάθε expert εγγύηση μετρημένη μόνο πάνω στους γύρους όπου ήταν παρών.

Οι αποδόσεις δεν είναι πιθανότητες. Οι δημοσιευμένες αποδόσεις ενσωματώνουν το περιθώριο κέρδους του bookmaker: τα αντίστροφα τους αθροίζουν σε περισσότερο από ένα. Η μετατροπή τους σε πιθανότητες (de-vig) είναι μοντελοποιητική επιλογή που μπορεί να επηρεάσει τα συμπεράσματα, και γι' αυτό ελέγχεται με δύο ανεξάρτητες μεθόδους.

Το καλύτερο log-loss δεν είναι το ζητούμενο. Ένα μείγμα μπορεί να προβλέπει καλύτερα από κάθε bookmaker και να χάνει χρήματα, αν η υπεροχή του είναι μικρότερη από το περιθώριο της αγοράς. Η εργασία ελέγχει ρητά αυτό το χάσμα, με προσομοίωση στοιχηματισμού βασισμένη στο κριτήριο Kelly.

1.3 Συνεισφορά

Η εργασία συνεισφέρει τα εξής.

- Πλήρη υλοποίηση τριών αλγορίθμων OCO με την αναγωγή Sleeping Experts, πάνω σε σύνολο 22 πρωταθλημάτων, 10 σεζόν και 76.584 αγώνων, με 26 bookmakers ως experts.
- Δύο επιπλέον στάδια OCO πάνω στο μείγμα: βαθμονόμηση με online temperature scaling και μέγεθος στοιχήματος με μαθαίνόμενο πολλαπλασιαστική Kelly, ώστε ολόκληρη η αλυσίδα από τις αποδόσεις ως το στοίχημα να είναι online και αιτιώδης. Δείχνεται ότι το *τι* μαθαίνεται στο τρίτο στάδιο είναι καθοριστικό: η μάθηση του πονταρίσματος κατευθείαν αποτυγχάνει συστηματικά, ενώ η μάθηση του πολλαπλασιαστική πάνω στον κλειστό τύπο όχι.
- Συστηματικό στατιστικό έλεγχο κάθε σύγκρισης με moving block bootstrap, αντί για σύγκριση σημειακών εκτιμήσεων.
- Έλεγχο ανάπτυξης με πραγματική χρονική τομή, που απαντά στο ερώτημα «τι θα έκανε σήμερα ένα μοντέλο εκπαιδευμένο ως το 2024».
- Μια σειρά αρνητικών ευρημάτων που περιορίζουν το πεδίο εφαρμογής της μεθόδου και είναι, κατά τη γνώμη μας, εξίσου χρήσιμα με τα θετικά.

1.4 Δομή

Το Κεφάλαιο 3 αναπτύσσει το θεωρητικό υπόβαθρο. Το Κεφάλαιο 4 περιγράφει τα δεδομένα και την προεπεξεργασία τους. Το Κεφάλαιο 5 παρουσιάζει τη μεθοδολογία και τις αποφάσεις σχεδιασμού. Το Κεφάλαιο 7 δίνει τα αποτελέσματα και το Κεφάλαιο 8 τα συζητά, μαζί με τα όρια της μεθόδου. Το Κεφάλαιο 9 συνοψίζει και προτείνει επεκτάσεις.

Κεφάλαιο 2

Σχετική βιβλιογραφία

Η εργασία τοποθετείται στη συμβολή τριών ερευνητικών παραδόσεων που αναπτύχθηκαν σε μεγάλο βαθμό ανεξάρτητα: της θεωρίας online μάθησης, της πρόβλεψης αθλητικών αποτελεσμάτων, και της οικονομικής μελέτης των αγορών στοιχηματισμού. Το κεφάλαιο αυτό σκιαγραφεί καθεμία και προσδιορίζει πού εντάσσεται η παρούσα συνεισφορά.

2.1 Online μάθηση και θεωρία regret

Η ιδέα της πρόβλεψης με συμβουλή ειδικών προηγείται της σύγχρονης μηχανικής μάθησης. Στην υπολογιστική της μορφή εμφανίζεται με τον αλγόριθμο *weighted majority* των Littlestone & Warmuth (1994), που έδειξε ότι είναι δυνατόν να εγγυηθεί κανείς απόδοση σχεδόν όσο καλή όσο του καλύτερου expert ενός συνόλου, χωρίς καμία υπόθεση για το πώς παράγονται τα δεδομένα. Η γενίκευση σε συνεχή βάρη και σε κυρτές απώλειες οδήγησε στον Hedge και στην οικογένεια των πολλαπλασιαστικών ενημερώσεων.

Παράλληλα αναπτύχθηκε η ιδέα της *αθροιστικής στρατηγικής* (aggregating algorithm) του Vovk (1990), η οποία εκμεταλλεύεται μια ισχυρότερη ιδιότητα ορισμένων απωλειών, την *exp-concavity*. Όταν η απώλεια είναι *exp-concave* — όπως είναι το *log-loss* — το regret μπορεί να φραχθεί από $\ln N$, δηλαδή *ανεξάρτητα* από τον ορίζοντα T , αντί για $O(\sqrt{T \log N})$. Το αποτέλεσμα αυτό είναι θεωρητικά ισχυρότερο, και η εργασία μας προσφέρει ένα εμπειρικό παράδειγμα όπου εντούτοις αποτυγχάνει, για λόγους που συνδέονται με τη μη στασιμότητα του συνόλου των experts.

Η ενοποίηση των παραπάνω κάτω από τον κοινό τίτλο της *online κυρτής βελτιστοποίησης* οφείλεται σε μεγάλο βαθμό στον Zinkevich (2003), ο οποίος έδειξε ότι η απλή προβολική κατάβαση κλίσης επιτυγχάνει $\text{regret } O(\sqrt{T})$ για οποιαδήποτε ακολουθία κυρτών συναρτήσεων. Οι σύγχρονες συνθετικές παρουσιάσεις του πεδίου δίνονται από τους Cesa-Bianchi & Lugosi (2006) και Hazan (2016).

Δύο επεκτάσεις είναι άμεσα σχετικές με την εφαρμογή μας. Η πρώτη είναι η αναγωγή *sleeping experts* ή *specialists* (Freund, Schapire, Singer & Warmuth, 1997· Blum & Mansour, 2007), που αντιμετωπίζει experts οι οποίοι δεν συμμετέχουν σε κάθε γύρο. Η δεύτερη είναι το *Fixed-Share* των Herbster & Warmuth (1998), το οποίο αλλάζει τον comparator από το καλύτερο σταθερό διάνυσμα στην καλύτερη ακολουθία διανυσμάτων με περιορισμένο πλήθος αλλαγών, και άρα απευθύνεται ακριβώς στο πρόβλημα της μη στασιμότητας.

Τέλος, οι προσαρμοστικοί ρυθμοί μάθησης τύπου AdaGrad (Duchi, Hazan & Singer, 2011) προτείνουν ανά συντεταγμένη κλιμάκωση του βήματος με βάση τη συσσωρευμένη

κλίση. Η ιδέα είναι ελκυστική σε ένα πλαίσιο όπου οι experts έχουν πολύ διαφορετική συχνότητα συμμετοχής, και εξετάζεται ρητά στο §7.12.

2.2 Πρόβλεψη αθλητικών αποτελεσμάτων

Η βιβλιογραφία της πρόβλεψης ποδοσφαιρικών αποτελεσμάτων ακολουθεί, χονδρικά, τρεις κατευθύνσεις.

Η πρώτη είναι τα *παραμετρικά στατιστικά μοντέλα*, με αφετηρία την παρατήρηση ότι τα γκολ προσεγγίζονται ικανοποιητικά από κατανομή Poisson. Τα μοντέλα αυτά εκτιμούν επιθετική και αμυντική ισχύ ανά ομάδα και παράγουν κατανομή σκορ, από την οποία προκύπτουν οι πιθανότητες $1/X/2$. Το βασικό τους πλεονέκτημα είναι η ερμηνευσιμότητα· το βασικό τους μειονέκτημα ότι απαιτούν επαρκές ιστορικό ανά ομάδα και δυσκολεύονται με μεταγραφές, αλλαγές προπονητή και ανόδους/υποβιβασμούς.

Η δεύτερη είναι η *μηχανική μάθηση πάνω σε χαρακτηριστικά*, όπου συγκεντρώνονται μεταβλητές μορφής, κατάταξης, στατιστικών αναμέτρησης και, στις πιο πρόσφατες εργασίες, δεδομένα παρακολούθησης παικτών. Τα μοντέλα αυτά συχνά αποδίδουν καλά σε σύγκριση με παραμετρικές εναλλακτικές, αλλά η σύγκρισή τους με την αγορά είναι σπανιότερη και συνήθως λιγότερο αυστηρή.

Η τρίτη, και η σχετικότερη εδώ, χρησιμοποιεί *τις ίδιες τις αποδόσεις ως πρόβλεψη*. Η προσέγγιση αυτή αναγνωρίζει ότι η τιμή της αγοράς ενσωματώνει το σύνολο της διαθέσιμης πληροφορίας, συμπεριλαμβανομένων στοιχείων που δεν αποτυπώνονται σε δημόσια στατιστικά. Η παρούσα εργασία ανήκει σε αυτή την κατηγορία, με τη διαφορά ότι δεν χρησιμοποιεί μία τιμή αλλά μαθαίνει online πώς να συνδυάζει πολλές.

2.3 Αποδοτικότητα αγορών στοιχηματισμού

Οι αγορές στοιχηματισμού αποτελούν προνομιακό πεδίο μελέτης της αποδοτικότητας των αγορών, για έναν συγκεκριμένο λόγο: σε αντίθεση με τις χρηματοπιστωτικές αγορές, κάθε στοιχείο έχει *καθορισμένη ημερομηνία λήξης και αντικειμενικά επαληθεύσιμο αποτέλεσμα*. Η θεμελιώδης αξία δεν χρειάζεται να εκτιμηθεί· αποκαλύπτεται.

Ο Levitt (2004) τεκμηριώνει ότι οι αγορές στοιχηματισμού οργανώνονται διαφορετικά από τις χρηματοπιστωτικές: ο bookmaker δεν λειτουργεί απλώς ως μεσάζων που εξισορροπεί τις δύο πλευρές, αλλά λαμβάνει ενεργή θέση, εκμεταλλευόμενος συστηματικές προκαταλήψεις των στοιχηματιστών. Η παρατήρηση αυτή είναι σημαντική για την ερμηνεία των διαφορών ανάμεσα στις εταιρείες: δεν αντανακλούν μόνο διαφορετική ικανότητα πρόβλεψης αλλά και διαφορετική επιχειρηματική στρατηγική.

Η θεωρία μικροδομής της αγοράς προσφέρει το πλαίσιο για την κατανόηση του τρόπου με τον οποίο η πληροφορία ενσωματώνεται στην τιμή. Τα υποδείγματα των Kyle (1985) και Glosten & Milgrom (1985) δείχνουν ότι, παρουσία πληροφορημένων συναλλασσομένων, η κίνηση της τιμής είναι ο μηχανισμός μέσω του οποίου η ιδιωτική πληροφορία γίνεται δημόσια, και ότι το άνοιγμα τιμής-προσφοράς λειτουργεί ως προστασία του διαμορφωτή έναντι αυτών. Το πλαίσιο αυτό φωτίζει άμεσα τη διαφορά ανάμεσα σε τιμές ανοίγματος και κλεισίματος (§4.3).

2.4 Favorite-longshot bias και μετατροπή αποδόσεων

Η συστηματικότερα τεκμηριωμένη ανωμαλία των αγορών στοιχηματισμού είναι το *favorite-longshot bias*: τα ενδεχόμενα μικρής πιθανότητας τιμολογούνται συστηματικά ακριβότερα απ' όσο δικαιολογεί η πραγματική τους συχνότητα. Το φαινόμενο έχει επιβεβαιωθεί σε πολλαπλά αθλήματα και δεκαετίες.

Ο Shin (1992, 1993) προσέφερε μια εξήγηση που δεν το αντιμετωπίζει ως ψυχολογική προκατάληψη των στοιχηματιστών αλλά ως *ορθολογική απόκριση* του bookmaker στην ύπαρξη πληροφορημένων συναλλασσομένων. Το υπόδειγμα παράγει ενδογενώς τη μορφή του bias και, το σημαντικότερο για εμάς, δίνει μια διαδικασία αντιστροφής που ανακτά τις δίκαιες πιθανότητες μαζί με μια εκτίμηση της αναλογίας z των πληροφορημένων. Ο Štrumbelj (2014) συγκρίνει συστηματικά τις μεθόδους μετατροπής αποδόσεων σε πιθανότητες και βρίσκει ότι η μέθοδος Shin υπερέχει της αναλογικής κανονικοποίησης ως προς την ποιότητα των προκυπτουσών πιθανοτήτων.

2.5 Βαθμονόμηση πιθανοτήτων

Η διάκριση ανάμεσα στην *αξιοπιστία* και τη *διακριτική ικανότητα* μιας πιθανοτικής πρόβλεψης ανάγεται στον Murphy (1973), ο οποίος έδειξε ότι κάθε κατάλληλος κανόνας βαθμολόγησης αναλύεται σε αυτές τις συνιστώσες. Η παρατήρηση έχει άμεση πρακτική συνέπεια: ένας προγνώστης μπορεί να διακρίνει άριστα ανάμεσα σε πιθανά και απίθανα ενδεχόμενα και εντούτοις να αποδίδει λανθασμένες πιθανότητες, σφάλμα διορθώσιμο χωρίς καμία επιπλέον πληροφορία.

Στη σύγχρονη βιβλιογραφία της μηχανικής μάθησης το ζήτημα επανήλθε με τους Guo κ.ά. (2017), οι οποίοι έδειξαν ότι τα βαθιά νευρωνικά δίκτυα είναι συστηματικά υπερβέβαια και ότι μια μονοπαραμετρική διόρθωση — το *temperature scaling* — αρκεί για να τα βαθμονομήσει. Η παρούσα εργασία χρησιμοποιεί την ίδια οικογένεια διόρθωσης, με τη διαφορά ότι η παράμετρος δεν προσαρμόζεται σε σύνολο επικύρωσης αλλά μαθαίνεται *online*, ως δεύτερο στάδιο OCO πάνω στο πρώτο.

2.6 Συνδυασμός προβλέψεων

Η ιδέα ότι ο συνδυασμός πολλών προβλέψεων υπερέχει της επιλογής μίας έχει μακρά ιστορία στην οικονομετρία και τη μετεωρολογία. Ένα σταθερό εμπειρικό εύρημα, γνωστό ως *forecast combination puzzle*, είναι ότι ο απλός μέσος όρος συχνά αποδεικνύεται ανθεκτικότερος από σταθμισμένους συνδυασμούς με βάρη εκτιμημένα από τα δεδομένα: το κέρδος από τη βελτιωμένη στάθμιση αναιρείται από τον θόρυβο εκτίμησης των βαρών.

Το εύρημα αυτό είναι άμεσα σχετικό με τα αποτελέσματά μας. Η εργασία δείχνει ότι ο συνδυασμός με μάθηση υπερέχει του απλού μέσου όρου όταν οι experts διαφέρουν ουσιωδώς σε ποιότητα, και υπολείπεται αυτού όταν δεν διαφέρουν — δηλαδή προσδιορίζει εμπειρικά τη συνθήκη υπό την οποία το puzzle ισχύει ή όχι.

2.7 Θέση της παρούσας εργασίας

Από τον συνδυασμό των παραπάνω προκύπτει το κενό στο οποίο απευθύνεται η εργασία. Η θεωρία *online* μάθησης προσφέρει αλγορίθμους με εγγυήσεις αλλά εφαρμόζε-

ται σπανιότερα σε αγορές στοιχηματισμού με πραγματική μερική κάλυψη. Η βιβλιογραφία πρόβλεψης αθλητικών αποτελεσμάτων χρησιμοποιεί συχνά τις αποδόσεις ως σημείο αναφοράς, αλλά λιγότερο συχνά ως *σύνολο experts προς συνδυασμό*. Και η οικονομική βιβλιογραφία των αγορών εξηγεί γιατί οι εταιρείες διαφέρουν, αλλά δεν αξιοποιεί αυτές τις διαφορές αλγοριθμικά.

Η συνεισφορά μας είναι η συστηματική σύνθεση των τριών: online αλγόριθμοι με εγγυήσεις, εφαρμοσμένοι στο πλήρες σύνολο των διαθέσιμων εταιρειών με τη σωστή αντιμετώπιση της μερικής κάλυψης, με στατιστικό έλεγχο κάθε σύγκρισης και με ρητή διάκριση ανάμεσα στην προγνωστική και στην οικονομική επίδοση.

Κεφάλαιο 3

Θεωρητικό υπόβαθρο

3.1 Online μάθηση και regret

Στο πλαίσιο της online μάθησης δεν υπάρχει διαχωρισμός σε φάση εκπαίδευσης και φάση εφαρμογής. Ο αλγόριθμος λειτουργεί σε γύρους: στον γύρο t διατυπώνει μια πρόβλεψη με βάση μόνο ό,τι έχει δει ως τον γύρο $t - 1$, στη συνέχεια αποκαλύπτεται το πραγματικό αποτέλεσμα, υφίσταται μια απώλεια, και ενημερώνει την κατάστασή του. Κάθε πρόβλεψη είναι επομένως εξ ορισμού εκτός δείγματος, χωρίς να χρειάζεται διαχωρισμός των δεδομένων.

Το μέτρο επιτυχίας δεν είναι η απόλυτη απώλεια αλλά το *regret*: πόσο χειρότερα τα πήγε ο αλγόριθμος από την καλύτερη σταθερή επιλογή εκ των υστέρων.

Ορισμός 3.1 (Regret). Έστω κυρτό σύνολο $\mathcal{K}$, ακολουθία κυρτών συναρτήσεων απώλειας $f_1, \dots, f_T$, και επιλογές $x_1, \dots, x_T \in \mathcal{K}$ του αλγορίθμου, όπου το x_t εξαρτάται μόνο από τα $f_1, \dots, f_{t-1}$. Το regret ορίζεται ως

$$\text{Regret}_T = \sum_{t=1}^T f_t(x_t) - \min_{x \in \mathcal{K}} \sum_{t=1}^T f_t(x).$$

Ένας αλγόριθμος θεωρείται επιτυχής όταν το regret του αυξάνεται υπογραμμικά ως προς T , δηλαδή $\text{Regret}_T/T \rightarrow 0$: μακροπρόθεσμα η μέση απώλειά του πλησιάζει αυτήν της καλύτερης σταθερής επιλογής. Κρίσιμο για την εφαρμογή μας είναι ότι η εγγύηση αυτή ισχύει **για κάθε** ακολουθία, χωρίς υπόθεση ανεξαρτησίας ή σταθερότητας της κατανομής.

Το σημείο αυτό αξίζει να διατυπωθεί με ακρίβεια, γιατί είναι ο λόγος για τον οποίο επιλέγεται εδώ το πλαίσιο OCO αντί του στατιστικού. Στη στατιστική θεωρία μάθησης το ζητούμενο είναι φράγμα στο *risk* $\mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h(x), y)]$, το οποίο προϋποθέτει ότι υπάρχει σταθερή κατανομή $\mathcal{D}$ και ότι τα δείγματα αντλούνται ανεξάρτητα από αυτήν. Καμία από τις δύο υποθέσεις δεν είναι αβλαβής εδώ: οι αποδόσεις διαμορφώνονται από μια αγορά που μεταβάλλεται μέσα στη δεκαετία, και διαδοχικοί αγώνες μοιράζονται αγωνιστική, πρωτάθλημα και περίοδο. Το regret δεν χρειάζεται καμία από τις δύο. Το τίμημα είναι ότι η εγγύηση γίνεται *σχετική*: δεν λέει ότι θα προβλέψουμε καλά, αλλά ότι δεν θα προβλέψουμε ουσιωδώς χειρότερα από τον καλύτερο σταθερό συνδυασμό των experts. Αν όλοι οι experts είναι κακοί, η εγγύηση τηρείται και το αποτέλεσμα παραμένει κακό.

Το πρωτόκολλο. Τυπικά, η online κυρτή βελτιστοποίηση είναι το εξής παίγνιο μεταξύ του αλγορίθμου και ενός — εν δυνάμει εχθρικού — περιβάλλοντος:

για $t = 1, 2, \dots, T$:

ο αλγόριθμος επιλέγει $x_t \in \mathcal{K}$.

το περιβάλλον αποκαλύπτει κυρτή $f_t : \mathcal{K} \rightarrow \mathbb{R}$.

ο αλγόριθμος υφίσταται απώλεια $f_t(x_t)$ και παρατηρεί f_t (ή μέρος της).

Η φράση «ή μέρος της» είναι ουσιώδης και επανέρχεται στο §3.12: η ποσότητα πληροφορίας που επιστρέφεται στον αλγόριθμο μετά από κάθε γύρο ορίζει διαφορετικά προβλήματα με διαφορετικά βέλτιστα φράγματα. Στο πλήρες μοντέλο πληροφόρησης (full information) αποκαλύπτεται ολόκληρη η f_t , άρα και η κλίση της σε κάθε σημείο.

Είναι τα φράγματα σφιχτά; Τα φράγματα που ακολουθούν είναι άνω φράγματα, και ένα άνω φράγμα από μόνο του δεν λέει αν ένας αλγόριθμος είναι καλός ή αν απλώς η ανάλυσή του είναι χαλαρή. Για το πρόβλημα των experts η απάντηση είναι γνωστή και αρνητική για κάθε πιθανή βελτίωση της τάξης μεγέθους.

Θεώρημα 3.1 (Κάτω φράγμα για την πρόβλεψη με ειδικούς). *Για κάθε αλγόριθμο πρόβλεψης με N experts και κάθε T αρκετά μεγάλο υπάρχει ακολουθία απωλειών $\ell_t \in [0, 1]^N$ τέτοια ώστε*

$$\text{Regret}_T \geq (1 - o(1)) \sqrt{\frac{1}{2} T \ln N}.$$

Σκιαγράφηση. Έστω οι απώλειες $\ell_{t,i}$ ανεξάρτητα και ισοπίθανα 0 ή 1. Τότε για κάθε επιλογή w_t που δεν βλέπει το μέλλον ισχύει $\mathbb{E}\langle w_t, \ell_t \rangle = 1/2$, οπότε η αναμενόμενη συνολική απώλεια του αλγορίθμου είναι $T/2$ ανεξάρτητα από τη στρατηγική του. Η αναμενόμενη απώλεια του καλύτερου expert όμως είναι $\mathbb{E}[\min_i \sum_t \ell_{t,i}] = T/2 - \Theta(\sqrt{T \ln N})$, από το κεντρικό οριακό θεώρημα και την ασυμπτωτική συμπεριφορά του μεγίστου N ανεξάρτητων κανονικών μεταβλητών, το οποίο είναι $\sqrt{2 \ln N}$ τυπικές αποκλίσεις πάνω από τη μέση τιμή. Η διαφορά των δύο δίνει το ζητούμενο, και αφού ισχύει κατά μέσο όρο ως προς την τυχαία ακολουθία, υπάρχει τουλάχιστον μία ακολουθία που το επιτυγχάνει. $\square$

Το φράγμα του Hedge (Θεώρημα 3.6) είναι $M \sqrt{T \ln N/2}$, δηλαδή ταιριάζει με το κάτω φράγμα μέχρι τον παράγοντα M που εκφράζει την κλίμακα των απωλειών. Ο αλγόριθμος είναι επομένως βέλτιστος ως προς την τάξη μεγέθους και δεν υπάρχει περιθώριο βελτίωσης στο χειρότερο δυνατό σενάριο. Αυτό είναι σημαντικό για την ερμηνεία των εμπειρικών αποτελεσμάτων του §7.1: όταν διαπιστώνεται εκεί ότι το θεωρητικά βέλτιστο βήμα είναι κατά δύο τάξεις μεγέθους μικρότερο από το εμπειρικά καλύτερο, αυτό δεν σημαίνει ότι η θεωρία είναι λανθασμένη. Σημαίνει ότι τα δεδομένα δεν είναι το χειρότερο δυνατό σενάριο, και ότι η απόσταση μεταξύ του χειρότερου σεναρίου και της συγκεκριμένης ακολουθίας που έτυχε να έχουμε είναι μεγάλη.

Ο στατικός comparator. Αξίζει να σημειωθεί ένας δεύτερος περιορισμός που θα αποδειχθεί ουσιώδης σε αρκετά σημεία της εργασίας: ο comparator είναι στατικός. Η εγγύηση αφορά τη σύγκριση με το καλύτερο σταθερό διάνυσμα βαρών, το οποίο επιλέγεται εκ των υστέρων αλλά παραμένει ένα και μόνο διάνυσμα για ολόκληρη την περίοδο. Όταν το ίδιο το αντικείμενο μεταβάλλεται — όταν, για παράδειγμα, ένας expert παύει να συμμετέχει — ένας αλγόριθμος που συγκλίνει γρήγορα σε μία απάντηση τιμωρείται ακριβώς γι' αυτό. Η γενίκευση που αίρει τον περιορισμό ορίζεται ως εξής.

Ορισμός 3.2 (Δυναμικό regret και regret παρακολούθησης). Για ακολουθία συγκρίσεως $u_1, \dots, u_T \in \mathcal{K}$ ορίζεται το *δυναμικό regret*

$$\text{Regret}_T^d(u_{1:T}) = \sum_{t=1}^T f_t(x_t) - \sum_{t=1}^T f_t(u_t).$$

Όταν η ακολουθία περιορίζεται σε όσες αλλάζουν τιμή το πολύ m φορές, δηλαδή $|\{t : u_{t+1} \neq u_t\}| \leq m$, το μέγεθος ονομάζεται *regret παρακολούθησης* (tracking regret) τάξεως m .

Το στατικό regret είναι η ειδική περίπτωση $m = 0$. Χωρίς περιορισμό στο m κανένα μη τετριμμένο φράγμα δεν είναι δυνατό: με u_t ελεύθερο να είναι κάθε φορά ο εκ των υστέρων καλύτερος expert, το δυναμικό regret μπορεί να αυξάνεται γραμμικά. Ο Fixed-Share του §3.10 είναι ακριβώς ο αλγόριθμος που ανταλλάσσει χειρότερη σταθερά στο στατικό regret με μη τετριμμένο φράγμα για $m > 0$.

3.2 Πρόβλεψη με συμβουλή ειδικών

Στην ειδική περίπτωση που μας ενδιαφέρει, το $\mathcal{K}$ είναι το πιθανοτικό simplex

$$\Delta_N = \left\{ w \in \mathbb{R}^N : w_i \geq 0, \sum_{i=1}^N w_i = 1 \right\},$$

όπου N το πλήθος των experts. Στον γύρο t κάθε expert i δημοσιεύει πρόβλεψη $p_{t,i} \in \Delta_3$ πάνω στα τρία ενδεχόμενα, ο αλγόριθμος επιλέγει βάρη $w_t \in \Delta_N$, και προβλέπει το μείγμα

$$\hat{p}_t = \sum_{i=1}^N w_{t,i} p_{t,i}.$$

Αποκαλύπτεται το αποτέλεσμα $y_t \in \{H, D, A\}$ και ο αλγόριθμος υφίσταται τη λογαριθμική απώλεια $\ell(\hat{p}_t, y_t) = -\log \hat{p}_t[y_t]$.

Η λογαριθμική απώλεια είναι *αυστηρά κατάλληλος κανόνας βαθμολόγησης* (strictly proper scoring rule): η αναμενόμενη τιμή της ελαχιστοποιείται μοναδικά όταν ο προγνώστης αναφέρει τις πραγματικές του πιθανότητες. Αυτό την καθιστά κατάλληλη εδώ, σε αντίθεση με την ακρίβεια (accuracy), η οποία δεν είναι κατάλληλος κανόνας και αγνοεί εντελώς το πόσο βέβαιη ήταν μια πρόβλεψη.

Θεώρημα 3.2 (Καταλληλότητα της λογαριθμικής απώλειας). Έστω p η πραγματική κατανομή του αποτελέσματος και q η αναφερόμενη. Τότε

$$\mathbb{E}_{y \sim p} [-\log q_y] = H(p) + \text{KL}(p \| q) \geq H(p),$$

με ισότητα αν και μόνο αν $q = p$.

Απόδειξη. $\mathbb{E}_{y \sim p} [-\log q_y] = -\sum_k p_k \log q_k = -\sum_k p_k \log p_k + \sum_k p_k \log \frac{p_k}{q_k} = H(p) + \text{KL}(p \| q)$. Η απόκλιση Kullback–Leibler είναι μη αρνητική και μηδενίζεται μόνο όταν $q = p$, από την ανισότητα του Jensen. $\square$

Το πόρισμα είναι ότι ένας προγνώστης δεν έχει κανένα κίνητρο να δηλώσει πιθανότητες διαφορετικές από αυτές που πραγματικά πιστεύει. Η ιδιότητα αυτή δεν ισχύει για την ακρίβεια: ένας προγνώστης που ενδιαφέρεται μόνο για το ποσοστό σωστών επιλογών μπορεί να αναφέρει βεβαιότητα 100% σε κάθε αγώνα χωρίς καμία ποινή, εφόσον διατηρεί την ίδια σειρά προτίμησης.

Γραμμική έναντι λογαριθμικής συνάθροισης

Ο ορισμός $\hat{p}_t = \sum_i w_{t,i} p_{t,i}$ είναι μια επιλογή, όχι η μόνη δυνατή. Ονομάζεται *γραμμική συνάθροιση* (linear pooling) και είναι η φυσική επιλογή εδώ, γιατί είναι αυτή που καθιστά το πρόβλημα κυρτό ως προς w και επομένως επιλύσιμο με τα εργαλεία της online κυρτής βελτιστοποίησης. Η εναλλακτική είναι η *λογαριθμική συνάθροιση* (logarithmic pooling), ο κανονικοποιημένος γεωμετρικός μέσος

$$\hat{p}_k^{\log} \propto \prod_{i=1}^N p_{t,i}[k]^{w_{t,i}}.$$

Οι δύο έχουν ποιοτικά διαφορετική συμπεριφορά, και η διαφορά τους προβλέπει ένα από τα εμπειρικά ευρήματα της εργασίας.

Πρόταση 3.3 (Η γραμμική συνάθροιση είναι υπο-βέβαιη). Έστω $\hat{p} = \sum_i w_i p_i$ με $w \in \Delta_N$. Τότε:

- (α') $\max_k \hat{p}_k \leq \max_i \max_k p_{i,k}$, με ισότητα μόνο αν όλοι οι experts με $w_i > 0$ μεγιστοποιούν στο ίδιο k με την ίδια τιμή.
- (β') $H(\hat{p}) \geq \sum_i w_i H(p_i)$, όπου H η εντροπία Shannon, με ισότητα αν και μόνο αν όλοι οι experts με $w_i > 0$ συμφωνούν απόλυτα.

Απόδειξη. Για το (α), $\hat{p}_k = \sum_i w_i p_{i,k} \leq \max_i p_{i,k} \leq \max_i \max_j p_{i,j}$ για κάθε k , και το αριστερό μέλος μεγιστοποιείται ως προς k . Για το (β), η εντροπία είναι αυστηρά κοίλη συνάρτηση της κατανομής, οπότε από την ανισότητα του Jensen $H(\sum_i w_i p_i) \geq \sum_i w_i H(p_i)$, με ισότητα μόνο στο εκφυλισμένο σημείο όπου όλα τα p_i με $w_i > 0$ ταυτίζονται. $\square$

Με λόγια: το μείγμα είναι πάντοτε λιγότερο βέβαιο από τον μέσο όρο της βεβαιότητας των μελών του, και η απώλεια βεβαιότητας είναι ακριβώς τόση όση και η διαφωνία τους. Αυτό δεν είναι ελάττωμα της υλοποίησης αλλά ιδιότητα του τελεστή: η γραμμική συνάθροιση συστηματικά σπρώχνει τις πιθανότητες προς το κέντρο του simplex. Η λογαριθμική συνάθροιση δεν έχει την ιδιότητα αυτή — μπορεί να παράγει κατανομή οξύτερη από κάθε μέλος της, εφόσον τα μέλη συμφωνούν — και για τον λόγο αυτό λέγεται ότι είναι *εξωτερικά μπεϋζιανή*.

Η συνέπεια είναι προβλέψιμη εκ των προτέρων και επιβεβαιώνεται εμπειρικά: στρατοποιώντας τις προβλέψεις σε δέκα ζώνες πιθανότητας, ένας μεμονωμένος bookmaker είναι καλύτερα βαθμονομημένος από το μείγμα και στις δέκα, ακόμη και όταν το μείγμα έχει χαμηλότερο συνολικό log-loss από αυτόν. Δεν πρόκειται για αντίφαση. Το log-loss αναλύεται (§3.13) σε έναν όρο διακριτικής ικανότητας και έναν όρο αξιοπιστίας· η συνάθροιση βελτιώνει τον πρώτο και επιδεινώνει τον δεύτερο. Αυτή είναι και η καθαρότερη δικαιολόγηση του σταδίου βαθμονόμησης που ακολουθεί: δεν προστίθεται ως εκ των υστέρων διόρθωση, αλλά ως αναίρεση μιας παραμόρφωσης που ο ίδιος ο τελεστής συνάθροισης εισάγει κατ' ανάγκην.

3.3 Από αποδόσεις σε πιθανότητες: de-vig

Πριν από οποιονδήποτε αλγόριθμο υπάρχει ένα βήμα μοντελοποίησης που δεν είναι ουδέτερο. Οι δημοσιευμένες αποδόσεις δεν είναι πιθανότητες: τα αντίστροφα τους αθροίζουν σε περισσότερο από ένα. Αν o_i η δεκαδική απόδοση του ενδεχομένου i και $\pi_i = 1/o_i$,

τότε

$$B = \sum_i \pi_i > 1,$$

και η περίσσεια $B - 1$ είναι το *overround*, το περιθώριο κέρδους του bookmaker. Η μετατροπή των π_i σε πιθανότητες απαιτεί υπόθεση για το πώς κατανέμεται αυτό το περιθώριο στα τρία ενδεχόμενα.

Αναλογική κανονικοποίηση. Η απλούστερη επιλογή υποθέτει ότι το περιθώριο κατανέμεται αναλογικά:

$$p_i = \frac{\pi_i}{B}.$$

Είναι διαφανής και αμερόληπτη ως προς τα ενδεχόμενα, αλλά ενσωματώνει μια ισχυρή σιωπηρή υπόθεση: ότι ο bookmaker χρεώνει το ίδιο ποσοστιαίο περιθώριο σε ένα φαβορί και σε ένα outsider. Η εμπειρική βιβλιογραφία δεν το επιβεβαιώνει. Το γνωστό *favorite-longshot bias* — η συστηματική υπερτίμηση των απίθανων ενδεχομένων στις δημοσιευμένες αποδόσεις — σημαίνει ακριβώς ότι το περιθώριο είναι βαρύτερο στα outsiders.

Η μέθοδος του Shin. Ο Shin (1992, 1993) παράγει την κατανομή του περιθωρίου από μικροοικονομικό επιχείρημα αντί να την υποθέσει. Το μοντέλο θεωρεί ότι ένα ποσοστό z των στοιχηματιστών διαθέτει προνομιακή πληροφορία και ποντάρει με βεβαιότητα στο πραγματικό αποτέλεσμα, ενώ το υπόλοιπο $1 - z$ ποντάρει σύμφωνα με τις δημόσιες πιθανότητες. Ο bookmaker, γνωρίζοντας ότι υπάρχουν τέτοιοι στοιχηματιστές αλλά όχι ποιοι είναι, τιμολογεί ώστε να προστατευθεί. Η προστασία αυτή είναι ακριβότερη εκεί όπου η προνομιακή πληροφορία αποδίδει περισσότερο, δηλαδή στα ενδεχόμενα μικρής πιθανότητας — και έτσι το μοντέλο παράγει ενδογενώς το *favorite-longshot bias*.

Αντιστρέφοντας το μοντέλο, οι δίκαιες πιθανότητες δίνονται από

$$p_i(z) = \frac{\sqrt{z^2 + 4(1-z)\pi_i^2/B} - z}{2(1-z)},$$

με το z προσδιορισμένο από την απαίτηση $\sum_i p_i(z) = 1$. Η εξίσωση δεν λύνεται αναλυτικά· στην υλοποίηση το z βρίσκεται ανά αγώνα με διχοτόμηση στο διάστημα $[0, 0.4]$.

Γιατί κρατάμε και τα δύο. Η επιλογή de-vig είναι υπόθεση, όχι δεδομένο, και μπορεί κατ' αρχήν να καθορίσει ένα συμπέρασμα. Για τον λόγο αυτό ολόκληρο το σύνολο δεδομένων κατασκευάζεται δύο φορές, μία με κάθε μέθοδο, και κάθε κεντρικό αποτέλεσμα ελέγχεται και στις δύο. Έχει επιπλέον ενδιαφέρον ότι η εκτιμώμενη παράμετρος z είναι η ίδια μια ποσότητα με ερμηνεία, την οποία αξιοποιούμε αργότερα ως δείκτη άφιξης πληροφορίας.

3.4 Μικροδομή της αγοράς στοιχηματισμού

Το de-vig του §3.3 αντιμετωπίζει το *overround* ως τεχνικό εμπόδιο προς αφαίρεση. Αξίζει όμως να ειπωθεί γιατί υπάρχει, γιατί η απάντηση εξηγεί δύο από τα κεντρικά ευρήματα της εργασίας: τη διαφορά ανοίγματος-κλεισίματος και το γιατί ο ένας συγκεκριμένος οίκος δεν ξεπερνιέται.

Το πρόβλημα του διαμορφωτή τιμών. Ο bookmaker δημοσιεύει τιμές πριν μάθει το αποτέλεσμα και δέχεται στοιχήματα από δύο ειδών αντισυμβαλλομένους: τους *μη πληροφορημένους*, που στοιχηματίζουν για λόγους άσχετους με την πληροφορία, και τους *πληροφορημένους*, που στοιχηματίζουν μόνο όταν η τιμή είναι λάθος προς όφελός τους. Η δεύτερη κατηγορία δημιουργεί *δυσμενή επιλογή* (adverse selection): το γεγονός και μόνο ότι κάποιος δέχεται την τιμή σου είναι κακή είδηση για την τιμή σου.

Τα υποδείγματα των Glosten & Milgrom (1985) και Kyle (1985) δείχνουν ότι η ορθολογική απόκριση δεν είναι η άρνηση συναλλαγής αλλά η τιμολόγηση με *περιθώριο*: ο διαμορφωτής χρεώνει αρκετά ώστε τα κέρδη από τους μη πληροφορημένους να καλύπτουν τις ζημιές από τους πληροφορημένους. Το overround είναι ακριβώς αυτό το περιθώριο, και το μέγεθός του είναι αύξουσα συνάρτηση της εκτιμώμενης αναλογίας πληροφορημένων. Στο υπόδειγμα του Kyle η τιμή κινείται γραμμικά με τη ροή εντολών, με συντελεστή λ που μετρά το *βάθος* της αγοράς· κάθε συναλλαγή αποκαλύπτει μέρος της ιδιωτικής πληροφορίας και η τιμή συγκλίνει προς τη θεμελιώδη αξία καθώς πλησιάζει η λήξη.

Παρατήρηση 3.4 (Γιατί η τιμή κλεισίματος είναι καλύτερη πρόβλεψη). Η συνέπεια είναι άμεση και ελέγξιμη: αν η κίνηση της τιμής είναι ο μηχανισμός με τον οποίο η ιδιωτική πληροφορία γίνεται δημόσια, τότε η τιμή κλεισίματος ενσωματώνει ό,τι έμαθε η αγορά μεταξύ ανοίγματος και έναρξης, και πρέπει να είναι συστηματικά ακριβέστερη. Ισχυρότερα: το πλεονέκτημά της πρέπει να είναι *μεγαλύτερο εκεί όπου η τιμή κινήθηκε περισσότερο*, αφού εκεί ακριβώς έφτασε περισσότερη πληροφορία. Αυτή είναι ποσοτική πρόβλεψη και όχι απλή ποιοτική προσδοκία, και ελέγχεται στο §7.4.

Η σύνδεση με τον Shin. Το υπόδειγμα του Shin, που το §3.3 χρησιμοποιεί ως μέθοδο devig, είναι η ίδια ιδέα σε μορφή από την οποία μπορεί κανείς να αντιστρέψει: η παράμετρος z είναι η εκτιμώμενη αναλογία πληροφορημένων, και το favorite–longshot bias προκύπτει ενδογενώς επειδή η προστασία κοστίζει περισσότερο εκεί όπου η ιδιωτική πληροφορία αποδίδει περισσότερο, δηλαδή στα απίθανα ενδεχόμενα. Το z είναι επομένως δύο πράγματα ταυτόχρονα: παράμετρος όχλησης για τη μετατροπή αποδόσεων σε πιθανότητες, και *μετρήσιμο μέγεθος με οικονομική ερμηνεία*.

Δύο πράγματα που το πλαίσιο δεν επιτρέπει να ειπωθούν. Πρώτον, οι αποδόσεις από μόνες τους δεν διακρίνουν *προνομιακή από δημόσια* πληροφορία: μια μεγάλη κίνηση μπορεί να οφείλεται σε διαρροή ενδεκάδας ή σε ανακοινωμένο τραυματισμό. Ο ισχυρισμός αφορά την *άφιξη* πληροφορίας, όχι τη φύση της, και κάθε διατύπωση περί «ανίχνευσης insider» θα ήταν υπερβολή. Δεύτερον, το υπόδειγμα εξηγεί γιατί υπάρχει περιθώριο αλλά δεν προβλέπει το *ύψος* του για συγκεκριμένη εταιρεία· αυτό εξαρτάται από εμπορική στρατηγική, κόστος κεφαλαίου και ανοχή στο ρίσκο, δηλαδή από παράγοντες έξω από τα δεδομένα μας (§8.3).

3.5 Hedge

Ο αλγόριθμος Hedge, ή πολλαπλασιαστικών βαρών, διατηρεί ένα βάρος ανά expert και το μειώνει εκθετικά ανάλογα με την απώλειά του:

$$w_{t+1,i} \propto w_{t,i} e^{-\eta_t \ell_{t,i}}, \quad \ell_{t,i} = -\log p_{t,i}[y_t].$$

Με κατάλληλο η_t επιτυγχάνει $\text{regret } O(\sqrt{T \log N})$. Η εξάρτηση από το N είναι μόνο λογαριθμική, γεγονός που επιτρέπει μεγάλα σύνολα experts.

Λήμμα 3.5 (Hoeffding). Έστω τυχαία μεταβλητή X με τιμές σε διάστημα πλάτους M . Τότε για κάθε $\lambda \in \mathbb{R}$

$$\ln \mathbb{E}[e^{\lambda X}] \leq \lambda \mathbb{E}[X] + \frac{\lambda^2 M^2}{8}.$$

Σκιαγράφηση. Έστω $\psi(\lambda) = \ln \mathbb{E}[e^{\lambda X}]$ η αθροιστική γεννήτρια ροπών. Ισχύει $\psi(0) = 0$ και $\psi'(0) = \mathbb{E}[X]$, ενώ $\psi''(\lambda)$ ισούται με τη διασπορά του X κάτω από την εκθετικά στρεβλωμένη κατανομή $d\mathbb{P}_\lambda \propto e^{\lambda X} d\mathbb{P}$. Μια τυχαία μεταβλητή με τιμές σε διάστημα πλάτους M έχει διασπορά το πολύ $M^2/4$ (μεγιστοποιείται από την κατανομή που τοποθετεί μάζα $1/2$ σε κάθε άκρο), άρα $\psi'' \leq M^2/4$ παντού. Το ανάπτυγμα Taylor με υπόλοιπο Lagrange δίνει το ζητούμενο. $\square$

Θεώρημα 3.6 (Φράγμα regret του Hedge). Με σταθερό $\eta > 0$ και απώλειες $\ell_{t,i} \in [0, M]$, ο Hedge ικανοποιεί

$$\sum_{t=1}^T \langle w_t, \ell_t \rangle - \min_i \sum_{t=1}^T \ell_{t,i} \leq \frac{\ln N}{\eta} + \frac{\eta M^2 T}{8}.$$

Με $\eta = \sqrt{8 \ln N / (M^2 T)}$ το φράγμα γίνεται $M \sqrt{T \ln N / 2}$.

Απόδειξη. Έστω $W_t = \sum_i w_{t,i}$ το άθροισμα των μη κανονικοποιημένων βαρών, με $W_1 = N$ αν ξεκινήσουμε από $w_{1,i} = 1$. Για το κάτω φράγμα, κρατώντας μόνο τον καλύτερο expert i^* ,

$$\ln \frac{W_{T+1}}{W_1} \geq \ln \frac{w_{T+1,i^*}}{N} = -\eta \sum_t \ell_{t,i^*} - \ln N.$$

Για το άνω φράγμα, ανά γύρο,

$$\ln \frac{W_{t+1}}{W_t} = \ln \sum_i \frac{w_{t,i}}{W_t} e^{-\eta \ell_{t,i}} = \ln \mathbb{E}_{i \sim w_t} [e^{-\eta \ell_{t,i}}].$$

Εφαρμόζοντας το Λήμμα 3.5 με $\lambda = -\eta$ στην τυχαία μεταβλητή $\ell_{t,i}$, $i \sim w_t$, η οποία παίρνει τιμές στο $[0, M]$,

$$\ln \frac{W_{t+1}}{W_t} \leq -\eta \langle w_t, \ell_t \rangle + \frac{\eta^2 M^2}{8}.$$

Αθροίζοντας ως προς t και συνδυάζοντας με το κάτω φράγμα προκύπτει το ζητούμενο. Η βελτιστοποίηση ως προς η δίνει την τελική μορφή. $\square$

Σημειώνεται ότι το βέλτιστο η εξαρτάται από τον ορίζοντα T , ο οποίος σε online πλαίσιο δεν είναι γνωστός εκ των προτέρων. Υπάρχουν δύο καθιερωμένες λύσεις. Η πρώτη είναι το *κόλπο του διπλασιασμού* (doubling trick): ο αλγόριθμος τρέχει με σταθερό η συντονισμένο για ορίζοντα 2^j , και κάθε φορά που ο χρόνος υπερβεί το 2^j επανεκκινείται με $j+1$. Το συνολικό regret είναι τότε το άθροισμα γεωμετρικής σειράς, δηλαδή της ίδιας τάξης με πολλαπλασιαστική επιβάρυνση $(\sqrt{2} - 1)^{-1} \approx 3,41$. Η δεύτερη, που χρησιμοποιείται εδώ, είναι το φθίνον χρονοδιάγραμμα $\eta_t \propto 1/\sqrt{t}$, το οποίο επιτυγχάνει την ίδια τάξη μεγέθους χωρίς επανεκκινήσεις.

Πρόταση 3.7 (Φθίνον χρονοδιάγραμμα). Με $\eta_t = c/\sqrt{t}$ ο δεύτερος όρος του φράγματος γίνεται $\frac{cM^2}{8} \sum_{t=1}^T t^{-1/2} \leq \frac{cM^2}{4} \sqrt{T}$, ενώ ο πρώτος $\frac{\ln N}{c} \sqrt{T}$. Το συνολικό φράγμα παραμένει $O(M\sqrt{T \ln N})$ για κάθε T ταυτόχρονα, χωρίς ο ορίζοντας να είναι γνωστός.

Απόδειξη. Από $\sum_{t=1}^T t^{-1/2} \leq \int_0^T u^{-1/2} du = 2\sqrt{T}$. Η τηλεσκοπική δομή της απόδειξης του Θεωρήματος 3.6 επιβιώνει όταν το η μεταβάλλεται, αρκεί να είναι φθίνον, γιατί τότε ο όρος $\ln N / \eta_t$ αυξάνεται μονότονα και φράσσεται από την τιμή του στο $t = T$. $\square$

Η επιλογή αυτή έχει συνέπειες που εξετάζονται εμπειρικά στο §7.1, όπου διαπιστώνεται ότι η σταθερά c την οποία υπαγορεύει η θεωρία είναι για τα δεδομένα αυτά σοβαρά λανθασμένη — προς τα πάνω για τον Hedge, προς τα κάτω κατά δύο τάξεις μεγέθους για τον OGD.

Παρατήρηση 3.8 (Η δομή του η και η κατεύθυνση του συντονισμού). Ο λόγος για τον οποίο ο Hedge και ο OGD αντιδρούν *αντίθετα* στην κλιμάκωση του βήματος είναι δομικός και φαίνεται από τους τύπους. Στον Hedge το η βρίσκεται σε *εκθέτη* πάνω στην απώλεια ενός γύρου: μικρότερο η σημαίνει βραδύτερη εκθετική απόσβεση, άρα *μακρύτερη μνήμη*. Στον OGD το η *πολλαπλασιάζει* την κλίση ενός γύρου: μεγαλύτερο η σημαίνει απλώς μεγαλύτερο βήμα προς την ίδια κατεύθυνση. Οι δύο παράμετροι, παρότι φέρουν το ίδιο όνομα, δεν ελέγχουν το ίδιο μέγεθος.

3.6 Online Gradient Descent

Ο OGD (Zinkevich, 2003) κάνει ένα βήμα κατά την αντίθετη κατεύθυνση της κλίσης και προβάλλει πίσω στο εφικτό σύνολο:

$$w_{t+1} = \Pi_{\Delta_N}(w_t - \eta_t \nabla f_t(w_t)),$$

όπου Π_{Δ_N} η ευκλείδεια προβολή στο simplex, υπολογιζόμενη σε $O(N \log N)$ (Duchi κ.ά., 2008). Για κυρτές συναρτήσεις με φραγμένη κλίση το regret είναι $O(\sqrt{T})$.

Δύο συστατικά του σχήματος αυτού χρησιμοποιούνται σε όλη την εργασία και αξίζουν ρητή δικαιολόγηση: η γραμμικοποίηση της απώλειας και ο υπολογισμός της προβολής.

Γιατί επιτρέπεται η γραμμικοποίηση. Στην υλοποίηση δεν χρησιμοποιείται η κλίση της πραγματικής απώλειας $-\log\langle w, p_t \rangle$ αλλά το διάνυσμα των ανά-expert απωλειών ℓ_t , δηλαδή η κλίση της γραμμικής συνάρτησης $\tilde{f}_t(w) = \langle w, \ell_t \rangle$. Η αντικατάσταση αυτή δεν είναι προσέγγιση που πρέπει να ελεγχθεί εκ των υστέρων· είναι ασφαλής εξ ορισμού για κάθε κυρτή απώλεια.

Λήμμα 3.9 (Η γραμμικοποίηση δεν χαλαρώνει το φράγμα). Έστω f_t κυρτή και $g_t \in \partial f_t(x_t)$ οποιοδήποτε υποδιαφορικό στο παιγμένο σημείο. Τότε για κάθε $u \in \mathcal{K}$

$$\sum_{t=1}^T f_t(x_t) - \sum_{t=1}^T f_t(u) \leq \sum_{t=1}^T \langle g_t, x_t - u \rangle,$$

δηλαδή το regret ως προς τις πραγματικές απώλειες φράσσεται από το regret ως προς τις γραμμικοποιήσεις τους. Κάθε φράγμα που αποδεικνύεται για γραμμικές απώλειες ισχύει επομένως αυτόματα και για τις αρχικές κυρτές.

Απόδειξη. Από τον ορισμό της κυρτότητας μέσω υποδιαφορικού, $f_t(u) \geq f_t(x_t) + \langle g_t, u - x_t \rangle$ για κάθε u . Αναδιατάσσοντας, $f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle$. άθροιση ως προς t . $\square$

Η κατεύθυνση της ανισότητας είναι αυτή που χρειαζόμαστε: το γραμμικό πρόβλημα είναι *δυσκολότερο*, οπότε το να λυθεί καλά συνεπάγεται ότι λύθηκε καλά και το αρχικό. Το τίμημα είναι ότι η γραμμικοποίηση πετά την καμπυλότητα, και μαζί της την ευκαιρία για το πολύ ισχυρότερο φράγμα $O(\log T)$ που επιτρέπει η $\exp$ -concavity της λογαριθμικής απώλειας (§3.8). Αυτό είναι συνειδητή ανταλλαγή και όχι παράλειψη: το §7.1 δείχνει ότι ο αλγόριθμος που εκμεταλλεύεται την καμπυλότητα αποδίδει στα δεδομένα αυτά χειρότερα, για λόγους που δεν αφορούν την ποιότητα του φράγματος αλλά τον στατικό comparator στον οποίο αναφέρεται.

Η προβολή στο simplex. Η προβολή είναι η μόνη μη τετριμμένη πράξη του βήματος και εκτελείται δεκάδες χιλιάδες φορές, οπότε η κλειστή της μορφή έχει σημασία.

Θεώρημα 3.10 (Ευκλείδεια προβολή στο simplex). Έστω $v \in \mathbb{R}^n$ και $\Pi_{\Delta_n}(v) = \arg \min_{w \in \Delta_n} \|w - v\|_2^2$. Τότε

$$\Pi_{\Delta_n}(v)_i = \max\{v_i - \theta, 0\},$$

όπου το θ είναι ο μοναδικός αριθμός που ικανοποιεί $\sum_i \max\{v_i - \theta, 0\} = 1$. Αν u είναι το v ταξινομημένο φθίνουσα και $\rho = \max\{j : u_j - \frac{1}{j}(\sum_{r \leq j} u_r - 1) > 0\}$, τότε $\theta = \frac{1}{\rho}(\sum_{r \leq \rho} u_r - 1)$.

Απόδειξη. Το πρόβλημα είναι αυστηρά κυρτό με γραμμικούς περιορισμούς, άρα έχει μοναδική λύση που χαρακτηρίζεται πλήρως από τις συνθήκες KKT. Η Lagrangian είναι $\mathcal{L}(w, \theta, \mu) = \frac{1}{2}\|w - v\|^2 + \theta(\sum_i w_i - 1) - \sum_i \mu_i w_i$ με $\mu_i \geq 0$. Η συνθήκη στασιμότητας δίνει $w_i = v_i - \theta + \mu_i$, και η συμπληρωματική χαλαρότητα $\mu_i w_i = 0$ επιβάλλει: όπου $w_i > 0$ είναι $\mu_i = 0$, άρα $w_i = v_i - \theta$. όπου $w_i = 0$ είναι $\mu_i \geq 0$, άρα $v_i - \theta \leq 0$. Οι δύο περιπτώσεις συνοψίζονται στο $w_i = \max\{v_i - \theta, 0\}$. Η συνάρτηση $\theta \mapsto \sum_i \max\{v_i - \theta, 0\}$ είναι συνεχής, φθίνουσα και γνησίως φθίνουσα όπου είναι θετική, οπότε το θ με άθροισμα 1 είναι μοναδικό. Επειδή το σύνολο των μη μηδενικών συντεταγμένων είναι πάντοτε ένα άνω σύνολο της φθίνουσας διάταξης, αρκεί να βρεθεί το πλήθος τους ρ , το οποίο δίνεται από την παραπάνω συνθήκη. Το κόστος κυριαρχείται από την ταξινόμηση, δηλαδή $O(n \log n)$. $\square$

Παρατήρηση 3.11 (Η προβολή δεν είναι παθητική). Η προβολή δεν είναι απλώς μηχανισμός εφικτότητας. Επειδή μηδενίζει κάθε συντεταγμένη κάτω από το κατώφλι θ , είναι *αραιοποιητική*: επιβάλλει ακριβώς μηδενικό βάρος σε experts, όχι απλώς μικρό. Στην αναγωγή Sleeping Experts του §3.9 εφαρμόζεται εκ νέου κάθε φορά που αλλάζει το σύνολο των ξύπνιων, και η εμπειρική διερεύνηση του §7.8 δείχνει ότι η κίνηση των βαρών στα τελευταία στάδια της περιόδου οφείλεται κυρίως σε αυτήν και όχι στο βήμα της κλίσης — εύρημα που ανατρέπει τη διαισθητική προσδοκία ότι ένα φθίνον η_t «παγώνει» τον αλγόριθμο.

Θεώρημα 3.12 (Φράγμα regret του OGD). Έστω $\mathcal{K}$ κυρτό με διάμετρο $D = \max_{u,v \in \mathcal{K}} \|u - v\|$ και κλίσεις φραγμένες, $\|g_t\| \leq G$. Με σταθερό η ,

$$\text{Regret}_T \leq \frac{D^2}{2\eta} + \frac{\eta G^2 T}{2},$$

και με $\eta = D/(G\sqrt{T})$ προκύπτει $\text{Regret}_T \leq DG\sqrt{T}$.

Απόδειξη. Έστω $u \in \mathcal{K}$ αυθαίρετο σημείο σύγκρισης. Επειδή η προβολή σε κυρτό σύνολο δεν αυξάνει αποστάσεις,

$$\|w_{t+1} - u\|^2 \leq \|w_t - \eta g_t - u\|^2 = \|w_t - u\|^2 - 2\eta \langle g_t, w_t - u \rangle + \eta^2 \|g_t\|^2.$$

Αναδιατάσσοντας,

$$\langle g_t, w_t - u \rangle \leq \frac{\|w_t - u\|^2 - \|w_{t+1} - u\|^2}{2\eta} + \frac{\eta \|g_t\|^2}{2}.$$

Από την κυρτότητα, $f_t(w_t) - f_t(u) \leq \langle g_t, w_t - u \rangle$. Αθροίζοντας ως προς t , ο πρώτος όρος τηλεσκοπεί και φράσσεται από $D^2/(2\eta)$, ενώ ο δεύτερος από $\eta G^2 T/2$. $\square$

Στην περίπτωση μας $\mathcal{K} = \Delta_N$, οπότε $D = \sqrt{2}$, και το G φράσσεται από το M του §7.1. Η δομή αυτή — ότι το η πολλαπλασιάζει την κλίση ενός γύρου — εξηγεί γιατί ο OGD αντιδρά στην κλιμάκωση του βήματος αντίθετα από τον FTRL.

3.7 Follow-The-Regularized-Leader

Ο FTRL επιλέγει σε κάθε γύρο το σημείο που ελαχιστοποιεί ολόκληρη τη σωρευμένη απώλεια, συν έναν όρο κανονικοποίησης που εμποδίζει την υπερβολικά απότομη μετακίνηση:

$$w_{t+1} = \arg \min_{w \in \Delta_N} \left\{ \eta_t \sum_{s=1}^t \langle \ell_s, w \rangle + R(w) \right\}.$$

Με $R(w) = \frac{1}{2} \|w - w_0\|^2$ η λύση δίνεται πάλι από προβολή στο simplex. Η διαφορά από τον OGD είναι ότι ο FTRL είναι «τεμπέλης»: ανακατασκευάζει τα βάρη από το σύνολο της ιστορίας κάθε φορά, αντί να βηματίζει από την προηγούμενη θέση.

Γιατί χρειάζεται ο όρος κανονικοποίησης. Η προφανής στρατηγική χωρίς τον όρο R — επέλεξε ό,τι ήταν βέλτιστο μέχρι τώρα, Follow-The-Leader — αποτυγχάνει θεαματικά. Με δύο experts και απώλειες που εναλλάσσονται $(\frac{1}{2}, 0), (0, 1), (1, 0), (0, 1), \dots$, ο FTL επιλέγει κάθε φορά ακριβώς τον expert που πρόκειται να χάσει τον επόμενο γύρο και υφίσταται γραμμικό regret, ενώ ο καλύτερος σταθερός expert χάνει περίπου $T/2$. Ο όρος R είναι αυτό που σταθεροποιεί τις διαδοχικές επιλογές· το παρακάτω λήμμα δείχνει ότι η σταθερότητα είναι ακριβώς το ζητούμενο.

Λήμμα 3.13 (Be-The-Leader). Έστω $w_t^* = \arg \min_w \{ \sum_{s=1}^t \langle \ell_s, w \rangle + R(w)/\eta \}$ η επιλογή του FTRL. Αν ο αλγόριθμος επιτρεπόταν να παίζει το w_t^* αφού δει το ℓ_t , θα ίσχυε για κάθε u

$$\sum_{t=1}^T \langle \ell_t, w_t^* \rangle \leq \sum_{t=1}^T \langle \ell_t, u \rangle + \frac{R(u) - R(w_0^*)}{\eta}.$$

Απόδειξη. Επαγωγή στο T . Για $T = 0$ ισχύει τετριμμένα. Έστω ότι ισχύει για $T - 1$ με αυθαίρετο u . εφαρμόζοντάς το για $u = w_T^*$ και προσθέτοντας $\langle \ell_T, w_T^* \rangle$ και στα δύο μέλη προκύπτει $\sum_{t \leq T} \langle \ell_t, w_t^* \rangle \leq \sum_{t \leq T} \langle \ell_t, w_T^* \rangle + (R(w_T^*) - R(w_0^*))/\eta$. Το δεξί μέλος όμως είναι, από τον ορισμό του w_T^* ως ελαχιστοποιητή, μικρότερο ή ίσο της αντίστοιχης ποσότητας για κάθε u . $\square$

Θεώρημα 3.14 (Φράγμα regret του FTRL). Με R ισχυρά κυρτή ως προς $\|\cdot\|_2$ με σταθερά 1, απώλειες με $\|\ell_t\| \leq G$ και R φραγμένη στο $\mathcal{K}$ από $D_R = \max_u R(u) - \min_u R(u)$, ο FTRL ικανοποιεί

$$\text{Regret}_T \leq \frac{D_R}{\eta} + \eta G^2 T,$$

και με $\eta = \sqrt{D_R/(G^2 T)}$ προκύπτει $\text{Regret}_T \leq 2G\sqrt{D_R T}$.

Απόδειξη. Από το Λήμμα 3.13 αρκεί να φραχθεί η διαφορά μεταξύ του τι παίζει ο αλγόριθμος και του τι θα έπαιζε αν έβλεπε πρώτα το ℓ_t , δηλαδή το άθροισμα $\sum_t \langle \ell_t, w_{t-1}^* - w_t^* \rangle$, το οποίο από την ανισότητα Cauchy–Schwarz φράσσεται από $G \sum_t \|w_{t-1}^* - w_t^*\|$. Η ισχυρή κυρτότητα της R κάνει τον ελαχιστοποιητή σταθερό: η προσθήκη ενός γραμμικού όρου με νόρμα ηG στη συνάρτηση στόχου μετακινεί το ελάχιστο κατά το πολύ ηG , οπότε $\|w_{t-1}^* - w_t^*\| \leq \eta G$. Συνολικά ο όρος αυτός είναι το πολύ $\eta G^2 T$, και προστίθεται στον όρο D_R/η του λήμματος. $\square$

Παρατήρηση 3.15 (OGD και FTRL ως «άπληστη» και «τεμπέλης» προβολή). Οι δύο αλγόριθμοι δεν είναι άσχετοι: με τετραγωνικό R ο FTRL γράφεται ως $w_{t+1} = \Pi_{\mathcal{K}}(w_0 - \eta \sum_{s \leq t} \ell_s)$, δηλαδή προβολή του συσσωρευμένου αθροίσματος, ενώ ο OGD είναι $w_{t+1} = \Pi_{\mathcal{K}}(w_t - \eta \ell_t)$, προβολή μετά από κάθε βήμα. Η διαφορά είναι πού παρεμβάλλεται η προβολή: ο FTRL κρατά το απροβόλιστο άθροισμα και προβάλλει στο τέλος («τεμπέλης»), ο OGD προβάλλει και συνεχίζει από το προβεβλημένο σημείο («άπληστος»). Χωρίς περιορισμούς οι δύο ταυτίζονται· με περιορισμούς αποκλίνουν, και ακριβώς αυτή η απόκλιση εξηγεί γιατί αντιδρούν αντίθετα στην κλιμάκωση του βήματος: στον FTRL το η πολλαπλασιάζει ολόκληρη τη σωρευμένη ιστορία, οπότε η αύξησή του οδηγεί τον αλγόριθμο προς τον ασταθή Follow-The-Leader, ενώ στον OGD πολλαπλασιάζει την κλίση ενός μόνο γύρου.

3.8 Exp-concavity και ο Aggregating Algorithm

Τα παραπάνω φράγματα είναι της τάξης $O(\sqrt{T})$ και ισχύουν για κάθε κυρτή απώλεια. Για ορισμένες απώλειες μπορεί να επιτευχθεί σημαντικά ισχυρότερο αποτέλεσμα.

Ορισμός 3.3 (Exp-concavity). Μια συνάρτηση f λέγεται α -exp-concave αν η $e^{-\alpha f}$ είναι κοίλη.

Η λογαριθμική απώλεια του μείγματος είναι 1-exp-concave: αν $f(w) = -\log \langle w, p \rangle$, τότε $e^{-f(w)} = \langle w, p \rangle$, που είναι γραμμική ως προς w και άρα κοίλη. Πρόκειται για ισχυρότερη ιδιότητα από την κυρτότητα και ασθενέστερη από την ισχυρή κυρτότητα· η σημασία της είναι ότι επιτρέπει φράγμα λογαριθμικό, ή και σταθερό, αντί για $O(\sqrt{T})$.

Ο Aggregating Algorithm. Ο αλγόριθμος του Vovk (1990) δεν είναι παραλλαγή του Hedge αλλά διαφορετική κατασκευή. Διατηρεί βάρη που ενημερώνονται *μπεϋζιανά* με τη συνάρτηση πιθανοφάνειας ως βάρους,

$$w_{t+1,i} \propto w_{t,i} e^{-\ell_{t,i}} = w_{t,i} p_{t,i}[y_t],$$

δηλαδή ακριβώς ο κανόνας του Bayes με ομοιόμορφη εκ των προτέρων κατανομή, και προβλέπει $\hat{p}_t = \sum_i w_{t,i} p_{t,i}$. Για τη λογαριθμική απώλεια το σχήμα αυτό είναι ταυτόσημο με τον Hedge σε $\eta = 1$, που είναι και ο λόγος για τον οποίο η διερεύνηση του §7.1 τον εξετάζει ως την ειδική περίπτωση «σταθερό $\eta = 1$ ».

Θεώρημα 3.16 (Φράγμα του Aggregating Algorithm). Για α -exp-concave απώλεια και N experts, ο Aggregating Algorithm ικανοποιεί

$$\text{Regret}_T \leq \frac{\ln N}{\alpha},$$

δηλαδή φράγμα ανεξάρτητο του ορίζοντα T .

Απόδειξη. Παρουσιάζεται για $\alpha = 1$, που είναι η περίπτωση της λογαριθμικής απώλειας· η γενική προκύπτει με κλιμάκωση. Έστω $W_t = \sum_i w_{t,i}$ με μη κανονικοποιημένα βάρη και $w_{1,i} = 1/N$, οπότε $W_1 = 1$. Η exp-concavity με $\alpha = 1$ σημαίνει ότι η e^{-f} είναι κοίλη, άρα από την ανισότητα του Jensen η απώλεια του μείγματος ικανοποιεί

$$e^{-\ell(\hat{p}_t, y_t)} = \left\langle \frac{w_t}{W_t}, p_t[y_t] \right\rangle = \sum_i \frac{w_{t,i}}{W_t} e^{-\ell_{t,i}} = \frac{W_{t+1}}{W_t},$$

όπου η τελευταία ισότητα είναι απλώς ο ορισμός της ενημέρωσης. Παίρνοντας λογαρίθμους, $\ell(\hat{p}_t, y_t) = -\ln(W_{t+1}/W_t)$, και αθροίζοντας το άθροισμα τηλεσκοπεί:

$$\sum_{t=1}^T \ell(\hat{p}_t, y_t) = -\ln W_{T+1} \leq -\ln w_{T+1,i^*} = \ln N + \sum_{t=1}^T \ell_{t,i^*}$$

για κάθε expert i^* , αφού $W_{T+1} \geq w_{T+1,i^*}$ και $w_{T+1,i^*} = \frac{1}{N} e^{-\sum_{t=1}^T \ell_{t,i^*}}$. □

Για $N = 26$ experts αυτό σημαίνει regret το πολύ $\ln 26 \approx 3,26$ συνολικά, έναντι εκατοντάδων για τα $O(\sqrt{T})$ φράγματα σε $T \approx 76.000$. Σημειώνεται ότι το αποτέλεσμα δεν έρχεται σε αντίφαση με το κάτω φράγμα του Θεωρήματος 3.1: εκείνο αφορά γραμμικές απώλειες, οι οποίες δεν είναι exp-concave, και η διαφορά μεταξύ των δύο περιπτώσεων είναι ακριβώς η καμπυλότητα που η γραμμικοποίηση του Λήμματος 3.9 πετά.

Το αποτέλεσμα αυτό είναι θεωρητικά πολύ ισχυρότερο. Αξίζει επομένως να σημειωθεί ρητά ότι στα δεδομένα μας ο αντίστοιχος αλγόριθμος αποδίδει χειρότερα από την ομοιόμορφη μέση τιμή. Η εξήγηση δεν είναι ότι το φράγμα είναι λάθος αλλά ότι αφορά στατικό comparator: εγγυάται ότι δεν θα τα πάμε πολύ χειρότερα από τον καλύτερο σταθερό expert. Όταν ο καλύτερος expert παύει να συμμετέχει στη μέση της περιόδου, η εγγύηση παραμένει τυπικά αληθής αλλά πρακτικά κενή, και ένας αλγόριθμος που συγκεντρώνει γρήγορα τη μάζα του σε λίγους experts τιμωρείται ακριβώς γι' αυτό.

3.9 Η αναγωγή Sleeping Experts

Οι παραπάνω αλγόριθμοι υποθέτουν ότι κάθε expert συμμετέχει σε κάθε γύρο. Στα δεδομένα μας αυτό δεν ισχύει: πολλοί bookmakers καλύπτουν μικρό μόνο ποσοστό των αγώνων. Χρησιμοποιούμε την κλασική αναγωγή *Sleeping Experts* ή *Specialists* (Freund, Schapire, Singer & Warmuth, 1997· Blum & Mansour, 2007). Έστω $A(t) \subseteq \{1, \dots, N\}$ το σύνολο των «ξύπνιων» experts στον γύρο t . Τότε:

- κάθε expert διατηρεί τη δική του μόνιμη κατάσταση (βάρος για τον Hedge, θέση για τον OGD, σωρευμένη απώλεια για τον FTRL).
- η πρόβλεψη σχηματίζεται μόνο από τους ξύπνιους, με τα βάρη τους κανονικοποιημένα ώστε να αποτελούν κατανομή πάνω στο $A(t)$ και μόνο.

- μετά τον γύρο ενημερώνεται μόνο η κατάσταση των ξύπνιων· οι κοιμισμένοι παραμένουν παγωμένοι ακριβώς ως είχαν·
- γύρος όπου κανείς δεν είναι ξύπνιος παραλείπεται εξ ολοκλήρου.

Η αναγωγή δίνει σε κάθε expert i εγγύηση regret μετρημένη μόνο πάνω στους γύρους όπου ήταν ξύπνιος, αντί να απαιτεί συμμετοχή σε όλους.

Θεώρημα 3.17 (Ανά-expert regret υπό μερική συμμετοχή). Έστω $T_i = \{t : i \in A(t)\}$ οι γύροι όπου ο expert i είναι ξύπνιος και $n_i = |T_i|$. Ο Hedge με την παραπάνω αναγωγή ικανοποιεί, για κάθε i ταυτόχρονα,

$$\sum_{t \in T_i} (\langle \bar{w}_t, \ell_t \rangle - \ell_{t,i}) \leq \frac{\ln N}{\eta} + \frac{\eta M^2 n_i}{8},$$

όπου $\bar{w}_t$ τα κανονικοποιημένα στο $A(t)$ βάρη. Με η συντονισμένο στο n_i το φράγμα γίνεται $M\sqrt{n_i \ln N/2}$.

Σκιαγράφιση. Η απόδειξη του Θεωρήματος 3.6 στηρίζεται αποκλειστικά σε δύο γεγονότα: ότι το $\ln(W_{t+1}/W_t)$ φράσσεται ανά γύρο από το λήμμα του Hoeffding, και ότι το άθροισμα τηλεσκοπεί. Και τα δύο επιβιώνουν εδώ. Επειδή οι κοιμισμένοι δεν ενημερώνονται, το βάρος $w_{t,i}$ παραμένει αναλλοίωτο εκτός του T_i , οπότε το γινόμενο των ανά γύρο παραγόντων για τον expert i περιλαμβάνει μόνο n_i μη τετριμμένους όρους. Το κάτω φράγμα $\ln(w_{T+1,i}/W_1) \geq -\eta \sum_{t \in T_i} \ell_{t,i} - \ln N$ ισχύει αυτούσιο, ενώ το άνω φράγμα ανά γύρο εφαρμόζεται μόνο στους $t \in T_i$: στους υπόλοιπους ο δείκτης i δεν συνεισφέρει τίποτα στη μεταβολή. Το αποτέλεσμα είναι το ίδιο φράγμα με n_i στη θέση του T . $\square$

Η ουσιαστική συνέπεια είναι ότι ένας bookmaker που καλύπτει το 7% των αγώνων δεν «αραιώνει» την εγγύηση των υπολοίπων: κάθε expert κρίνεται στο δικό του πεδίο. Αυτό είναι ακριβώς ό,τι χρειάζεται ένα panel με κάλυψη από 6,9% έως 99,8%.

Παρατήρηση 3.18 (Ένας πειρασμός που το φράγμα δημιουργεί και τα δεδομένα απορρίπτουν). Το Θεώρημα 3.17 έχει n_i όπου το αρχικό είχε T , οπότε προτείνει από μόνο του ότι το βήμα κάθε expert θα έπρεπε να φθίνει ως $1/\sqrt{n_i}$ — με το δικό του ρολόι — και όχι ως $1/\sqrt{t}$ με το καθολικό. Η πρόταση αυτή είναι θεωρητικά ορθή και δοκιμάστηκε· απορρίφθηκε εμπειρικά (§7.12). Ο λόγος είναι διδακτικός: ένας expert με κάλυψη 7% αποκτά βήμα περίπου 14 φορές μεγαλύτερο από έναν με πλήρη κάλυψη στον ίδιο χρόνο, οπότε το μείγμα κυνηγά τους σπάνιους experts. Το φράγμα δεν είναι λάθος — απλώς το μέγεθος που εγγυάται δεν είναι αυτό που μας ενδιαφέρει να ελαχιστοποιήσουμε.

Δύο λεπτομέρειες αποδεικνύονται κρίσιμες στην υλοποίηση. Πρώτον, το μόνιμο διάλυμα βαρών δεν πρέπει ποτέ να κανονικοποιείται καθολικά — μόνο το αντίγραφο που χρησιμοποιείται για την πρόβλεψη. Ο λόγος φαίνεται στην απόδειξη: το κάτω φράγμα στηρίζεται στο ότι το $w_{t,i}$ ενός κοιμισμένου expert μένει κυριολεκτικά αναλλοίωτο, και μια καθολική επανακανονικοποίηση το αλλάζει. Δεύτερον, η τελευταία γραμμή του πίνακα βαρών δεν είναι «το τελικό βάρος κάθε expert», αφού είναι μηδενική για όποιον δεν συμμετείχε στον τελευταίο γύρο· η ερμηνεύσιμη ποσότητα είναι το βάρος που κρατούσε ο καθένας την τελευταία φορά που ήταν ξύπνιος.

3.10 Fixed-Share

Η αναγωγή Sleeping Experts δημιουργεί ένα παράπλευρο πρόβλημα: ένας expert που κοιμάται για μεγάλο διάστημα διατηρεί παγωμένο το βάρος του, το οποίο δεν διαβρώνεται από τις απώλειες των υπολοίπων. Σπάνιοι experts μπορούν έτσι να καταλήξουν με δυσανάλογη επιρροή. Ο αλγόριθμος Fixed-Share (Herbster & Warmuth, 1998) εισάγει μια μικρή διαρροή α προς το ομοιόμορφο μετά από κάθε ενημέρωση:

$$w_{t+1,i} = (1 - \alpha) \tilde{w}_{t,i} + \frac{\alpha}{N} \sum_j \tilde{w}_{t,j}, \quad \tilde{w}_{t,i} = w_{t,i} e^{-\eta \ell_{t,i}},$$

όπου η δεύτερη μορφή διατηρεί τη συνολική μάζα ακριβώς. Θεωρητικά αυτό αλλάζει τον comparator από το καλύτερο σταθερό διάνυσμα στην καλύτερη ακολουθία διανυσμάτων με φραγμένο πλήθος αλλαγών, δηλαδή στο regret παρακολούθησης του Ορισμού 3.2.

Θεώρημα 3.19 (Regret παρακολούθησης του Fixed-Share). Έστω ακολουθία συγκρίσεως που επιλέγει σε κάθε γύρο έναν expert και αλλάζει επιλογή το πολύ m φορές. Ο Fixed-Share με κατάλληλα η και $\alpha = m/(T-1)$ ικανοποιεί

$$\text{Regret}_T^d \leq \frac{1}{\eta} \left[\ln N + m \ln(N-1) + (T-1) \mathcal{H}(\alpha) \right] + \frac{\eta M^2 T}{8},$$

όπου $\mathcal{H}(\alpha) = -\alpha \ln \alpha - (1-\alpha) \ln(1-\alpha)$ η δυαδική εντροπία. Βελτιστοποιώντας, το φράγμα είναι $O\left(M \sqrt{T(m \ln N + m \ln \frac{T}{m})}\right)$.

Σκιαγράφιση. Η ενημέρωση Fixed-Share είναι ακριβώς η μπροστινή αναδρομή ενός κρυφού μαρκοβιανού μοντέλου στο οποίο η «κρυφή κατάσταση» είναι ο τρέχων καλύτερος expert και η πιθανότητα μετάβασης είναι α . Το βάρος $w_{T+1,i}$ ισούται επομένως με το άθροισμα, πάνω σε όλες τις διαδρομές που καταλήγουν στο i , του γινομένου των πιθανοτήτων μετάβασης επί τις πιθανοφάνειες. Κρατώντας μόνο τη διαδρομή που αντιστοιχεί στην ακολουθία συγκρίσεως, η πιθανότητά της είναι $\alpha^m (1-\alpha)^{T-1-m}/N$ επί τον παράγοντα $(N-1)^{-m}$ για την επιλογή του προορισμού κάθε μετάβασης. Ο λογάριθμος αυτής της ποσότητας δίνει τον όρο σε αγκύλες, και το υπόλοιπο της απόδειξης είναι ταυτόσημο με εκείνη του Θεωρήματος 3.6. $\square$

Το φράγμα ποσοτικοποιεί μια ανταλλαγή: για $m=0$ ο όρος $(T-1)\mathcal{H}(\alpha)$ είναι καθαρή επιβάρυνση σε σχέση με τον απλό Hedge, ενώ για $m>0$ είναι το τίμημα που αγοράζει μια εγγύηση την οποία ο Hedge δεν προσφέρει καθόλου. Το εμπειρικό αποτέλεσμα του §7.12 είναι ακριβώς αυτό που η ανταλλαγή προβλέπει όταν η υποκείμενη ακολουθία δεν αλλάζει αρκετά: κάθε $\alpha > 0$ επιδεινώνει το log-loss. Πιο ενδιαφέρον, η βέλτιστη τιμή του α αποδεικνύεται πάντοτε 0 αφού συντονιστεί το βήμα, γιατί τα δύο μεγέθη ελέγχουν την ίδια ποσότητα — πόσο γρήγορα ξεχνά ο αλγόριθμος — και το βήμα είναι το αποδοτικότερο από τα δύο εργαλεία.

3.11 Μαρκοβιανές αλυσίδες: τρεις διαφορετικές χρήσεις

Ο όρος «Markov chain OGD» χρησιμοποιείται στη βιβλιογραφία για τουλάχιστον τρία διαφορετικά πράγματα, και η εργασία δοκιμάζει και τα τρία. Τα διαχωρίζουμε ρητά, γιατί τα αρνητικά αποτελέσματα του ενός δεν λένε τίποτα για τα άλλα.

(α) Αλυσίδα πάνω στο διάνυσμα βαρών. Μετά το βήμα κλίσης και την προβολή, η μάζα μετακινείται από έναν γραμμοστοχαστικό πίνακα M :

$$v_t = \Pi_\Delta(w_t), \quad \hat{w} = v_t - \eta_t \ell_t, \quad w_{t+1} = M^\top \hat{w}.$$

Το Fixed-Share του §3.10 είναι η ειδική περίπτωση $M = (1 - \alpha)I + \frac{\alpha}{N} \mathbf{1}\mathbf{1}^\top$, δηλαδή ομοιόμορφη διαρροή. Ένας γενικός M είναι αυστηρά εκφραστικότερος, επειδή μπορεί να πει πού πηγαίνει η μάζα που χάνεται — π.χ. προς τον opening/closing «δίδυμο» του ίδιου οίκου, ή προς τους ομοίους της ίδιας φάσης της αγοράς. Η γραμμοστοχαστικότητα εγγυάται διατήρηση της συνολικής μάζας, που είναι ακριβώς αυτό που κάνει το $\alpha = 0$ γνήσιο no-op και όχι προσεγγιστικό.

(β) Αλυσίδα πάνω σε λανθάνουσα κατάσταση (κρυφό μαρκοβιανό μοντέλο). Εδώ η κρυφή μεταβλητή δεν είναι τα βάρη αλλά μια κατάσταση $k \in \{1, \dots, K\}$, και κάθε κατάσταση κουβαλά το δικό της διάνυσμα βαρών. Η πεποίθηση b_t πάνω στις καταστάσεις ενημερώνεται με την *μπροστινή αναδρομή*:

$$b_{t+1}(k) \propto b_t(k) L_t(k), \quad L_t(k) = \langle w_t^{(k)}, p_t[y_t] \rangle,$$

ακολουθούμενη από τη μετάβαση $b \leftarrow (1 - \tau)b + \tau/K$. Η πρόβλεψη είναι το μείγμα $\sum_k b_t(k) \langle w_t^{(k)}, p_t \rangle$ και κάθε κατάσταση ενημερώνεται κλιμακωμένα με την *ευθύνη* της $b_t(k)$.

Παρατήρηση 3.20 (Γιατί η συμμετρία είναι παγίδα). Αν όλες οι καταστάσεις ξεκινούν κοινά η μία στην άλλη και λαμβάνουν το *ίδιο* διάνυσμα απωλειών, ακολουθούν ταυτόσημες τροχιές: τότε $L_t(k)$ είναι ίσες για κάθε k , η πεποίθηση μένει ομοιόμορφη, και το σχήμα εκφυλίζεται σε έναν OGD με βήμα διαιρεμένο διά K . Η συμμετρική λύση είναι σταθερό σημείο της δυναμικής. Χρειάζεται ρητός μηχανισμός διαφοροποίησης — όξυνση της πεποίθησης ώστε να αντιδρά σε μικρές ανά γύρο διαφορές, λήθη ώστε να παρακολουθεί το παρόν αντί του αθροίσματος της ιστορίας, και ρολόι ανά κατάσταση ώστε καμία να μην υποβηματίζει. Το §7.11 δείχνει ότι χωρίς αυτά το μοντέλο αποτυγχάνει ακριβώς με αυτόν τον τρόπο.

(γ) Markov Chain Gradient Descent: εξαρτημένη δειγματοληψία. Αυτό μελετούν οι Sun, Sun & Yin (2018), και δεν αφορά καθόλου μετάβαση βαρών. Η κλασική ανάλυση του SGD υποθέτει ανεξάρτητα δείγματα· όταν τα δείγματα είναι διαδοχικά σημεία μιας μαρκοβιανής τροχιάς, μετά από t γύρους ο αλγόριθμος έχει δει *λιγότερη* από t ανεξάρτητη πληροφορία. Αν ο ορίζοντας εξάρτησης είναι τ γύροι, το ενεργό πλήθος δειγμάτων είναι $\sim t/\tau$ και το χρονοδιάγραμμα γίνεται

$$\eta_t = \frac{D}{M\sqrt{t/\tau + 1}} \approx \sqrt{\tau} \eta_t^{\text{iid}},$$

δηλαδή μια εξαρτημένη ακολουθία δικαιολογεί βήμα διογκωμένο κατά $\sqrt{\tau}$.

Παρατήρηση 3.21 (Μια ανεξάρτητη θεωρητική εξήγηση του εμπειρικού $\times 100$). Παίρνοντας ως τ το ίδιο μήκος μπλοκ $b \approx n^{1/3} \approx 42$ που το moving block bootstrap (§3.14) επιλέγει για εντελώς διαφορετικό λόγο, η διογκωση είναι $\sqrt{42} \approx 6,5$. Πολλαπλασιασμένη με τον παράγοντα $13,82/3,76 \approx 3,7$ που προκύπτει από το ότι το $M = \log(1/\varepsilon)$ είναι υπερβολικά συντηρητικό φράγμα για πραγματικές de-vigged πιθανότητες, δίνει ≈ 24 . Αυτό

δεν φτάνει το εμπειρικά συντονισμένο $\times 100$, αλλά είναι μερική εξήγηση που προκύπτει χωρίς καμία σάρωση πλέγματος — και γι' αυτό αξίζει να αναφερθεί, ακόμη κι όταν ο ίδιος ο αλγόριθμος δεν βελτιώνει τίποτα.

3.12 Bandit online κυρτή βελτιστοποίηση

Όλα τα παραπάνω υποθέτουν *πλήρη πληροφόρηση*: μετά τον γύρο t ο αλγόριθμος μαθαίνει ολόκληρο το διάνυσμα ℓ_t , δηλαδή πόσο καλά τα πήγε κάθε expert, όχι μόνο ο ίδιος. Στην εφαρμογή μας αυτό είναι εφικτό επειδή βαθμολογούμε και τους 26 bookmakers εκ των υστέρων. Δεν είναι όμως αυτονόητο. Ένας προγνώστης που καταγράφει μόνο τη δική του επίδοση — και αυτή είναι η συνήθης κατάσταση σε ανάπτυξη — παρατηρεί έναν μόνο αριθμό τον γύρο:

$$f_t(w_t) = -\log\langle w_t, p_t[y_t] \rangle.$$

Το μοντέλο αυτό ονομάζεται *bandit*, και ορίζει γνήσια δυσκολότερο πρόβλημα. Η δυσκολία είναι συγκεκριμένη: για να κινηθεί κανείς προς την κατεύθυνση μείωσης μιας συνάρτησης χρειάζεται την κλίση της, και μία βαθμωτή τιμή δεν την προσδιορίζει. Η λύση των Flaxman, Kalai & McMahan (2005) είναι να κατασκευαστεί μια στοχαστική εκτίμηση της κλίσης από τιμές της συνάρτησης μόνο.

Λήμμα 3.22 (Εκτίμηση κλίσης από μία τιμή). Έστω $f : \mathbb{R}^d \rightarrow \mathbb{R}$ και $\hat{f}_\delta(x) = \mathbb{E}_{v \sim \mathbb{B}^d}[f(x + \delta v)]$ η εξομάλυνσή της με ομοιόμορφο v στη μοναδιαία μπάλα. Αν u κατανέμεται ομοιόμορφα στη μοναδιαία σφαίρα $\mathbb{S}^{d-1}$, τότε

$$\mathbb{E}_u \left[\frac{d}{\delta} f(x + \delta u) u \right] = \nabla \hat{f}_\delta(x).$$

Σκιαγράφηση. Από το θεώρημα απόκλισης του Stokes, η κλίση ενός ολοκληρώματος πάνω σε μπάλα γράφεται ως ολοκλήρωμα πάνω στο σύνορό της: $\nabla \int_{\mathbb{B}} f(x + \delta v) dv = \frac{1}{\delta} \int_{\mathbb{S}} f(x + \delta u) u du$. Κανονικοποιώντας τα δύο μέτρα — ο λόγος του όγκου της μπάλας προς το εμβαδόν της σφαίρας σε d διαστάσεις είναι $1/d$ — προκύπτει ο συντελεστής d/δ . $\square$

Η εκτίμηση είναι επομένως *αμερόληπτη* ως προς την κλίση της εξομαλυσμένης συνάρτησης, όχι της αρχικής, και η εξομάλυνση εισάγει σφάλμα $O(\delta)$. Ταυτόχρονα η διασπορά της κλιμακώνεται ως $O(1/\delta^2)$: μικρό δ δίνει μικρή μεροληψία και τεράστιο θόρυβο, μεγάλο δ το αντίστροφο. Η βελτιστοποίηση της ανταλλαγής δίνει το κεντρικό αποτέλεσμα.

Θεώρημα 3.23 (Flaxman, Kalai & McMahan, 2005). Για κυρτές απώλειες φραγμένες κατ' απόλυτη τιμή, ο Bandit Gradient Descent με $\delta \sim T^{-1/4}$ και κατάλληλο η επιτυγχάνει

$$\mathbb{E}[\text{Regret}_T] = O(T^{3/4}).$$

Η σύγκριση με το $O(\sqrt{T}) = O(T^{1/2})$ της πλήρους πληροφόρησης είναι το ποσοτικό τίμημα της άγνοιας. Το φράγμα βελτιώνεται σε $O(\sqrt{T})$ αν επιτραπούν δύο ερωτήματα στην ίδια συνάρτηση ανά γύρο (Agarwal, Dekel & Xiao, 2010), με την εκτίμηση

$$\hat{g}_t = \frac{d}{2\delta} (f_t(x_t + \delta u) - f_t(x_t - \delta u)) u,$$

η οποία είναι πεπερασμένη διαφορά κατά μήκος τυχαίας κατεύθυνσης. Ο λόγος της βελτίωσης φαίνεται αμέσως: η αφαίρεση ακυρώνει τον σταθερό όρο $f_t(x_t)$ που στην εκτίμηση ενός σημείου πολλαπλασιάζεται επί d/δ και κυριαρχεί στη διασπορά. Καθώς $\delta \rightarrow 0$ η εκτίμηση δύο σημείων συγκλίνει στην ακριβή κατευθυντική παράγωγο, δηλαδή το μοντέλο δύο ερωτημάτων δεν είναι πραγματικά bandit για ομαλές συναρτήσεις — παρατήρηση που έχει άμεση συνέπεια στα μετρούμενα αποτελέσματα.

Η γεωμετρία του simplex. Η εφαρμογή στο δικό μας $\mathcal{K} = \Delta_N$ απαιτεί τρεις προσαρμογές που δεν είναι διακοσμητικές:

- το simplex είναι $(N-1)$ -διάστατο, οπότε η διαταραχή πρέπει να ανήκει στον *εφαπτόμενο χώρο* $\{u : \sum_i u_i = 0\}$ και ο συντελεστής του Λήμματος 3.22 είναι $d = N - 1$, όχι N . Διαταραχή σε τυχαία κατεύθυνση του $\mathbb{R}^N$ θα έβγαζε το σημείο εκτός του επιπέδου $\sum_i w_i = 1$.
- το σημείο γύρω από το οποίο διαταράσσουμε πρέπει να απέχει από το σύνορο, αλλιώς η διαταραχή είναι μη εφικτή. Χρησιμοποιείται το *συρρικνωμένο simplex* $\Delta^\xi = \{w : w_i \geq \xi/N\}$, και η επιλογή $\delta = \xi/N$ εξασφαλίζει εφικτότητα δωρεάν: αφού $|u_i| \leq 1$, κάθε συντεταγμένη του $w \pm \delta u$ παραμένει μη αρνητική, ενώ το άθροισμα μένει ακριβώς 1.
- η συρρίκνωση εισάγει τη δική της μεροληψία, αφού το βέλτιστο μπορεί να βρίσκεται στο σύνορο — και στα δεδομένα μας τυπικά βρίσκεται, αφού η προβολή του Θεωρήματος 3.10 μηδενίζει συντεταγμένες.

Υπό την αναγωγή Sleeping Experts όλα τα παραπάνω περιορίζονται στο $A(t)$, οπότε τα d και δ μεταβάλλονται ανά γύρο με το πλήθος των ξύπνιων. Γύρος με έναν μόνο ξύπνιο expert έχει $d = 0$: δεν υπάρχει κατεύθυνση για διαταραχή και δεν μαθαίνεται τίποτα.

Τι μετράει «η απώλεια» ενός bandit αλγορίθμου. Μια λεπτομέρεια λογιστικής που αλλάζει το νόημα των αριθμών. Ο αλγόριθμος δημοσιεύει το διαταραγμένο σημείο $w_t + \delta u_t$, όχι το κέντρο w_t , οπότε η απώλεια που πραγματικά πληρώνει περιλαμβάνει το κόστος της εξερεύνησης· αυτή είναι και η ποσότητα την οποία αφορά το Θεώρημα 3.23. Το κέντρο w_t είναι όμως η πρόβλεψη που θα αναπτύσσαμε, και είναι το μόνο μέγεθος άμεσα συγκρίσιμο με τον OGD σε ολόκληρη τη σειρά μετρικών. Αναφέρονται και τα δύο (§7.10): το πρώτο είναι η τίμια λογιστική του bandit, το δεύτερο απαντά στο ερώτημα «τι μάθαμε τελικά».

3.13 Κατάλληλοι κανόνες βαθμολόγησης και βαθμονόμηση

Πέρα από το log-loss χρησιμοποιούμε το Brier score, $\frac{1}{T} \sum_t \|\hat{p}_t - e_{y_t}\|^2$, επίσης αυστηρά κατάλληλο. Η γενική θεωρία (Gneiting & Raftery, 2007) δείχνει ότι κάθε κατάλληλος κανόνας βαθμολόγησης αντιστοιχεί σε μια κυρτή συνάρτηση G πάνω στο simplex μέσω της αναπαράστασης του Savage,

$$S(q, y) = G(q) + \langle \nabla G(q), e_y - q \rangle,$$

όπου η αναμενόμενη βαθμολογία $\mathbb{E}_{y \sim p}[S(q, y)]$ ελαχιστοποιείται στο $q = p$ ακριβώς επειδή η G είναι κυρτή. Το log-loss προκύπτει για G την αρνητική εντροπία και το Brier για $G(q) = \|q\|^2$. Τα δύο δεν είναι επομένως ανεξάρτητες επιλογές αλλά δύο σημεία της ίδιας οικογένειας — γεγονός που εξηγεί γιατί, όπως διαπιστώνεται εμπειρικά, συμφωνούν σε 18 από 18 ετυμηγορίες, ενώ η ακρίβεια, που δεν ανήκει στην οικογένεια, δεν αναπαράγει καμία.

Η αποσύνθεση του Murphy. Αν οι προβλέψεις ομαδοποιηθούν σε κλάσεις με κοινή τιμή, κάθε κατάλληλος κανόνας αναλύεται σε τρεις όρους:

$$\underbrace{\bar{S}}_{\text{σκορ}} = \underbrace{\mathbb{E}[d(\hat{p}, \bar{y}_{\hat{p}})]}_{\text{αναξιολπιστία}} - \underbrace{\mathbb{E}[d(\bar{y}_{\hat{p}}, \bar{y})]}_{\text{διακριτική ικανότητα}} + \underbrace{d(\bar{y}, \cdot)}_{\text{αβεβαιότητα}},$$

όπου $\bar{y}_{\hat{p}}$ η πραγματική συχνότητα στη κλάση με πρόβλεψη $\hat{p}$, $\bar{y}$ η συνολική βασική συχνότητα και d η απόκλιση που επάγει η G . Ο τρίτος όρος είναι ιδιότητα των δεδομένων και κανείς δεν μπορεί να τον βελτιώσει. Ο δεύτερος απαιτεί γνώσια πληροφορία. Ο πρώτος όμως — η αναξιολπιστία — διορθώνεται χωρίς καμία επιπλέον πληροφορία, αναδιατάσσοντας μονότονα τις ήδη υπάρχουσες πιθανότητες. Εκεί ακριβώς παρεμβαίνει το στάδιο βαθμονόμησης, και η Πρόταση 3.3 έχει ήδη προβλέψει ότι ο τελεστής συνάθροισης επιβαρύνει συστηματικά αυτόν ακριβώς τον όρο.

Temperature scaling. Η διόρθωση που χρησιμοποιούμε υψώνει τις πιθανότητες σε εκθέτη $s = 1/T_{\text{temp}}$ και επανακανονικοποιεί,

$$\tilde{p}_k = \frac{\hat{p}_k^s}{\sum_j \hat{p}_j^s}.$$

Τιμές $s < 1$ «απαλύνουν» την κατανομή, τιμές $s > 1$ την οξύνουν. Πρόκειται για μονοπαρμετρική οικογένεια, η οποία διατηρεί τη σειρά κατάταξης των ενδεχομένων και άρα δεν μπορεί να αλλάξει καμία απόφαση argmax — ιδιότητα που εξηγεί γιατί η βαθμονόμηση βελτιώνει σημαντικά το log-loss αφήνοντας την ακρίβεια αμετάβλητη.

Πρόταση 3.24 (Κυρτότητα ως προς τον εκθέτη). Έστω $a_k = \log \hat{p}_k$ και y το πραγματικό ενδεχόμενο. Η απώλεια

$$\phi(s) = -\log \tilde{p}_y = -s a_y + \log \sum_j e^{s a_j}$$

είναι κυρτή ως προς s , με $\phi'(s) = \mathbb{E}_{k \sim \tilde{p}^{(s)}}[a_k] - a_y$ και $\phi''(s) = \text{Var}_{k \sim \tilde{p}^{(s)}}(a_k) \geq 0$.

Απόδειξη. Ο πρώτος όρος είναι γραμμικός. Ο δεύτερος είναι log-sum-exp γραμμικών συναρτήσεων του s , γνωστά κυρτή. Παραγωγίζοντας άμεσα, $\frac{d}{ds} \log \sum_j e^{s a_j} = \sum_j a_j e^{s a_j} / \sum_j e^{s a_j} = \mathbb{E}_{\tilde{p}^{(s)}}[a]$, και η δεύτερη παράγωγος του λογαρίθμου μιας ροπογεννήτριας είναι η διασπορά κάτω από την αντίστοιχη εκθετικά στρεβλωμένη κατανομή, η οποία εδώ είναι ακριβώς η $\tilde{p}^{(s)}$. $\square$

Η κυρτότητα είναι αυτό που καθιστά το s μαθήσιμο με projected OGD, δηλαδή δεύτερο στάδιο OCO πάνω στην έξοδο του πρώτου, που παραμένει πλήρως αιτιώδης: η θερμοκρασία του γύρου t εξαρτάται μόνο από αποτελέσματα ως τον γύρο $t - 1$. Η μορφή της παραγώγου έχει επιπλέον άμεση ερμηνεία: το βήμα είναι θετικό όταν το πραγματικό ενδεχόμενο είχε λογαριθμική πιθανότητα χαμηλότερη του μέσου όρου, δηλαδή ο αλγόριθμος οξύνει την κατανομή όταν εκπλήσσεται και την απαλύνει όταν όχι.

3.14 Στατιστική σημαντικότητα: moving block bootstrap

Η σύγκριση δύο προγνωστών απαιτεί έλεγχο της διαφοράς των ανά γύρο απωλειών τους. Ένα απλό t -test θα ήταν ακατάλληλο, καθώς οι διαδοχικές απώλειες δεν είναι ανεξάρτητες: αγώνες της ίδιας αγωνιστικής και της ίδιας περιόδου μοιράζονται δυσκολία. Η συνέπεια της παράβλεψης είναι συγκεκριμένη και μονόπλευρη: για θετικά συσχετισμένα ακολουθία ισχύει

$$\text{Var}\left(\frac{1}{n} \sum_t d_t\right) = \frac{\sigma^2}{n} \left(1 + 2 \sum_{k \geq 1} \left(1 - \frac{k}{n}\right) \rho_k\right) > \frac{\sigma^2}{n},$$

οπότε ο τύπος της ανεξαρτησίας υποτιμά τη διασπορά, τα διαστήματα εμπιστοσύνης βγαίνουν πολύ στενά και αποτελέσματα φαίνονται σημαντικά ενώ δεν είναι.

Χρησιμοποιούμε το *moving block bootstrap* (Künsch, 1989), το οποίο δειγματοληπτεί με επανατοποθέτηση μπλοκ διαδοχικών παρατηρήσεων μήκους b , διατηρώντας έτσι την τοπική συσχέτιση: κάθε μπλοκ κουβαλά μαζί του τη δομή εξάρτησης εντός του, και μόνο οι συσχετίσεις σε απόσταση μεγαλύτερη του b καταστρέφονται. Το 95% διάστημα εμπιστοσύνης προκύπτει από τα ποσοστημόρια της κατανομής bootstrap.

Παρατήρηση 3.25 (Γιατί $b \approx n^{1/3}$). Η επιλογή του μήκους είναι ανταλλαγή μεροληψίας-διασποράς. Μικρό b καταστρέφει εξαρτήσεις που υπάρχουν, αφήνοντας μεροληψία τάξεως $O(1/b)$ στην εκτίμηση της διασποράς μεγάλου δείγματος· μεγάλο b αφήνει λίγα ουσιαστικά ανεξάρτητα μπλοκ, δηλαδή n/b , και ανεβάζει τη διασπορά της ίδιας της εκτίμησης κατά $O(b/n)$. Ελαχιστοποιώντας το μέσο τετραγωνικό σφάλμα $O(b^{-2}) + O(b/n)$ προκύπτει $b \propto n^{1/3}$ (Hall, Horowitz & Jing, 1995). Για $n \approx 76.000$ δίνει $b \approx 42$, δηλαδή περίπου μιάμιση αγωνιστική — τάξη μεγέθους που ταιριάζει με τον φυσικό ορίζοντα εξάρτησης των δεδομένων. Η ίδια ποσότητα επανεμφανίζεται αυτόνομα ως ορίζοντας εξάρτησης στη μελέτη του βήματος, επιλεγμένη εκεί για εντελώς διαφορετικό λόγο.

Σύμβαση προσήμου. Ορίζουμε $d_t = \ell_t(A) - \ell_t(B)$, οπότε **αρνητική** μέση διαφορά σημαίνει ότι ο πρώτος είναι **καλύτερος**. Για το log-loss χαμηλότερο είναι καλύτερο· για τον ρυθμό λογαριθμικής ανάπτυξης του κεφαλαίου ισχύει το αντίθετο.

3.15 Το κριτήριο Kelly

Δεδομένης εκτιμώμενης πιθανότητας p και δεκαδικής απόδοσης o , το κλάσμα του κεφαλαίου που μεγιστοποιεί τον αναμενόμενο λογαριθμικό ρυθμό ανάπτυξης είναι

$$f^* = \frac{p(o-1) - (1-p)}{o-1} = p - \frac{1-p}{o-1}.$$

Παραγωγή. Στοιχηματίζοντας κλάσμα f του κεφαλαίου, το κεφάλαιο πολλαπλασιάζεται επί $1 + f(o-1)$ με πιθανότητα p και επί $1 - f$ με πιθανότητα $1 - p$. Ο αναμενόμενος λογαριθμικός ρυθμός είναι

$$g(f) = p \log(1 + f(o-1)) + (1-p) \log(1 - f).$$

Παραγωγίζοντας,

$$g'(f) = \frac{p(o-1)}{1 + f(o-1)} - \frac{1-p}{1-f},$$

και θέτοντας $g'(f) = 0$ προκύπτει $p(o-1)(1-f) = (1-p)(1+f(o-1))$, απ' όπου $f^* = p - (1-p)/(o-1)$. Η g είναι κοίλη, οπότε το σημείο αυτό είναι μέγιστο. $\square$

Το κριτήριο δεν είναι αυθαίρετη προτίμηση για τον λογάριθμο. Ο Breiman (1961) έδειξε ότι η στρατηγική που μεγιστοποιεί τον αναμενόμενο λογαριθμικό ρυθμό είναι *ασυμπτωτικά βέλτιστη* με δύο ισχυρές έννοιες: μεγιστοποιεί τον ρυθμό αύξησης του κεφαλαίου σχεδόν βεβαίως, και ελαχιστοποιεί τον αναμενόμενο χρόνο για να φτάσει το κεφάλαιο σε οποιοδήποτε προκαθορισμένο μεγάλο επίπεδο. Η λογαριθμική χρησιμότητα προκύπτει επομένως από την επαναληπτική δομή του προβλήματος, όχι από υπόθεση για τις προτιμήσεις του στοιχηματιστή.

Γιατί κλασματικό Kelly. Το πλήρες Kelly είναι γνωστό για τη μεταβλητότητά του και για την ευαισθησία του σε σφάλματα εκτίμησης του p . Η ανταλλαγή ποσοτικοποιείται από το ανάπτυγμα δεύτερης τάξης του g γύρω από το μηδέν. Γράφοντας $b = o - 1$ και $e = pb - (1-p)$ την αναμενόμενη απόδοση ανά μονάδα,

$$g(f) \approx ef - \frac{1}{2}\sigma^2 f^2, \quad \sigma^2 = \mathbb{E}[b^2] \text{ κατά προσέγγιση,}$$

μια κοίλη παραβολή με μέγιστο $f^* = e/\sigma^2$ και μέγιστη τιμή $g(f^*) = e^2/(2\sigma^2)$.

Πρόταση 3.26 (Το κόστος του κλασματικού Kelly). *Στην τετραγωνική προσέγγιση, στοιχηματίζοντας κλάσμα λf^* με $\lambda \in (0, 1]$ διατηρείται ποσοστό $\lambda(2-\lambda)$ του μέγιστου ρυθμού ανάπτυξης, ενώ η διασπορά του κεφαλαίου μειώνεται κατά παράγοντα λ^2 .*

Απόδειξη. $g(\lambda f^*) = e\lambda f^* - \frac{1}{2}\sigma^2 \lambda^2 f^{*2} = \lambda \frac{e^2}{\sigma^2} - \frac{1}{2}\lambda^2 \frac{e^2}{\sigma^2} = (2\lambda - \lambda^2) \frac{e^2}{2\sigma^2} = \lambda(2-\lambda) g(f^*)$. Η διασπορά της ανά γύρο απόδοσης είναι ανάλογη του f^2 , άρα κλιμακώνεται ως λ^2 . $\square$

Για $\lambda = \frac{1}{4}$, την τιμή που χρησιμοποιείται εδώ, διατηρείται $\frac{1}{4} \cdot \frac{7}{4} = \frac{7}{16} \approx 44\%$ του ρυθμού ανάπτυξης με $\frac{1}{16}$ της διασποράς — πολύ ευνοϊκή ανταλλαγή. Το επιχείρημα είναι ισχυρότερο απ' όσο φαίνεται, γιατί το p εδώ είναι *εκτίμηση*: αν η πραγματική πιθανότητα είναι μικρότερη της εκτιμώμενης, το πλήρες Kelly υπερστοιχηματίζει, και η ζημία από την υπερβολή είναι ασύμμετρα μεγαλύτερη από το κέρδος της αντίστοιχης έλλειψης, αφού η g πέφτει στο $-\infty$ καθώς $f \rightarrow 1$.

Περισσότερα από δύο ενδεχόμενα. Με τρία αμοιβαία αποκλειόμενα ενδεχόμενα η ακριβής λύση απαιτεί ταυτόχρονη βελτιστοποίηση του διανύσματος των στοιχημάτων. Η υλοποίηση απλοποιεί: σε κάθε γύρο επιλέγεται το ενδεχόμενο με τη μεγαλύτερη θετική αναμενόμενη αξία και στοιχηματίζεται μόνο αυτό, με τον διμερή τύπο. Η απλοποίηση είναι συντηρητική — ένα χαρτοφυλάκιο ταυτόχρονων στοιχημάτων σε αμοιβαία αποκλειόμενα ενδεχόμενα μπορεί μόνο να αυξήσει τον ρυθμό, αφού μειώνει τη διασπορά — και ταιριάζει με τον τρόπο που στοιχηματίζει κανείς στην πράξη. Στοιχηματίζουμε μόνο όταν $po > 1$, γεγονός που απαιτεί η εκτίμησή μας να υπερβαίνει την υπονοούμενη πιθανότητα της αγοράς *μετά* το περιθώριο: το κατώφλι δεν είναι «είμαστε καλύτεροι από τον bookmaker» αλλά «είμαστε καλύτεροι κατά περισσότερο από το περιθώριό του», και η διαφορά των δύο είναι ακριβώς ο λόγος για τον οποίο βελτιωμένο log-loss δεν συνεπάγεται κερδοφορία.

3.16 Το μέγεθος του στοιχήματος ως τρίτο στάδιο ΟCO

Ο συντελεστής $\frac{1}{4}$ της Πρότασης 3.26 είναι πρακτικός κανόνας. Η τιμή του δεν προκύπτει από τα δεδομένα, και δεν υπάρχει λόγος να είναι η ίδια απέναντι σε έναν bookmaker που τιμολογεί σφιχτά και σε έναν που δεν τιμολογεί. Είναι επομένως φυσικός υποψήφιος για να μαθευτεί online, όπως μαθεύτηκαν ήδη τα βάρη και η θερμοκρασία.

Τι ακριβώς μαθαίνεται, και γιατί έχει σημασία. Η προφανής διατύπωση — μάθε το κλάσμα f του κεφαλαίου κατευθείαν — είναι λάθος, και ο λόγος είναι ο *comparator*. Ένα φράγμα regret για έναν τέτοιο μαθητή είναι υπόσχεση απέναντι στο καλύτερο σταθερό f εκ των υστέρων. Ο κλειστός τύπος όμως δεν ανήκει καν σε αυτή την κλάση: παράγει διαφορετικό f κάθε γύρο, υπολογισμένο από το $\hat{p}_t$ και την απόδοση, που είναι και τα δύο γνωστά πριν τοποθετηθεί το στοίχημα. Ακόμη και μηδενικό regret απέναντι στο καλύτερο σταθερό ποντάρισμα δεν φτάνει έναν κανόνα που μεταβάλλεται ανά γύρο. Επιπλέον ένας τέτοιος μαθητής πετά το $\hat{p}_t$, δηλαδή ακριβώς την ποσότητα που τα δύο προηγούμενα στάδια υπάρχουν για να παραγάγουν, και την ξαναμαθαίνει από ένα bit ανά στοίχημα.

Η σωστή διατύπωση κρατά τον κλειστό τύπο και μαθαίνει μόνο τον *πολλαπλασιαστή*:

$$f_t = \lambda_t \cdot f_t^*, \quad f_t^* = f^*(\hat{p}_t, o_t), \quad \lambda_t \in [0, \lambda_{\max}].$$

Η πληροφορία του γύρου παραμένει μέσα στο f_t^* και μαθαίνεται μόνο η συρρίκνωση. Ο comparator «καλύτερο σταθερό λ » γίνεται τώρα ουσιαστικό αντικείμενο: είναι ακριβώς η ποσότητα που ο συντελεστής $\frac{1}{4}$ καθηλώνει σε σταθερά.

Πρόταση 3.27 (Η απώλεια ως προς τον πολλαπλασιαστή). Με $w \in \{0, 1\}$ τον δείκτη νίκης, η απώλεια ενός γύρου

$$\ell_t(\lambda) = -\log(1 - \lambda f_t^* + \lambda f_t^* o_t w)$$

είναι κυρτή ως προς λ , με παράγωγο

$$\ell'_t(\lambda) = \begin{cases} -f_t^*(o_t - 1)/g_t, & w = 1, \\ f_t^*/g_t, & w = 0, \end{cases} \quad g_t = 1 - \lambda f_t^* + \lambda f_t^* o_t w.$$

Επιπλέον είναι 1-exp-concave σε κάθε διάστημα όπου το g_t μένει φραγμένο μακριά από το μηδέν, δηλαδή όπου $\lambda_{\max} \max_t f_t^* < 1$.

Απόδειξη. Και στις δύο περιπτώσεις το όρισμα του λογαρίθμου είναι αφινική συνάρτηση του λ με θετική τιμή στο επιτρεπτό διάστημα, και η $-\log$ θετικής αφινικής συνάρτησης είναι κυρτή: οι παράγωγοι προκύπτουν με τον κανόνα της αλυσίδας και είναι οι παράγωγοι ως προς f πολλαπλασιασμένες επί f_t^* . Για την exp-concavity, $e^{-\alpha \ell_t(\lambda)} = g_t(\lambda)^\alpha$, και η α -δύναμη θετικής αφινικής συνάρτησης είναι κοίλη για $\alpha \leq 1$. $\square$

Ο περιορισμός $\lambda_{\max} \max_t f_t^* < 1$ δεν είναι τεχνική λεπτομέρεια αλλά συνθήκη φερεγγυότητας: πάνω από αυτόν μία και μόνη ήττα μηδενίζει το κεφάλαιο και η απώλεια παύει να είναι φραγμένη. Το επιτρεπτό διάστημα προσδιορίζεται επομένως από τα δεδομένα και όχι από επιλογή.

Ποιος αλγόριθμος. Η exp-concavity είναι το κρίσιμο σημείο. Ο projected OGD δίνει εδώ $O(\sqrt{T})$, ενώ το Online Newton Step των Hazan, Agarwal & Kale (2007) εκμεταλλεύεται την καμπυλότητα και δίνει $O(\log T)$. Σε μία διάσταση το σχήμα είναι ασυνήθιστα σύντομο,

$$A_t = A_{t-1} + \ell'_t(\lambda_t)^2, \quad \lambda_{t+1} = \Pi_{[0, \lambda_{\max}]} \left(\lambda_t - \frac{1}{\gamma} \frac{\ell'_t(\lambda_t)}{A_t} \right),$$

όπου η προβολή στη νόρμα που ορίζει ο A_t ταυτίζεται με απλή αποκοπή, αφού σε μία διάσταση η νόρμα αυτή είναι θετική αναβαθμονόμηση της ευκλείδειας.

Από πού ξεκινά. Η αρχική τιμή $\lambda_0 = 1$, δηλαδή πλήρες Kelly, δεν είναι ουδέτερη επιλογή αλλά η θεωρητικά σωστή: αν το $\hat{p}$ ήταν ακριβές, το πλήρες Kelly θα ήταν βέλτιστο, και κάθε συρρίκνωση κάτω από τη μονάδα είναι απάντηση στο *σφάλμα εκτίμησης*. Ξεκινώντας από εκεί, ο αλγόριθμος καλείται να ανακαλύψει από τα δεδομένα πόσο λανθασμένη είναι η δική του εκτίμηση — ποσότητα που καμία a-priori σταθερά δεν γνωρίζει.

Γιατί δεν μεταφέρεται το Universal Portfolios. Η καθαρή διατύπωση Online Portfolio Selection (Cover, 1991) συγκρίνεται με το καλύτερο σταθερό αναπροσαρμοζόμενο χαρτοφυλάκιο πάνω σε σταθερό σύνολο περιουσιακών στοιχείων. Εδώ τα «στοιχεία» είναι τα H/D/A ενός διαφορετικού αγώνα κάθε γύρο, οπότε ένα σταθερό διάνυσμα βαρών δεν αντιστοιχεί σε τίποτα ερμηνεύσιμο. Η αναγωγή στον βαθμωτό πολλαπλασιαστική είναι ο τρόπος να διατηρηθεί ένας ουσιαστικός comparator σε ένα πρόβλημα όπου το σύνολο των διαθέσιμων στοιχημάτων αλλάζει εντελώς από γύρο σε γύρο.

3.17 Μπεϋζιανή εκδοχή του Kelly και δειγματοληψία MCMC

Και ο κλειστός τύπος και ο μαθαίνόμενος πολλαπλασιαστικής αντιμετωπίζουν το $\hat{p}$ ως γνωστό. Δεν είναι: είναι εκτίμηση, και το πόσο αβέβαιη είναι ποικίλλει ανά αγώνα — όταν οι awake experts συμφωνούν, η εκτίμηση είναι αξιόπιστη, όταν διαφωνούν, όχι. Η φυσική διατύπωση αντικαθιστά το σημειακό μέγιστο με το *εκ των υστέρων αναμενόμενο*:

$$f^B = \arg \max_f \mathbb{E}_{\theta \sim \pi(\cdot | \mathcal{D})} [g(f, \theta)],$$

$$g(f, \theta) = \theta_k \log(1 + f(o_k - 1)) + (1 - \theta_k) \log(1 - f).$$

Πρόταση 3.28 (Η μπεϋζιανή εκδοχή είναι πάντοτε συντηρητικότερη). Για κάθε μη εκφυλισμένη εκ των υστέρων κατανομή π με μέση τιμή $\bar{\theta}$ ισχύει $f^B \leq f^*(\bar{\theta})$, όπου f^* ο κλειστός τύπος στο σημειακό $\bar{\theta}$. Η ανισότητα είναι γνήσια όταν π έχει θετική διασπορά.

Σκιαγράφηση. Η $g(f, \cdot)$ είναι γραμμική ως προς θ_k , οπότε $\mathbb{E}[g(f, \theta)] = g(f, \bar{\theta})$ ως προς την τιμή· η διαφορά δεν βρίσκεται εκεί αλλά στο ότι η g είναι αυστηρά κοίλη και μη φραγμένη προς τα κάτω ως προς f : $\log(1 - f) \rightarrow -\infty$ καθώς $f \rightarrow 1$. Μάζα της π σε χαμηλά θ_k αντιστοιχεί σε σενάρια όπου το στοίχημα χάνει, και η απεριόριστη ποινή εκεί κυριαρχεί στην αναμενόμενη τιμή πολύ πριν επηρεαστεί η μέση τιμή. Η παράγωγος $\partial_f \mathbb{E}[g]$ στο $f^*(\bar{\theta})$ είναι επομένως αρνητική, και η κοιλότητα μετακινεί το μέγιστο προς τα αριστερά. $\square$

Το πόρισμα είναι εννοιολογικά ελκυστικό: η *συρρίκνωση προκύπτει* από την αβεβαιότητα αντί να επιβάλλεται με μια αυθαίρετη σταθερά $\frac{1}{4}$, και το μέγεθός της μεταβάλλεται ανά γύρο ανάλογα με το πόσο συμφωνούν οι experts.

Το μοντέλο. Ως εκ των προτέρων κατανομή λαμβάνεται η $\theta \sim \text{Dirichlet}(1, 1, 1)$, δηλαδή ομοιόμορφη πάνω στο Δ_3 . Κάθε ξύπνιος expert i συνεισφέρει την πρόβλεψή του p_i ως ένδειξη, μοντελοποιημένη ως $p_i \sim \text{Dirichlet}(\kappa \theta)$ και σταθμισμένη με το μαθημένο βάρος w_i . Η παράμετρος κ ελέγχει πόσο σφιχτά υποτίθεται ότι συσπειρώνονται οι experts γύρω από την αλήθεια: μεγάλο κ σημαίνει συγκεντρωμένη εκ των υστέρων κατανομή και επαναφέρει τη μέθοδο στον κλειστό τύπο, μικρό κ σημαίνει πλατιά κατανομή και ισχυρή συρρίκνωση.

Γιατί χρειάζεται MCMC. Η προκύπτουσα εκ των υστέρων κατανομή δεν είναι συζυγής — το θ εμφανίζεται μέσα στις παραμέτρους της Dirichlet των ενδείξεων — οπότε δεν υπάρχει κλειστή μορφή ούτε για την ίδια ούτε για το ολοκλήρωμα $\mathbb{E}_\pi[g(f, \theta)]$. Χρησιμοποιείται δειγματοληψία *Metropolis–Hastings* με τυχαίο περίπατο: από την τρέχουσα κατάσταση θ προτείνεται θ' και γίνεται αποδεκτή με πιθανότητα

$$a(\theta \rightarrow \theta') = \min \left\{ 1, \frac{\pi(\theta' | \mathcal{D}) q(\theta | \theta')}{\pi(\theta | \mathcal{D}) q(\theta' | \theta)} \right\}.$$

Με συμμετρική πρόταση ($q(\theta' | \theta) = q(\theta | \theta')$) ο λόγος απλοποιείται στον λόγο των εκ των υστέρων πυκνοτήτων, οπότε η *σταθερά κανονικοποίησης δεν χρειάζεται* — που είναι ακριβώς ο λόγος ύπαρξης της μεθόδου εδώ. Ο κανόνας αυτός ικανοποιεί τη *λεπτομερή ισορροπία* $\pi(\theta)P(\theta \rightarrow \theta') = \pi(\theta')P(\theta' \rightarrow \theta)$, άρα η π είναι στάσιμη κατανομή της αλυσίδας· με εργοδικότητα, οι χρονικοί μέσοι όροι συγκλίνουν στις αναμενόμενες τιμές ως προς την π .

Παρατήρηση 3.29 (Παράλληλες αλυσίδες αντί για μία μακριά). Η υλοποίηση τρέχει N παράλληλες αλυσίδες για λίγες επαναλήψεις αντί για μία μακριά. Οι δύο επιλογές είναι ισοδύναμες ως προς τη στάσιμη κατανομή, αλλά όχι ως προς το κόστος: οι παράλληλες αλυσίδες μετατρέπουν έναν βαθμωτό βρόχο Python σε διανυσματικές πράξεις numpy, που είναι αυτό που κάνει το ανά στοίχημα κόστος διαχειρίσιμο σε δεκάδες χιλιάδες στοιχήματα. Το τίμημα είναι ότι καμία αλυσίδα δεν προλαβαίνει να ξεχάσει πλήρως την αρχικοποίησή της, οπότε η προσέγγιση βασίζεται στο ότι το burn-in αρκεί — υπόθεση που δεν ελέγχεται τυπικά εδώ και αναφέρεται ως περιορισμός.

Η θεωρία λοιπόν ευνοεί σαφώς αυτή τη διατύπωση έναντι του σταθερού $\frac{1}{4}$. Το §7.12 αναφέρει ότι στα δεδομένα αυτά δεν την ευνοεί η μέτρηση, κάτι που είναι από μόνο του μέρος του επιχειρήματος της εργασίας: η θεωρητική ανωτερότητα μιας διατύπωσης δεν εγγυάται τίποτα όταν οι υποθέσεις της — εδώ, ότι το μοντέλο Dirichlet περιγράφει πράγματι πώς παράγονται οι διαφωνίες των bookmakers — δεν ισχύουν.

Κεφάλαιο 4

Δεδομένα

4.1 Πηγή και εύρος

Τα δεδομένα προέρχονται από το `football-data.co.uk`, ενότητα «Main Leagues», που δημοσιεύει ανά αγώνα το αποτέλεσμα και τις αποδόσεις πλήθους στοιχηματικών εταιρειών. Η ενότητα «Extra Leagues» έχει διαφορετική μορφή και συνήθως δεν περιέχει αποδόσεις, οπότε είναι εκτός πεδίου.

Πρωταθλήματα	22
Σεζόν	10 (2016/17 – 2025/26)
Αγώνες με ≥ 1 χρήσιμη απόδοση	76.584
Bookmakers ως experts	26 (13 opening / 13 closing)
Εύρος κάλυψης ανά bookmaker	6,9% – 99,8%

Πίνακας 4.1: Το σύνολο δεδομένων μετά την προεπεξεργασία.

Τα 22 πρωταθλήματα κατανέμονται σε Αγγλία ($\times 5$), Σκωτία ($\times 4$), Γερμανία / Ιταλία / Ισπανία / Γαλλία ($\times 2$ το καθένα) και Ολλανδία / Βέλγιο / Πορτογαλία / Τουρκία / Ελλάδα ($\times 1$). Ο συνδυασμός κορυφαίων και κατώτερων κατηγοριών είναι σκόπιμος: οι κατώτερες κατηγορίες προσελκύουν μικρότερο όγκο στοιχημάτων και άρα λιγότερη προσοχή από τους αναλυτές των εταιρειών, οπότε η ανομοιογένεια ανάμεσα στους experts είναι εκεί μεγαλύτερη.

4.2 Καθαρισμός

Συγκεντρωτικές στήλες. Το `football-data.co.uk` δημοσιεύει, πέρα από τις μεμονωμένες εταιρείες, και στήλες με το μέγιστο και τον μέσο όρο της αγοράς (Max, Avg), καθώς και τα αντίστοιχα του Betbrain για τις παλαιότερες σεζόν. Αποκλείονται: δεν είναι ανεξάρτητοι experts αλλά συναρτήσεις των υπολοίπων, και η παρουσία τους θα παραβίαζε την υπόθεση του πλαισίου ότι οι experts δίνουν χωριστές γνώμες.

Μετονομασία εταιρείας. Οι στήλες VC (VC Bet) και BV (BetVictor) αντιστοιχούν στην ίδια εταιρεία πριν και μετά από rebrand, και η παρουσία τους δεν επικαλύπτεται χρονικά. Συγχωνεύονται σε μία συνεχή ταυτότητα, ώστε ο expert να μην «γεννιέται» ξανά στα

μισά της δεκαετίας χάνοντας τη μαθημένη του ιστορία. Η συγχώνευση συνάγεται από τη μη επικαλυπτόμενη παρουσία, όχι από επίσημη πηγή, και σημειώνεται ως περιορισμός.

Εταιρείες με μερική χρονική παρουσία. Αρκετές στήλες δεν καλύπτουν ολόκληρη τη δεκαετία: άλλες ξεκινούν αργά και άλλες σταματούν νωρίς. Καμία δεν αποκλείεται γι' αυτόν τον λόγο — η αναγωγή *Sleeping Experts* (§3.9) υπάρχει ακριβώς για να τις χειρίζεται, και η εγγύηση κάθε expert μετριέται μόνο πάνω στους γύρους όπου ήταν ενεργός. Η χρονική παρουσία έχει όμως συνέπεια στα *κατώφλια κάλυψης*: ένα κατώφλι υπολογισμένο στη δεκαετία λέει ελάχιστα για την παρουσία μιας εταιρείας σε στενότερο παράθυρο, γι' αυτό κάθε ανάλυση περιορισμένου παραθύρου ξαναυπολογίζει το δικό της κατώφλι μέσα στο παράθυρο που εξετάζει (§7.7).

4.3 Αποδόσεις ανοίγματος και κλεισίματος

Για κάθε εταιρεία η πηγή δημοσιεύει δύο τιμές: την *αρχική* (opening), όταν ανοίγει η αγορά, και την *τελική* (closing), λίγο πριν την έναρξη. Η σύμβαση ονοματοδοσίας είναι ότι η κατάληξη C δηλώνει την τιμή κλεισίματος της ομώνυμης εταιρείας: B365 και B365C, PS και PSC, και ούτω καθεξής. Το panel των 26 χωρίζεται επομένως καθαρά σε 13 opening και 13 closing.

Η διάκριση δεν είναι τεχνική λεπτομέρεια αλλά ουσιώδης μεταβλητή. Η τιμή κλεισίματος έχει απορροφήσει όση πληροφορία έφτασε στην αγορά στο ενδιαμέσο — ανακοινώσεις συνθέσεων, τραυματισμοί, κινήσεις μεγάλων στοιχηματιστών — και γι' αυτό θεωρείται στη βιβλιογραφία το αποδοτικότερο διαθέσιμο σήμα. Η διάκριση επιβάλλει επίσης έναν περιορισμό αιτιότητας: όταν στοιχηματίζουμε σε μια τιμή ανοίγματος, καμία τιμή κλεισίματος δεν υπάρχει ακόμη, ούτε καν της ίδιας εταιρείας.

Κεφάλαιο 5

Μεθοδολογία

Το κεφάλαιο αυτό περιγράφει τον πειραματικό σχεδιασμό. Η βασική αρχή που το διατρέχει είναι ότι κάθε ποσότητα που αναφέρεται πρέπει να έχει υπολογιστεί χωρίς πρόσβαση σε πληροφορία που δεν θα ήταν διαθέσιμη τη στιγμή της πρόβλεψης, και να συγκρίνεται με ποσότητες που έχουν μετρηθεί στα ίδια ακριβώς δεδομένα.

5.1 Ο τανυστής των experts

Η βασική δομή είναι ένας τανυστής $P \in \mathbb{R}^{T \times N \times 3}$ με T γύρους (αγώνες σε χρονολογική σειρά), N experts και τρία ενδεχόμενα, μαζί με δυαδικό πίνακα $A \in \{0, 1\}^{T \times N}$ που δηλώνει ποιος expert έδωσε απόδοση σε ποιον αγώνα. Η χρονολογική ταξινόμηση είναι απαραίτητη: ολόκληρο το πλαίσιο προϋποθέτει ότι ο γύρος t προηγείται του $t + 1$.

5.2 Τα τρία στάδια OCO

Η αλυσίδα από τις ωμές αποδόσεις ως το στοίχημα αποτελείται από τρία διαδοχικά στάδια, όλα online και αιτιώδη.

1. **Στάθμιση των experts.** Οι τρεις αλγόριθμοι του Κεφαλαίου 3 με την αναγωγή Sleeping Experts, συν την ομοιόμορφη μέση τιμή ως baseline. Παράγουν ανά γύρο ένα μείγμα $\hat{p}_t$.
2. **Βαθμονόμηση.** Online temperature scaling πάνω στο $\hat{p}_t$ (§3.13), με τη θερμοκρασία να μαθαίνεται με projected OGD.
3. **Μέγεθος στοιχήματος.** Κριτήριο Kelly πάνω στις βαθμονομημένες πιθανότητες, με τον *πολλαπλασιαστή* να μαθαίνεται online αντί να καθλώνεται σε σταθερά (§3.16). Ο σταθερός συντελεστής $\frac{1}{4}$ διατηρείται ως σημείο αναφοράς για τη σύγκριση.

Και τα τρία στάδια είναι η ίδια συνταγή εφαρμοσμένη σε διαφορετικό αντικείμενο: κυρτή απώλεια, αιτιώδης ενημέρωση, προβολή στο εφικτό σύνολο. Η μόνη διαφορά μεταξύ τους είναι ποιο μέγεθος θεωρείται άγνωστο — το διάνυσμα των βαρών, η θερμοκρασία, ο *πολλαπλασιαστής* — και σε ποια κλάση απώλειας ανήκει το καθένα, κάτι που καθορίζει και τον κατάλληλο αλγόριθμο για το καθένα.

Η ομοιόμορφη μέση τιμή δεν είναι διακοσμητική. Είναι το κρίσιμο baseline: αν ένας αλγόριθμος δεν την ξεπερνά, τότε η μαθημένη στάθμιση δεν προσφέρει τίποτα πάνω από το να πάρει κανείς τον μέσο όρο της αγοράς, και η πολυπλοκότητα δεν δικαιολογείται.

5.3 Πρωτόκολλο επιλογής υπερπαραμέτρων

Το πλαίσιο δεν απαιτεί διαχωρισμό εκπαίδευσης και ελέγχου, αφού κάθε πρόβλεψη είναι ήδη εκτός δείγματος. Απαιτεί όμως προσοχή σε ό,τι *επιλέγεται* κοιτώντας τα δεδομένα. Δύο τέτοιες ποσότητες υπάρχουν: ο συντελεστής βήματος κάθε αλγορίθμου και ο ρυθμός μάθησης του βαθμονομητή. Και οι δύο επιλέγονται με το ίδιο πρωτόκολλο:

- χρονολογικό πρόθεμα 75% των γύρων κάθε σειράς ως *train*.
- σάρωση πλέγματος υποψήφιων τιμών, με αξιολόγηση αποκλειστικά στο πρόθεμα.
- ένα τελικό αιτιώδες πέρασμα σε ολόκληρη την ιστορία με την επιλεγμένη τιμή παγωμένη.

Όπου γίνεται *επιλογή διαμόρφωσης* με βάση αναφερόμενα νούμερα — για παράδειγμα η επιλογή μεταξύ panel — αναφέρεται επιπλέον και μια χρονική ουρά 25% που η επιλογή δεν είδε ποτέ, ώστε να είναι ορατό αν η επιλογή ήταν προσαρμογή στον θόρυβο.

5.4 Ρύθμιση του βήματος

Το θεωρητικά βέλτιστο βήμα και των τριών αλγορίθμων περιέχει ένα φράγμα M για τη μέγιστη απώλεια ενός γύρου. Επειδή οι πιθανότητες κόβονται στο $\varepsilon = 10^{-6}$ ώστε το log-loss να παραμένει πεπερασμένο, προκύπτει

$$M = \ln(1/\varepsilon) = 6 \ln 10 \approx 13,82.$$

Το φράγμα αυτό προϋποθέτει bookmaker που τιμολογεί στο ένα εκατομμυριοστό το αποτέλεσμα που τελικά συνέβη. Η μεγαλύτερη απώλεια που όντως παρατηρείται στα δεδομένα είναι 3,76, δηλαδή το worst-case βήμα είναι κατά τάξη μεγέθους πιο συντηρητικό απ' όσο δικαιολογούν τα δεδομένα. Οι συντελεστές ρυθμίζονται επομένως εμπειρικά, με το πρωτόκολλο του §5.3 και πάνω στο ίδιο πλέγμα για τους τρεις αλγορίθμους, ώστε η μεταξύ τους σύγκριση να παραμένει δίκαιη.

5.5 Σύγκριση σειρών με διαφορετική κάλυψη

Η μερική κάλυψη δημιουργεί μια παγίδα που καθορίζει μεγάλο μέρος του σχεδιασμού. Ένα log-loss υπολογισμένο πάνω σε ένα σύνολο αγώνων δεν είναι συγκρίσιμο με ένα log-loss υπολογισμένο πάνω σε άλλο: οι αγώνες διαφέρουν σε δυσκολία, και μια σειρά που καλύπτει λιγότερους μπορεί να φαίνεται καλύτερη απλώς επειδή έτυχε να καλύψει τους ευκολότερους.

Όπου συγκρίνονται σειρές με διαφορετική κάλυψη, επομένως:

- η *προσαρμογή* χρησιμοποιεί ολόκληρο το διαθέσιμο εύρος κάθε σειράς.

- η βαθμολόγηση περιορίζεται στην τομή των γύρων όπου όλες οι συγκρινόμενες σειρές ορίζονται.
- τα ζευγαρωτά τεστ τρέχουν στο ίδιο αυτό σύνολο.

Η αρχή αυτή έχει κόστος. Όσο περισσότερες σειρές μπαίνουν στη σύγκριση, τόσο μικραίνει η τομή, και σε ακραίες περιπτώσεις η απαίτηση να συμμετέχουν όλοι μηδενίζει τη στατιστική ισχύ. Όπου συμβαίνει αυτό, η σειρά με τη χαμηλή κάλυψη αναφέρεται χωριστά, σε σύγκριση ένα προς ένα πάνω στους δικούς της γύρους, αντί να επιβληθεί στον κοινό πίνακα.

5.6 Έλεγχοι αιτιότητας στο value betting

Η προσομοίωση στοιχηματισμού χρησιμοποιεί σχεδιασμό *leave-one-bookmaker-out*: ο bookmaker εναντίον του οποίου στοιχηματίζουμε αφαιρείται από το panel πριν την προσαρμογή, ώστε το μείγμα να μην «προβλέπει» χρησιμοποιώντας την ίδια την τιμή που καλείται να νικήσει. Αυτό δεν αρκεί. Όταν ο στόχος είναι τιμή ανοίγματος, πρέπει να αφαιρεθεί ολόκληρη η closing πλευρά του panel, γιατί καμία τιμή κλεισίματος δεν υπάρχει ακόμη τη στιγμή εκείνη — ούτε καν της ίδιας εταιρείας. Ένα panel που τις αφήνει μέσα στοιχηματίζει γνωρίζοντας πού θα κλείσει η αγορά, και παράγει τελικά κεφάλαια τάξης 10^6 – 10^9 , δηλαδή καθαρό τεχνούργημα κατασκευής.

Το panel εκπαίδευσης ταιριάζει επομένως στη φάση του στόχου: closing panel για closing στόχο, opening panel για opening στόχο.

5.7 Έλεγχος ανάπτυξης

Πέρα από τα παραπάνω, η εργασία περιλαμβάνει έναν έλεγχο που απαντά σε διαφορετικό ερώτημα από το regret: τι θα έκανε σήμερα ένα μοντέλο εκπαιδευμένο ως το χθες; Η τομή είναι πραγματική ημερομηνία και όχι ποσοστό της σειράς, η προσαρμογή γίνεται στους γύρους πριν από αυτήν, και η μέτρηση στους μετά. Οι αντίπαλοι επιλέγονται από την κάλυψή τους μέσα στο παράθυρο ελέγχου, ώστε η σύγκριση να αφορά την αγορά που υπάρχει τότε και όχι εκείνη που υπήρχε πριν από δέκα χρόνια.

Αναφέρονται δύο αναγνώσεις, γιατί απαντούν σε διαφορετικά ερωτήματα: μία όπου το μείγμα συνεχίζει να μαθαίνει μέσα στο παράθυρο ελέγχου, που είναι και το ρεαλιστικό σενάριο ανάπτυξης, και μία όπου τα βάρη παγώνουν στην τομή, που είναι η αυστηρή ανάγνωση του «εκπαιδεύτηκε μία φορά».

Κεφάλαιο 6

Υλοποίηση

Το κεφάλαιο αυτό περιγράφει την υλοποίηση, τόσο ως τεκμηρίωση όσο και επειδή αρκετές αποφάσεις σχεδιασμού αποδείχθηκαν ουσιώδεις για την ορθότητα των αποτελεσμάτων.

6.1 Οργάνωση

Ο κώδικας είναι μια ακολουθία αυτόνομων σεναρίων Python, καθένα από τα οποία απαντά ένα συγκεκριμένο ερώτημα, διαβάζοντας και γράφοντας επίπεδα αρχεία CSV. Δεν υπάρχει βάση δεδομένων, ούτε ενδιάμεση προσωρινή μνήμη: κάθε σενάριο επανυπολογίζει τους αλγορίθμους του από την αρχή σε κάθε εκτέλεση. Η επιλογή αυτή κοστίζει χρόνο εκτέλεσης αλλά εξαλείφει μια ολόκληρη κατηγορία σφαλμάτων, αυτά που προκύπτουν από μη ενημερωμένη ενδιάμεση κατάσταση.

Αρχείο	Ρόλος
data_processor.py	Κατασκευή του συνόλου δεδομένων, $de-vig \times 2$
sleeping_experts.py	Κοινή βιβλιοθήκη: φόρτωση, οι τρεις αλγόριθμοι, μετρικές
final_ranking.py	Η κατάταξη αναφοράς, με βαθμονόμηση
significance_test.py	Moving block bootstrap
market_devig_comparisons.py	Opening/closing panel, Shin έναντι αναλογικής
best_configuration.py	Στοιβάξη διαμορφώσεων
no_pinnacle_panel.py	Αφαίρεση Pinnacle, τρία panel
recent_window.py	Όλα τα πειράματα στις πέντε τελευταίες σεζόν
deployment_test.py	Έλεγχος ανάπτυξης με χρονική τομή
value_betting.py	Προσομοιώσεις Kelly με σταθερό συντελεστή
oco_kelly.py	Μαθαίνόμενος πολλαπλασιαστής Kelly (ONS / OGD)
bandit_oco.py	Bandit εκτιμητές κλίσης για τη στάθμιση
learning_rate_study.py	Σάρωση συντελεστών βήματος

Πίνακας 6.1: Τα κύρια αρχεία και ο ρόλος τους.

Η `sleeping_experts.py` είναι το μόνο κοινό σημείο: περιέχει τη φόρτωση των δεδομένων, τις τρεις υλοποιήσεις των αλγορίθμων και τις μετρικές αξιολόγησης, και εισάγεται από ουσιαστικά κάθε άλλο σενάριο.

6.2 Αριθμητικά ζητήματα

Αποκοπή πιθανοτήτων. Οι πιθανότητες περιορίζονται στο διάστημα $[\varepsilon, 1]$ με $\varepsilon = 10^{-6}$, ώστε το log-loss να παραμένει πεπερασμένο. Η επιλογή αυτή έχει συνέπεια πέρα από την αριθμητική ευστάθεια: καθορίζει το φράγμα M που εισέρχεται στο θεωρητικό βήμα, και συνεπώς — έμμεσα — ολόκληρη τη συζήτηση του §7.1.

Προβολή στο simplex. Η ευκλείδεια προβολή υλοποιείται με τον αλγόριθμο ταξινόμησης των Duchi κ.ά. (2008), πολυπλοκότητας $O(N \log N)$. Απαιτεί προσοχή στην περίπτωση κενού συνόλου ξύπνιων experts: ο αλγόριθμος αναζητά το τελευταίο στοιχείο που ικανοποιεί μια συνθήκη, και σε κενή είσοδο αποτυγχάνει. Οι υλοποιήσεις παραλείπουν ρητά τέτοιους γύρους.

Λογαριθμικός χώρος για τον Hedge. Όταν το βήμα είναι μεγάλο, τα βάρη του Hedge μπορούν να υποχειλίσουν. Η προφανής λύση — επανακανονικοποίηση του διανύσματος — είναι λανθασμένη, για τον λόγο που εξηγείται αμέσως παρακάτω. Η σωστή λύση είναι η διατήρηση των βαρών σε λογαριθμικό χώρο με μετατόπιση log-sum-exp κατά την πρόβλεψη.

6.3 Τρία σφάλματα που εντοπίστηκαν

Τα ακόλουθα αναφέρονται επειδή καθένα παρήγαγε, προσωρινά, λανθασμένο αποτέλεσμα, και επειδή ο μηχανισμός εντοπισμού τους αποτελεί μέρος της μεθοδολογίας.

Κανονικοποίηση του μόνιμου διανύσματος βαρών. Στην αναγωγή Sleeping Experts τα μόνιμα βάρη κωδικοποιούν πόση συνολική μάζα έχει συσσωρεύσει κάθε expert στη δική του ιστορία. Η κανονικοποίησή τους σε κάθε γύρο καταστρέφει αυτή τη σημασία και παράγει διαφορετικό αλγόριθμο, ο οποίος — επειδή αναδιανέμει σιωπηρά μάζα — φαίνεται καλύτερος. Σε μια δοκιμή το σφάλμα εμφάνισε ψευδή βελτίωση 0,0009, μεγαλύτερη από ολόκληρο το στάδιο βαθμονόμησης. Εντοπίστηκε από έναν ισχυρισμό που απαιτούσε ο Fixed-Share με $\alpha = 0$ να αναπαράγει ακριβώς τον απλό Hedge.

Ανάγνωση της τελικής κατάστασης. Ο πίνακας βαρών συμπληρώνεται μόνο για τους ξύπνιους κάθε γύρου, οπότε η τελευταία του γραμμή είναι μηδενική για κάθε expert που δεν συμμετείχε στον τελευταίο αγώνα — δέκα από τους είκοσι έξι, μεταξύ των οποίων ο καλύτερος μεμονωμένος προγνώστης. Διαβασμένο ως «τελικό βάρος», αυτό το μηδέν σημαίνει «δεν κάλυψε τον τελευταίο αγώνα», όχι «ο αλγόριθμος έμαθε να τον αγνοεί». Το σφάλμα είχε κρύψει τα σοβαρότερα κρούσματα ακριβώς του φαινομένου που το Fixed-Share υπάρχει για να μετρήσει.

Απόκλιση αντιγράφων. Δύο σενάρια διατηρούν δικά τους αντίγραφα κοινής λειτουργικότητας, και αμφότερα έσπασαν όταν άλλαξε το κοινό πρωτότυπο. Εντοπίστηκαν από ισχυρισμούς που τα ίδια τα αρχεία ήδη περιείχαν. Το συμπέρασμα, και η πρακτική που ακολουθείται έκτοτε, είναι ότι κάθε τοπικό αντίγραφο κοινού κώδικα οφείλει να φέρει μαζί του τον ισχυρισμό που επαληθεύει την ισοδυναμία.

6.4 Επαλήθευση

Πέρα από τα παραπάνω, η υλοποίηση φέρει συστηματικά ισχυρισμούς ισοδυναμίας: κάθε παραλλαγή ενός αλγορίθμου επαληθεύει ότι αναπαράγει ακριβώς τον βασικό στην προεπιλεγμένη του ρύθμιση. Έτσι, ο Fixed-Share με $\alpha = 0$ ισούται με τον Hedge, η παραμετροποιημένη σάρωση βήματος με συντελεστή ίσο με τον ισχύοντα ισούται με τον αλγόριθμο που τρέχει στο pipeline, και η παραλλαγή με παγκόσμιο ρολόι του §7.12 ισούται με την κανονική υλοποίηση. Οι έλεγχοι αυτοί εντόπισαν και τα τρία σφάλματα του §6.3.

Κεφάλαιο 7

Αποτελέσματα

7.1 Ρύθμιση του βήματος

Η σάρωση των συντελεστών βήματος προηγείται όλων, αφού καθορίζει τους αλγορίθμους με τους οποίους παράγονται τα υπόλοιπα αποτελέσματα. Και οι τρεις χρειάστηκαν αλλαγή, και — αυτό είναι το μη προφανές — **προς αντίθετες κατευθύνσεις**.


	Συντελ.	train	πλήρες	ουρά	ελάχ. train	ελάχ. ουράς
OGD	$\times 100$	0,99739	0,99745	0,99765	$\times 110$	$\times 100$
Hedge	$\times 0,25$	0,99828	0,99842	0,99883	$\times 0,25$	$\times 0,05$
FTRL	$\times 0,05$	0,99828	0,99843	0,99889	$\times 0,05$	$\times 0,005$

Πίνακας 7.1: Ισχύοντες συντελεστές βήματος. Η επιλογή γίνεται αποκλειστικά στο χρονολογικό πρόθεμα, οπότε η καθοριστική στήλη είναι η **ελάχ. train**: και για τους τρεις αλγορίθμους συμπίπτει με τον συντελεστή που χρησιμοποιείται, με μόνη εξαίρεση το $\times 110$ του OGD, το οποίο δίνει ουρά ταυτόσημη με το $\times 100$ (0,99765). Η στήλη **ελάχ. ουράς** αναφέρεται για σύγκριση και όχι ως κριτήριο — η διαφορά των δύο σχολιάζεται παρακάτω.

Το OGD θέλει βήμα εκατό φορές μεγαλύτερο από το θεωρητικό, με γνήσιο εσωτερικό βέλτιστο: πλατό στο διάστημα $\times 75$ ως $\times 110$, με τα $\times 200$, $\times 500$ και $\times 1000$ σαφώς χειρότερα. Τα Hedge και FTRL θέλουν βήμα *μικρότερο*, κατά παράγοντα 4 και 20 αντίστοιχα.

Μια επιφύλαξη που αποδείχθηκε ανυπόστατη. Το ελάχιστο της *ουράς* για τον Hedge και τον FTRL βρίσκεται χαμηλότερα από τις τιμές που χρησιμοποιούνται, στο $\times 0,05$ και $\times 0,005$ αντίστοιχα, και για ένα διάστημα η εργασία κουβαλούσε την επιφύλαξη ότι οι δύο αυτοί αλγόριθμοι αναφέρονται με υποβέλτιστο βήμα. Η επιφύλαξη ήταν λάθος, και ο λόγος αξίζει να ειπωθεί: η **επιλογή με βάση την ουρά είναι επιλογή πάνω στο σύνολο ελέγχου**, δηλαδή ακριβώς ό,τι το πρωτόκολλο του §5.3 υπάρχει για να αποτρέψει. Επειδή το log-loss είναι απλός μέσος όρος ανά γύρο, η τιμή του προθέματος ανακτάται ακριβώς από το πλήρες δείγμα και την ουρά, ως $(\text{πλήρες} \cdot T - \text{ουρά} \cdot n_{\text{ουράς}}) / n_{\text{train}}$, και υπό το πρωτόκολλο η απάντηση αντιστρέφεται: ο Hedge επιλέγει $\times 0,25$ και ο FTRL $\times 0,05$, δηλαδή *ακριβώς* τους ισχύοντες συντελεστές.

Τα νούμερα δείχνουν και γιατί. Στον Hedge το $\times 0,05$ δίνει train 0,99838 έναντι 0,99828 του $\times 0,25$, και στον FTRL το $\times 0,005$ δίνει 0,99862 έναντι 0,99828 του $\times 0,05$: και στις δύο



Σχήμα 7.1: Σάρωση του συντελεστή βήματος και για τους τρεις αλγορίθμους. Η επιλογή γίνεται στο χρονολογικό πρόθεμα· η ουρά αναφέρεται ως επαλήθευση. Το OGD παρουσιάζει γνήσιο εσωτερικό βέλτιστο. Οι καμπύλες ουράς των Hedge και FTRL συνεχίζουν να πέφτουν προς τα αριστερά, αλλά η επιλογή δεν γίνεται πάνω σε αυτές — βλ. το σχόλιο για την επιφύλαξη που αποδείχθηκε ανυπόστατη.

περιπτώσεις η σειρά *αντιστρέφεται* μεταξύ προθέματος και ουράς, που είναι η υπογραφή της προσαρμογής στην ουρά και όχι ενδείξεις καλύτερης ρύθμισης. Το OGD παραμένει βέλτιστο στο $\times 100$, με το $\times 110$ να δίνει ταυτόσημη ουρά — ισοπαλία μέσα στο ήδη περιγραφόμενο πλατό.

Σταθερό βήμα: η μία ιδέα *χρονοδιαγράμματος* που δεν είχε δοκιμαστεί σωστά. Το φθίνον $1/\sqrt{t}$ παράγεται για *στατικό* comparator, ενώ το panel εδώ δεν είναι στατικό, οπότε ένα βήμα που δεν σταματά ποτέ να κινείται είναι η θεωρητικά υποδεικνυόμενη εναλλακτική. Είχε δοκιμαστεί μόνο για τον Hedge και μόνο στο διάστημα $[0,1,2]$ — ενώ το ισχύον φθίνον βήμα του Hedge περνά από $\eta \approx 0,033$ στον πρώτο γύρο και $\eta \approx 1,7 \cdot 10^{-4}$ στη μέση της περιόδου, δηλαδή ολόκληρη η ενδιαφέρουσα περιοχή βρισκόταν *κάτω* από το παλιό πλέγμα. Η σάρωση επεκτάθηκε σε πέντε δεκάδες και στους τρεις αλγορίθμους, με επιλογή στο πρόθεμα και ζευγαρωμένο έλεγχο στην ουρά.

	σταθερό η	ουρά	φθίνον	p	
Hedge	$3 \cdot 10^{-4}$	0,99892	0,99883	$< 0,001$	φθίνον
OGD	0,1	0,99795	0,99765	0,021	φθίνον
FTRL	10^{-5}	0,99879	0,99889	0,001	σταθερό

Πίνακας 7.2: Σταθερό έναντι φθίνοντος βήματος. Το η επιλέγεται στο χρονολογικό πρόθεμα και η σύγκριση γίνεται στην ουρά με moving block bootstrap.

Το αποτέλεσμα είναι αρνητικό για τους δύο και **θετικό για τον έναν**. Στον Hedge και τον OGD το σταθερό βήμα χάνει σημαντικά, κατά $+0,000089$ και $+0,000299$ αντίστοιχα. Στον FTRL όμως κερδίζει σημαντικά, κατά $-0,000096$ ($p = 0,001$) — και το κρίσιμο είναι ότι τα δύο σχήματα έχουν *ταυτόσημο* score στο πρόθεμα (0,99828 και τα δύο): η επιλογή δεν προτίμησε το σταθερό για να κολακεύσει την ουρά, το διάλεξε σε ισοπαλία και εκείνο

κέρδισε εκτός δείγματος. Η εξήγηση είναι η ίδια ασυμμετρία που εξηγεί και τις αντίθετες κατευθύνσεις συντονισμού: το η του FTRL πολλαπλασιάζει ολόκληρη τη σωρευμένη απώλεια, όχι την κλίση ενός γύρου, οπότε είναι ο ένας από τους τρεις για τον οποίο «μη φθίνον» σημαίνει κάτι ποιοτικά διαφορετικό.

Η σάρωση χρειάστηκε επέκταση και εδώ, για τον ίδιο λόγο όπως πριν: το ελάχιστο του FTRL καθόταν αρχικά στο κάτω άκρο του πλέγματος. Επεκτεινόμενο ως το 10^{-9} έγινε γνήσια εσωτερικό, και η επέκταση επιβεβαίωσε ταυτόχρονα το θεωρητικό όριο: για $\eta \rightarrow 0$ ο FTRL εκφυλίζεται στον ομοιόμορφο μέσο, και πράγματι στο $\eta = 10^{-9}$ δίνει 0,99882, την τιμή του ομοιόμορφου μέσου στην ουρά.

Ένα μεθοδολογικό σφάλμα που αξίζει να αναφερθεί. Η αρχική σάρωση είχε πλέγμα 1, 2, 5, ..., 1000 και κατέληξε ότι τα Hedge και FTRL είναι «ήδη βέλτιστα στο $\times 1$ ». Το 1 όμως ήταν το κάτω άκρο του πλέγματος, όχι βέλτιστο, και κανείς δεν είχε κοιτάξει αριστερά του. Η επέκταση προς τα κάτω αποκάλυψε γνήσια εσωτερικά ελάχιστα, με κέρδος +0,00013 και +0,00018 αντίστοιχα στην ουρά. Το συμπέρασμα γενικεύεται: όταν η απάντηση μιας σάρωσης βρίσκεται στο άκρο του πλέγματος, το πλέγμα πρέπει να επεκταθεί πριν θεωρηθεί απάντηση.

Η αντίθετη κατεύθυνση έχει δομική εξήγηση. Το η του OGD πολλαπλασιάζει την κλίση ενός γύρου, οπότε η αύξησή του σημαίνει μεγαλύτερη μετακίνηση. Το η του Hedge βρίσκεται σε εκθέτη πάνω στην απώλεια ενός γύρου, οπότε η μείωσή του *μακραίνει τη μνήμη*. Το η του FTRL πολλαπλασιάζει ολόκληρη τη σωρευμένη απώλεια, οπότε η αύξησή του τον καταρρέει προς follow-the-leader.


7.2 Κατάταξη στο πλήρες panel

			φάση	log-loss (raw / cal.)	Brier (raw / cal.)
PSC (Pinnacle)	bookmaker	closing		0,99714 / 0,99685	0,59592 / 0,59577
OGD	αλγόριθμος	—		0,99745 / 0,99693	0,59612 / 0,59586
Hedge	αλγόριθμος	—		0,99842 / 0,99773	0,59674 / 0,59637
FTRL	αλγόριθμος	—		0,99843 / 0,99774	0,59674 / 0,59638
Uniform	baseline	—		0,99886 / 0,99813	0,59703 / 0,59665
VC_BV	bookmaker	opening		1,00075 / 1,00026	0,59833 / 0,59806
WH	bookmaker	opening		1,00119 / 1,00048	0,59860 / 0,59818
PS (Pinnacle)	bookmaker	opening		1,00083 / 1,00055	0,59838 / 0,59824
IW	bookmaker	opening		1,00186 / 1,00061	0,59899 / 0,59826
BW	bookmaker	opening		1,00140 / 1,00065	0,59873 / 0,59833
B365	bookmaker	opening		1,00113 / 1,00073	0,59852 / 0,59832

Πίνακας 7.3: Κατάταξη κατά βαθμονομημένο log-loss, bookmakers με κάλυψη $\geq 70\%$.

Τα ζευγαρωτά τεστ δίνουν:

- Και οι τρεις αλγόριθμοι ξεπερνούν σημαντικά την ομοιόμορφη μέση τιμή: OGD $-0,00141$, Hedge $-0,00044$, FTRL $-0,00043$, όλα $p < 0,001$. Το περιθώριο του OGD είναι περίπου τριπλάσιο.



Σχήμα 7.2: Κάθε σειρά: κενός κύκλος το raw log-loss, γεμάτος το βαθμονομημένο. Η επιλογή dot/slope plot αντί ραβδογράμματος είναι σκόπιμη, καθώς τα log-loss συγκεντρώνονται γύρω από το 1,0 χωρίς ουσιαστικό μηδέν και ένα ραβδόγραμμα με κομμένο άξονα θα μεγεθύνε οπτικά μικροσκοπικές διαφορές.

- Το OGD ξεπερνά σημαντικά τους Hedge ($-0,00097$), FTRL ($-0,00098$) και B365C ($-0,00063$).
- Η βαθμονόμηση βελτιώνει σημαντικά και τις τέσσερις μεθόδους, κατά $+0,00053$ έως $+0,00073$.
- Ο PSC παραμένει σημαντικά μπροστά από το OGD σε αυτή τη διαμόρφωση: $+0,00043$ βαθμονομημένο, $p < 0,001$, στους 71.818 κοινούς αγώνες.

Μια αναγκαία επιφύλαξη. Το κατώφλι κάλυψης 70% αφήνει μέσα έναν μόνο closing bookmaker, τον PSC, επειδή οι υπόλοιπες closing στήλες αρχίζουν γύρω στο 2019/20 και ο B365C χάνει οριακά με 69,6%. Η διατύπωση «ξεπερνάμε όλους εκτός του PSC» σημαίνει επομένως, *εδώ*, ότι ξεπερνάμε έξι τιμές ανοίγματος. Η ουσιαστική σύγκριση απέναντι σε τιμές κλεισίματος γίνεται στις §7.7 και §7.8.

Σημειώνεται ότι η Interwetten καταλαμβάνει την *τελευταία* θέση της κατάταξης σε raw log-loss (1,00186) παρότι έχει την έβδομη καλύτερη κάλυψη. Η προσθήκη της κάνει επομένως τη διατύπωση «ξεπερνάμε όλους εκτός του PSC» κάπως ευκολότερη, και γι' αυτό η ουσιαστική σύγκριση παραμένει αυτή απέναντι στους PSC και B365C.

Σημειώνεται επίσης ότι το log-loss και το Brier δίνουν σχεδόν ταυτόσημη σειρά, με μόνη εξαίρεση τις δύο τελευταίες θέσεις. Η accuracy δίνει άλλη σειρά, αλλά καμία διαφορά της δεν είναι στατιστικά σημαντική — αναμενόμενο, αφού δεν είναι κατάλληλος κανόνας βαθμολόγησης.

7.3 Ποιο panel


	opening (13)		όλα (26)		closing (13)	
	απλή	Shin	απλή	Shin	απλή	Shin
OGD	1,00076	1,00024	0,99745	0,99709	0,99722	0,99689
Hedge	1,00088	1,00033	0,99842	0,99781	0,99762	0,99714
FTRL	1,00088	1,00033	0,99843	0,99782	0,99761	0,99714
Uniform	1,00080	1,00022	0,99886	0,99824	0,99748	0,99703

Πίνακας 7.4: Log-loss ανά panel και μέθοδο de-vig.

Η διάταξη closing < όλα < opening ισχύει σε κάθε κελί, και στις 24 συγκρίσεις (4 αλγόριθμοι $\times$ 3 συγκρίσεις $\times$ 2 κανονικοποιήσεις) η διαφορά είναι στατιστικά σημαντική. Ότι οι τιμές κλεισίματος υπερέχουν των ανοιγμάτων είναι αναμενόμενο. Το μη αναμενόμενο είναι ότι το closing-only panel ξεπερνά και το *πλήρες*: οι opening bookmakers δεν λειτουργούν ως χρήσιμη διαφοροποίηση αλλά ως καθαρό βάρος στο μείγμα.

Η σύγκριση κάθε αλγορίθμου με τον απλό μέσο όρο *μέσα* στο ίδιο panel εξηγεί τον μηχανισμό και αποτελεί, κατά τη γνώμη μας, το γενικότερα χρησιμότερο εύρημα της εργασίας:

- Στο *πλήρες* panel και οι τρεις αλγόριθμοι κερδίζουν σημαντικά τον μέσο όρο.
- Στα *περιορισμένα* panel οι Hedge και FTRL *χάνουν* σημαντικά από τον μέσο όρο, σε 8 από 8 τεστ. Το OGD κερδίζει στο closing και ισοπαλεί στο opening.



Σχήμα 7.3: Σύγκριση των τριών panel για κάθε αλγόριθμο. Η διάταξη $\text{closing} < \text{full panel} < \text{opening}$ ισχύει σε κάθε περίπτωση.


Το πλήρες panel περιέχει 13 καλούς closing και 13 συστηματικά χειρότερους opening experts, δηλαδή σαφή ποιοτική διαφορά προς εκμάθηση. Σε ομοιογενές panel η διαφορά αυτή λείπει, και για δύο από τους τρεις αλγορίθμους η προσαρμογή κοστίζει περισσότερο απ' όσο αποδίδει.

7.4 Πού ακριβώς υπερέχουν οι τιμές κλεισίματος

Η προηγούμενη ενότητα δείχνει ότι το closing panel κερδίζει κατά $\sim 0,0035$ σε log-loss. Αυτό είναι μέσος όρος, και η Παρατήρηση 3.4 κάνει αυστηρότερη πρόβλεψη: αν η υπεροχή οφείλεται στην άφιξη πληροφορίας, πρέπει να συγκεντρώνεται εκεί όπου η τιμή *όντως* κινήθηκε. Για να ελεγχθεί, κάθε αγώνας χαρακτηρίζεται από την απόσταση ολικής μεταβολής ανάμεσα στην αρχική και την τελική πιθανοτική κατανομή κάθε οίκου, μέσο όρο πάνω στα 13 διαθέσιμα ζεύγη opening/closing, και οι αγώνες χωρίζονται σε πεμπτημόρια.

Πεμπτημόριο κίνησης	Q1	Q2	Q3	Q4	Q5
Μέση κίνηση	0,0082	0,0144	0,0215	0,0324	0,0598
log-loss opening	0,99161	1,00581	1,00068	1,00666	1,00790
log-loss closing	0,99118	1,00509	0,99868	1,00214	0,99632
closing – opening	-0,00044	-0,00072	-0,00200	-0,00452	-0,01158
<i>p</i>	0,052	0,050	< 0,001	< 0,001	< 0,001

Πίνακας 7.5: Πλεονέκτημα κλεισίματος ανά πεμπτημόριο κίνησης της γραμμής, 10.649–10.650 αγώνες ανά πεμπτημόριο.



Σχήμα 7.4: Αριστερά η στρωμάτωση κατά κίνηση της γραμμής, δεξιά κατά ανωμαλία του z του Shin.

Η πρόβλεψη επιβεβαιώνεται, με διαβάθμιση 26 φορών. Το πλεονέκτημα του κλεισίματος πηγαίνει από $-0,00044$ στο ήσυχο πέμπτο των αγώνων σε $-0,01158$ στο θορυβώδες. Στο Q1 μάλιστα δεν είναι καν στατιστικά σημαντικό ($p = 0,052$): στο ένα πέμπτο των αγώνων όπου η γραμμή σχεδόν δεν κινήθηκε, δεν υπάρχει μετρήσιμο πλεονέκτημα κλεισίματος. Η «υπεροχή των τιμών κλεισίματος» δεν είναι επομένως γενική ιδιότητα των τελικών τιμών αλλά φαινόμενο του άνω πεμπτημορίου.

Μια αναγκαία επιφύλαξη. Η κίνηση μετρείται από τις ίδιες τιμές κλεισίματος που χρησιμοποιεί το closing panel, οπότε το μηδενικό αποτέλεσμα του Q1 είναι εν μέρει μηχανικό: αν οι δύο τιμές σχεδόν ταυτίζονται, τα δύο μείγματα δεν μπορούν να διαφέρουν πολύ. Το μη τετριμμένο σκέλος είναι η κατεύθυνση στο άλλο άκρο. Μια μεγάλη κίνηση θα μπορούσε κάλλιστα να πηγαίνει προς τη λάθος μεριά· το ότι η μεταγενέστερη τιμή είναι συστηματικά η καλύτερη κατά $0,0116$ είναι ακριβώς ο ισχυρισμός αποδοτικότητας της αγοράς, εντοπισμένος εκεί όπου πράγματι λειτουργεί. Χρήσιμος έλεγχος: η δυσκολία των αγώνων δεν είναι μονότονη στα πεμπτημόρια (το log-loss του πλήρους panel πηγαίνει $0,99120, 1,00510, 0,99877, 1,00241, 0,99683$), ενώ το πλεονέκτημα είναι, οπότε η διαβάθμιση δεν είναι τεχνούργημα του τύπου «δυσκολότεροι αγώνες, μεγαλύτερες διαφορές».

Το z του Shin είναι πολύ ασθενέστερος δείκτης. Στρωματώνοντας αντ' αυτού κατά την ανωμαλία του z — ποσότητα που το §3.4 ταυτίζει με την εκτιμώμενη αναλογία πληροφορημένων — η διαβάθμιση είναι μόλις $-0,00295$ έως $-0,00498$, δηλαδή παράγοντας $1,7$ έναντι 26 , με όλα τα πεμπτημόρια σημαντικά. Το z δηλαδή ανιχνεύει κάτι, αλλά η πραγματική κίνηση της τιμής είναι ασύγκριτα καθαρότερος δείκτης του ότι έφτασε πληροφορία — εύλογο, αφού το z εκτιμάται από μία στιγμή της αγοράς ενώ η κίνηση παρατηρεί τη διαφορά δύο.


7.5 Η διαμόρφωση που επιλέγεται

Τρεις βελτιώσεις είχαν μετρηθεί χωριστά — το διορθωμένο βήμα, το closing-only panel, το Shin — και συνδυάζονται εδώ. Κάθε διαμόρφωση βαθμολογείται στους ίδιους

71.818 αγώνες, την τομή όλων με τον PSC, σύμφωνα με την αρχή του §5.5.

Διαμόρφωση	πλήρες	train	ουρά 25%
PSC μόνος του	0,99685	0,99746	0,99502
closing-only + Shin	0,99692	0,99754	0,99507
closing-only, αναλογική	0,99693	0,99756	0,99506
closing-only + Shin, χωρίς μονής σεζόν	0,99692	0,99754	0,99509
πλήρες panel, αναλογική	0,99728	0,99801	0,99508
πλήρες panel, Shin	0,99731	0,99804	0,99512

Πίνακας 7.6: Βαθμονομημένο log-loss του OGD ανά διαμόρφωση, ίδιοι 71.818 αγώνες παντού.



Σχήμα 7.5: Οι διαμορφώσεις στην ουρά ελέγχου, με τον PSC ως γραμμή αναφοράς. Όλες συγκεντρώνονται εντός 0,00005.

- **Το panel κάνει όλη τη δουλειά.** Η closing-only + Shin ξεπερνά το πλήρες panel κατά $-0,00036$ ($p < 0,001$), και η closing-only με αναλογική κανονικοποίηση κατά $-0,00034$ ($p < 0,001$).
- **Το Shin μόνο του δεν προσφέρει τίποτα μετρήσιμο** πάνω στο πλήρες panel ($+0,00004$, $p = 0,181$) – συνεπές με το ότι Shin και temperature scaling διορθώνουν το ίδιο favorite-longshot bias, οπότε το δεύτερο απορροφά το πρώτο.
- **Έναντι του PSC:** το πλήρες panel χάνει σημαντικά ($+0,00043$, $p < 0,001$), ενώ η closing-only + Shin *ισοπαλεί* ($+0,00007$, $p = 0,234$) και η closing-only με αναλογική επίσης ($+0,00009$, $p = 0,143$).


Η ουρά 25% δεν αναδεικνύει νικητή: και οι έξι γραμμές μαζεύονται σε λιγότερο από 0,00005. Επιβεβαιώνει δηλαδή την ισοπαλία, και δεν θα ήταν έντιμο να παρουσιαστεί ως νίκη. Σημειώνεται επίσης ότι σε κάθε closing διαμόρφωση ο PSC βρίσκεται μέσα στο μείγμα: το «φτάνουμε τον PSC» διαβάζεται «το μείγμα φτάνει το καλύτερο μέλος του».

7.6 Χωρίς την Pinnacle

Το προφανές αντεπιχείρημα είναι ότι το μείγμα απλώς αναπαράγει την Pinnacle, που ούτως ή άλλως βρίσκεται μέσα του. Αφαιρώντας και τις δύο στήλες της και επανεκπαιδεύοντας από την αρχή σε τρία panel:

Panel	Θέση OGD	log-loss	Πρώτος	Ζευγαρωτά
πλήρες (24)	#3 από 9	0,99782	FTRL 0,99771	5 νίκες, 0 ήττες
closing-only (12)	#1 από 9	0,99919	OGD (ο ίδιος)	3 νίκες, 2 ισοπαλίες
opening-only (12)	#5 από 9	0,99999	VC_BV 0,99987	3 νίκες, 1 ήττα, 1 ισοπαλία

Πίνακας 7.7: Κάθε panel επανεκπαιδεύεται από την αρχή και συγκρίνεται με τους bookmakers της δικής του φάσης.



Σχήμα 7.6: Πλήρες panel χωρίς καμία στήλη Pinnacle. Και οι τέσσερις μέθοδοι βρίσκονται πάνω από όλους τους εναπομείναντες bookmakers.

Στο πλήρες panel το αποτέλεσμα αντέχει άνετα: και οι τέσσερις μέθοδοι βρίσκονται πάνω από όλους τους bookmakers, και το OGD κερδίζει σημαντικά και τους πέντε, με

περιθώρια $-0,00181$ (VC_BV) έως $-0,00315$ (IW) και $p < 0,001$ παντού. Όλοι τους όμως είναι opening.

Στα δύο ομοιογενή panel το αποτέλεσμα αλλάζει. Στο closing το OGD κερδίζει τρεις (WHC $-0,00088$, IWC $-0,00077$, BWC $-0,00051$) και ισοπαλεί με τους B365C ($p = 0,505$) και VC_BVC ($p = 0,284$). κατατάσσεται μεν πρώτο, αλλά με τον απλό μέσο όρο δεύτερο σε απόσταση $0,00002$, δηλαδή πρακτικά αδιάκριτο. Στο opening κερδίζει πάλι τρεις, ισοπαλεί με τον B365 ($p = 0,203$), αλλά **χάνει σημαντικά από τον VC_BV** ($+0,00030$, $p = 0,004$) — η μόνη περίπτωση σε όλη την εργασία όπου μας ξεπερνά σημαντικά *bookmaker* εκτός της Pinnacle, και εκεί ο απλός μέσος όρος περνάει μπροστά από το OGD. Η διατύπωση περιορίζεται σκόπιμα στους bookmakers: στον έλεγχο ανάπτυξης (§7.8) μας ξεπερνά σημαντικά και το Betfair Exchange, που όμως δεν είναι bookmaker αλλά ανταλλακτήριο.

Το μοτίβο είναι αρκετά σταθερό ώστε να μην αποδοθεί στην τύχη, και επαναλαμβάνει το εύρημα του §7.3: μόλις φύγει η Pinnacle, οι υπόλοιποι της ίδιας φάσης μοιάζουν τόσο πολύ μεταξύ τους που δεν απομένει ποιοτική διαφορά προς εκμάθηση. Η διαμόρφωση που επιλέγεται είναι λοιπόν η καλύτερη εν μέρει *επειδή* περιέχει τον καλύτερο odds-setter της αγοράς.


7.7 Πρόσφατο παράθυρο

Το κατώφλι κάλυψης ορίζεται από τη δεκαετία, γεγονός που ευνοεί όποιον έδινε αποδόσεις παλιά. Περιορίζοντας στις τελευταίες πέντε σεζόν (38.749 αγώνες), οι B365C, BWC, VC_BVC και WHC περνούν όλοι το κατώφλι και η απαιτητική σύγκριση γίνεται δυνατή.

#	Σειρά	φάση	log-loss
1	PSC	closing	0,99439
2	OGD	—	0,99495
3	VC_BVC	closing	0,99498
4	WHC	closing	0,99502
5	BWC	closing	0,99504
6	B365C	closing	0,99543
7	Uniform	—	0,99591
8	Hedge	—	0,99604
9	FTRL	—	0,99607
10–14	WH, PS, VC_BV, BW, B365	opening	0,99771 και κάτω

Πίνακας 7.8: Τελευταίες πέντε σεζόν, πλήρες panel, βαθμονομημένο log-loss.

Το OGD βρίσκεται στη θέση #2, μπροστά από κάθε closing bookmaker πλην της Pinnacle, και η διαφορά από τον PSC συρρικνώνεται σε $+0,00036$ ($p = 0,014$) από $+0,00043$ της δεκαετίας. Δύο ευρήματα όμως *αντιστρέφονται* και αναφέρονται ρητά: οι Hedge και FTRL χάνουν από τον απλό μέσο όρο σε όλα τα panel εδώ, όχι μόνο στα περιορισμένα ($+0,00012$ και $+0,00015$, $p = 0,006$ και $p = 0,002$), και το log-loss με το Brier παύουν να συμφωνούν στη σειρά.




Σχήμα 7.7: Τελευταίες πέντε σεζόν. Οι closing bookmakers περνούν πλέον το κατώφλι κάλυψης και η σύγκριση γίνεται απαιτητικότερη.

7.8 Έλεγχος ανάπτυξης

Ο έλεγχος με πραγματική χρονική τομή: προσαρμογή σε 65.009 γύρους ως 31/12/2024, μέτρηση σε 11.574 γύρους του 2025–26, από τους οποίους 8.151 κοινοί.

#	Σειρά	φάση	log-loss
1	BFEC (Betfair Exchange)	closing	1,00040
2	OGD closing-only, online	—	1,00110
3	OGD πλήρες panel, online	—	1,00129
4	BWC	closing	1,00146
5	OGD closing-only, παγωμένο	—	1,00151
6	B365C	closing	1,00165
7	OGD πλήρες panel, παγωμένο	—	1,00183
8–10	B365, BW, BFE	opening	1,00371 – 1,00758

Πίνακας 7.9: Εκπαίδευση ως 31/12/2024, μέτρηση στο 2025–26.



Σχήμα 7.8: Έλεγχος ανάπτυξης. Οι τιμές ανοίγματος βρίσκονται σαφώς χαμηλότερα, ενώ οι τιμές κλεισίματος και οι παραλλαγές του μείγματος συγκεντρώνονται.

- Κάθε τιμή ανοίγματος κερδίζεται σημαντικά, σε κάθε παραλλαγή: $-0,0019$ έως $-0,0065$, όλα $p \leq 0,019$.
- Οι τιμές κλεισίματος δεν κερδίζονται. Το βέλτιστο αποτέλεσμα είναι ισοπαλία και με τις τρεις, και μόνο στην παραλλαγή closing-only / online: B365C $p = 0,193$,

BWC $p = 0,361$, BFEC $p = 0,052$. Στις παραλλαγές πλήρους panel το BFEC μάς κερδίζει σημαντικά (+0,00089, $p = 0,013$ online· +0,00143, $p = 0,002$ παγωμένο), οπότε η ισοπαλία με κάθε τιμή κλεισίματος ισχύει μόνο για τη closing-only παραλλαγή.

- Η online παραλλαγή κερδίζει σταθερά την παγωμένη (1,00110 έναντι 1,00151), οπότε η ακριβής διατύπωση δεν είναι «εκπαιδεύτηκε ως το 2024» αλλά «τρέχει συνεχώς».

Η Pinnacle σε αυτό το παράθυρο. Η κάλυψή της πέφτει στο 59% μετά το 2025 και σταματάει να δίνει αποδόσεις στις 14/01/2026, οπότε δεν περνάει το κατώφλι. Επιβάλλοντάς την στον κοινό πίνακα, οι κοινοί αγώνες πέφτουν από 8.151 σε 2.860 και κανένα αποτέλεσμα δεν παραμένει σημαντικό. Συγκρίνεται επομένως ένα προς ένα, στους δικούς της γύρους: τον PS τον κερδίζουμε σημαντικά ($-0,0022$ έως $-0,0023$, p από 0,007 ως 0,019, σε 6.857 αγώνες) και με τον PSC ισοπαλούμε (p από 0,532 ως 0,796, σε 6.892 αγώνες).

Αξίζει να σημειωθεί ότι ο καλύτερος προγνώστης σε αυτό το παράθυρο δεν είναι bookmaker αλλά το Betfair Exchange: ανταλλακτήριο όπου οι παίκτες στοιχηματίζουν μεταξύ τους, δηλαδή τιμή αγοράς χωρίς περιθώριο διαχειριστή.

7.9 Value betting και το μαθαινόμενο μέγεθος στοιχήματος


Προσομοίωση Kelly με βαθμονομημένες πιθανότητες και panel ταιριασμένο στη φάση του στόχου. Το μέγεθος του στοιχήματος δεν καθιλώνεται σε σταθερό κλάσμα αλλά μαθαίνεται online, με τον πολλαπλασιαστή του §3.16· ο σταθερός συντελεστής $\frac{1}{4}$ κρατιέται ως σημείο αναφοράς.

Έλεγχος ορθότητας και επιλογή. Σταθερό $\lambda = 0,25$ αναπαράγει ακριβώς την υλοποιημένη προσομοίωση, σε κάθε γύρο ανάπτυξης και στο ίδιο σύνολο στοιχημάτων, οπότε ο μαθαινόμενος πολλαπλασιαστής είναι η μόνη διαφορά μεταξύ των στηλών που ακολουθούν. Το ρυθμό, την αρχική τιμή και το άνω όριο του λ τα επιλέγουμε σε χρονολογικό πρόθεμα 75% των στοιχημάτων, από κοινού για όλους τους στόχους, και η υπόλοιπη ουρά μένει έξω από την επιλογή. Τίποτα από τα δύο προηγούμενα στάδια δεν ξανασυντονίζεται εδώ.

Η επιλογή δίνει $\lambda_0 = 0,5$ και $\lambda_{\max} = 1,5$ για το Online Newton Step, με ουρά +0,000106 σε λογαριθμικό ρυθμό ανά στοιχείο, και $\lambda_0 = 0,25$, $\lambda_{\max} = 1$ για τον OGD, με ουρά +0,000101. Αξίζει να σημειωθεί ένα σημείο που έρχεται σε αντίθεση με κάθε άλλο συντονισμό της εργασίας: το Online Newton Step επιλέγει πολλαπλασιαστή ρυθμού ίσο με 1, δηλαδή η σταθερά που δίνει η θεωρία δεν χρειάζεται καμία διόρθωση, ενώ ο OGD χρειάζεται $\times 10$ και σε μία ρύθμιση το πλέγμα φεύγει στην ακμή χωρίς να σταθεροποιηθεί. Όπου η δομή της απώλειας αξιοποιείται σωστά, το a-priori φράγμα αποδεικνύεται και σωστά βαθμονομημένο.

Εναντίον	Στοιχ.	Kelly $\frac{1}{4}$	OCO λ	Kelly πλήρες	μέσο λ
WHC	7.253	84,2×	6.494×	29.342×	0,79
BWC	6.920	3,09×	7,08×	13,77×	0,62
VC_BVC	4.561	1,58×	1,54×	1,74×	0,57
B365C	7.643	1,05×	0,67×	0,24×	0,39
PSC	19.497	0,54×	0,25×	0,0035×	0,37

Πίνακας 7.10: Τελικό κεφάλαιο με αρχή 1, βαθμονομημένες πιθανότητες, απλή κανονικοποίηση. Κάθε στήλη παίζει τα ίδια στοιχήματα, αφού η επιλογή ενδεχομένου δεν εξαρτάται από το μέγεθος. Η τελευταία στήλη είναι ο μέσος πολλαπλασιαστής που έμαθε το Online Newton Step.



Σχήμα 7.9: Πάνω, η πορεία του κεφαλαίου· κάτω, η τροχιά του μαθαινόμενου λ με στική γραμμή στο ισχύον $\frac{1}{4}$.

Το αποτέλεσμα έχει δύο σκέλη που δεν λένε το ίδιο. Στον ζευγαρωμένο έλεγχο ανά στοιχείο ο μαθαίνόμενος πολλαπλασιαστής **ισοπαλεί** με το σταθερό $\frac{1}{4}$: σε είκοσι κελιά (δύο κανονικοποιήσεις $\times$ δύο στάδια $\times$ πέντε στόχοι) προκύπτουν 17 ισοπαλίες, δύο νίκες και μία ήττα. Στο τελικό κεφάλαιο είναι μπροστά σε δύο από τους πέντε στόχους, και στον WHC κατά εβδομήντα επτά φορές. Τα δύο συμβιβάζονται αριθμητικά: η διαφορά ανά στοιχείο είναι +0,00060, μικροσκοπική, αλλά ανατοκίζεται σε 7.253 στοιχήματα, ενώ η αβεβαιότητα παραμένει αρκετά πλατιά ώστε ο έλεγχος να μην την πιστοποιεί ($p = 0,099$). Είναι το ίδιο μοτίβο με το αποτέλεσμα του «σκληρού» άγκυρα-bookmaker: συστηματική υπεροχή στο σημειακό μέγεθος, χωρίς στατιστική πιστοποίηση.

Τι μαθαίνει ο πολλαπλασιαστής. Κάθεται σχεδόν παντού πάνω από το $\frac{1}{4}$, και η τιμή του παρακολουθεί το πόσο κερδοφόρος είναι ο στόχος: 0,37 στον ζημιογόνο PSC, 0,79 στον κερδοφόρο WHC. Ανεβάζει δηλαδή το ρίσκο όπου υπάρχει περιθώριο και το μαζεύει όπου δεν υπάρχει — συμπεριφορά που καμία σταθερά δεν μπορεί να εκφράσει, και η οποία προκύπτει χωρίς να του δοθεί καμία πληροφορία για το ποιος είναι ο αντίπαλος.

Η διατύπωση ήταν το πρόβλημα, όχι η ιδέα. Η ίδια ερώτηση είχε τεθεί νωρίτερα με τον μαθητή να μαθαίνει απευθείας το κλάσμα του κεφαλαίου. Εκείνη η εκδοχή έχανε συστηματικά: 9 ήττες στα 20 κελιά, καμία νίκη. Η αιτία είναι ακριβώς αυτή που προβλέπει το §3.16 — ο comparator «καλύτερο σταθερό ποντάρισμα» δεν περιέχει τον κλειστό τύπο, και ο μαθητής πετά το $\hat{p}_t$ που τα δύο προηγούμενα στάδια μόλις παρήγαγαν. Αλλάζοντας μόνο το τι μαθαίνεται, με τα ίδια δεδομένα και τον ίδιο έλεγχο, το αποτέλεσμα περνά από συστηματική ήττα σε ισοπαλία με σημειακή υπεροχή.

Παράπλευρο εύρημα: το $\frac{1}{4}$ είναι υπερβολικά συντηρητικό. Το πλήρες Kelly ισοπαλεί σε 16 από τα 20 κελιά, κερδίζει σε 2 και χάνει μόνο σε 2. Ο κίνδυνός του συγκεντρώνεται σχεδόν ολόκληρος στον PSC, όπου μηδενίζει το κεφάλαιο (0,0035). Στους κερδοφόρους στόχους δηλαδή το σταθερό $\frac{1}{4}$ αφήνει σημαντικό μέρος της ανάπτυξης αχρησιμοποίητο. Ο μαθαινόμενος πολλαπλασιαστής είναι ο ενδιάμεσος δρόμος: κρατά το μεγαλύτερο μέρος της ανόδου και αποφεύγει την καταστροφή.

Πού υπάρχει άκρη. Το ποιοι bookmakers είναι καν κερδίσιμοι χαρτογραφείται σε δέκα στόχους με το σταθερό $\frac{1}{4}$, ώστε οι γραμμές να παραμένουν συγκρίσιμες μεταξύ τους.

Εναντίον	Φάση	Στοιχ.	Κεφάλαιο	p	
WHC	closing	6.565	38,52×	< 0,001	κέρδος
IW	opening	7.443	7,89×	0,008	κέρδος
BWC	closing	6.607	1,81×	0,247	—
WH	opening	5.931	1,38×	0,545	—
BW	opening	7.841	1,09×	0,820	—
VC_BVC	closing	4.653	0,75×	0,455	—
VC_BV	opening	8.083	0,60×	0,245	—
B365C	closing	7.970	0,58×	0,328	—
B365	opening	10.829	0,41×	0,101	—
PS	opening	26.675	0,26×	0,055	—
PSC	closing	39.997	0,0002×	< 0,001	ζημιά

Πίνακας 7.11: Η στήλη p αφορά τον μέσο λογαριθμικό ρυθμό ανά στοίχημα. Τα τελικά κεφάλαια δεν συγκρίνονται μεταξύ γραμμών, αφού ο αριθμός στοιχημάτων διαφέρει κατά τάξη μεγέθους.

Σε έντεκα bookmakers προκύπτουν δύο σημαντικά κέρδη — και οι δύο απέναντι σε «μαλακούς», recreational-facing οίκους — και μία σημαντική ζημιά, απέναντι στον PSC, που είναι ο καλύτερος προγνώστης του panel και επομένως ακριβώς ο αντίπαλος απέναντι στον οποίο ένα κατώτερο μοντέλο οφείλει να χάνει. Ο έλεγχος λειτουργεί δηλαδή και προς τις δύο κατευθύνσεις. Η αντιστοίχιση φάσης είναι ουσιώδης: με το πλήρες panel αντί για το closing-only, το αποτέλεσμα χειροτερεύει σε *κάθε* έναν από τους closing στόχους.

Η επέκταση στους στόχους ανοίγματος. Ο μαθαινόμενος πολλαπλασιαστής εφαρμόζεται και στους έξι opening στόχους, με το αντίστοιχο opening-only panel. Η απαίτηση αιτιότητας είναι εδώ αυστηρότερη: δεν αρκεί να φύγει ο στόχος, πρέπει να φύγει *ολόκληρη* η closing πλευρά, αφού καμία τιμή κλεισίματος δεν υπάρχει τη στιγμή που τοποθετείται το στοίχημα. Οι υπερπαραμέτροι επιλέγονται χωριστά ανά φάση, στο δικό της πρόθεμα στοιχημάτων, ώστε το αποτέλεσμα των opening να μην εξαρτάται από στοιχήματα των closing.

Εναντίον	Στοιχ.	Kelly $\frac{1}{4}$	OCO λ	Kelly πλήρες	μέσο λ
IW	7.443	7,89×	64,4×	109,6×	0,67
WH	5.931	1,38×	1,39×	0,78×	0,28
BW	7.841	1,09×	1,10×	0,50×	0,45
VC_BV	8.083	0,60×	0,67×	0,03×	0,17
B365	10.829	0,41×	0,61×	0,007×	0,12
PS	26.675	0,26×	0,68×	0,0003×	0,05

Πίνακας 7.12: Στόχοι ανοίγματος: τελικό κεφάλαιο με αρχή 1, βαθμονομημένες πιθανότητες, απλή κανονικοποίηση. Η στήλη OCO λ δίνει την καλύτερη από τις δύο παραλλαγές (ONS / OGD) και το μέσο λ αντιστοιχεί σε αυτήν.

Το εύρημα είναι ότι ο μαθαίνόμενος πολλαπλασιαστής αποδίδει *περισσότερο* στα ανοίγματα παρά στα κλεισίματα: 8 νίκες και 2 ήττες σε 48 ζευγαρωμένους ελέγχους, έναντι 4 νικών και 3 ηττών στα κλεισίματα. Σημαντικές νίκες προκύπτουν απέναντι στους PS ($p < 0,001$), IW ($p = 0,027$) και VC_BV ($p = 0,009$), ενώ οι δύο ήττες είναι μικροσκοπικές ($-0,000028$ και $-0,000080$).

Πιο ενδιαφέρον από το αποτέλεσμα είναι ο *μηχανισμός*, που εδώ γίνεται ορατός. Το μέσο λ κατατάσσει τους στόχους σχεδόν τέλεια κατά το πόσο είναι νικήσιμοι, χωρίς να δοθεί στον αλγόριθμο καμία πληροφορία για το ποιος είναι ο αντίπαλος: στον IW, τον μόνο κερδοφόρο στόχο ανοίγματος, ανεβάζει το λ στο 0,67, δηλαδή σχεδόν στο πλήρες Kelly· στον PS, τον σκληρότερο, το κατεβάζει στο 0,05 και ουσιαστικά σταματά να στοιχηματίζει — υπερδιπλασιάζοντας έτσι το κεφάλαιο που επιβιώνει, από $0,26 \times$ σε $0,68 \times$. Τα λ των ανοιγμάτων (0,05–0,75) είναι συστηματικά χαμηλότερα από εκείνα των κλεισιμάτων (0,17–0,79): η αγορά ανοίγματος είναι δυσκολότερη και ο αλγόριθμος το ανακαλύπτει μόνος του.

Το ίδιο φαίνεται και από την αντίθετη πλευρά. Το *πλήρες Kelly*, που στα κλεισίματα ισοπαλούσε (2 νίκες, 2 ήττες), στα ανοίγματα καταρρέει: **11 σημαντικές ήττες έναντι 2 νικών**. Η πλευρά του ανοίγματος χρειάζεται δηλαδή πραγματικά συρρίκνωση, και το ερώτημα δεν είναι αν θα επιβληθεί αλλά πόση — που είναι ακριβώς το ερώτημα στο οποίο ένας σταθερός συντελεστής $\frac{1}{4}$ δεν μπορεί να απαντήσει και ένας μαθαίνόμενος μπορεί.

Το συμπέρασμα είναι ότι το βελτιωμένο log-loss δεν μεταφράζεται σε κερδοφορία. Η διαφορά ποιότητας που κερδήθηκε είναι μικρότερη από το περιθώριο της αγοράς, και όποια άκρη υπάρχει αφορά *συγκεκριμένους* bookmakers, όχι στρατηγική που δουλεύει γενικά. Το μέγεθος του στοιχήματος είναι ορθογώνιο σε αυτό: αλλάζει πόσο γρήγορα μεγαλώνει το κεφάλαιο εκεί που άκρη υπάρχει, και πόσο γρήγορα χάνεται εκεί που δεν υπάρχει, χωρίς να δημιουργεί άκρη από το μηδέν.

7.10 Πόση πληροφορία χρειάζεται η μάθηση; Το bandit πείραμα


Όλα τα προηγούμενα προϋποθέτουν πλήρη πληροφόρηση: μετά από κάθε αγώνα βαθμολογούνται και οι 26 bookmakers. Το ερώτημα του §3.12 είναι τι απομένει όταν ο αλγόριθμος βλέπει μόνο *έναν* αριθμό τον γύρο, την απώλεια της δικής του πρόβλεψης. Υλοποιούνται οι δύο εκτιμητές κλίσης, ενός και δύο σημείων, με τα ξ και το βήμα επιλεγμένα

στο ίδιο χρονολογικό train prefix με κάθε άλλη υπερπαράμετρο, και δέκα διαφορετικούς σπόρους τυχαιότητας, αφού ο αλγόριθμος είναι στοχαστικός.

Δύο έλεγχοι ορθότητας προηγούνται. Με πλήρη πληροφόρηση και γραμμικοποιημένη απώλεια ο κώδικας αναπαράγει ακριβώς τον υλοποιημένο OGD, και ο εκτιμητής δύο σημείων ταυτοποιείται με την αληθινή εφαπτομενική κλίση με σχετικό σφάλμα 0,6% και συνημίτονο 0,99998 πάνω σε 200.000 δείγματα.

Σειρά	Βαθμ. log-loss	Raw log-loss	Διαφορά
OGD, πλήρης πληρ., ακριβής κλίση	0,996928	0,997455	+0,000002
OGD, πλήρης πληρ., γραμμικοποίηση	0,996926	0,997454	—
BGD δύο σημείων ($\xi = 0,0003$)	0,997368	0,998004	+0,000443
Χωρίς μάθηση ($\eta = 0$)	0,997632	0,998296	+0,000707
BGD ενός σημείου ($\xi = 0,02$)	0,997631	0,998297	+0,000706
Ομοιόμορφος μέσος	0,998132	0,998862	+0,001206

Πίνακας 7.13: Bandit έναντι πλήρους πληροφόρησης, ίδιοι 76.584 γύροι, ίδιο calibration. Η τελευταία στήλη είναι η ζευγαρωμένη διαφορά από τον υλοποιημένο OGD στο βαθμονομημένο log-loss· θετική σημαίνει χειρότερο από αυτόν. Η πρώτη γραμμή είναι ισοπαλία ($p = 0,823$), οι υπόλοιπες σημαντικές σε $p < 0,001$.



Σχήμα 7.10: Αριστερά, το προφίλ του βήματος πάνω στο οποίο γίνεται η επιλογή· δεξιά, η τελική σύγκριση.

Ο έλεγχος που κάνει τους αριθμούς ερμηνεύσιμους. Η προφανής ανάγνωση — «το BGD ξεπερνά τον ομοιόμορφο μέσο, άρα η bandit ανάδραση του δίδαξε κάτι» — είναι λανθασμένη, και η εργασία την έκανε σε πρώτη γραφή πριν τη διορθώσει. Υπό την αναγωγή Sleeping Experts το διάνυσμα βαρών κινείται ακόμη και με μηδενικό βήμα: κάθε φορά που αλλάζει το σύνολο των ξύπνιων, η μόνιμη κατάσταση επαναπροβάλλεται σε simplex άλλης διάστασης, και αυτή η αναταραχή από μόνη της παράγει μη ομοιόμορφα βάρη. Μετρημένο απευθείας: στο $\eta = 0$ τα βάρη απέχουν ως 0,69 από το ομοιόμορφο σε νόρμα μεγίστου. Ο σωστός συγκριτικός δείκτης δεν είναι επομένως ο ομοιόμορφος μέσος αλλά ο ίδιος ο αλγόριθμος με το βήμα στο μηδέν: ίδια συρρίκνωση, ίδιες διαταραχές, ίδια

δυναμική προβολής, καμία μάθηση. Ό,τι βρίσκεται ανάμεσα στον έλεγχο αυτόν και στο BGD είναι ό,τι αγόρασε πράγματι το bandit σήμα.

	Προβολή χωρίς μάθηση	+ bandit μάθηση
BGD δύο σημείων	+0,000500 (41,4%)	+0,000264 (21,9%)
BGD ενός σημείου	+0,000501 (41,5%)	−0,000000 (0,0%)

Πίνακας 7.14: Διάσπαση του περιθωρίου πλήρους πληροφόρησης (ομοιόμορφος μέσος 0,998132 προς OGD 0,996926, δηλαδή 0,001206) σε ό,τι δίνει η προβολή χωρίς καμία μάθηση και σε ό,τι προσθέτει από πάνω η bandit ανάδραση.

Ο εκτιμητής ενός σημείου δεν μαθαίνει τίποτα εδώ. Η επιλογή στο train οδηγεί το βήμα του στο $1,4 \cdot 10^{-14}$, και ολόκληρη η περιοχή από 10^{-14} ως $9 \cdot 10^{-11}$ ισοβαθεί στο ίδιο train score 0,998375: πρόκειται για το οροπέδιο της μη μάθησης, και ο επιλογέας απλώς παίρνει το άκρο του. Κάθε θετική ποσότητα μάθησης βλέπτει. Η αιτία ποσοτικοποιείται από την ευθυγράμμιση της εκτίμησης ενός γύρου με την αληθινή κλίση: για τον εκτιμητή δύο σημείων το μέσο συνημίτονο είναι +0,27, ενώ για τον εκτιμητή ενός σημείου +0,002, δηλαδή μηδέν. Το σήμα είναι 0,2% του μεγέθους της εκτίμησης· η άθροιση σε T γύρους μειώνει τον θόρυβο κατά $\sqrt{T} \approx 277$, που αφήνει ωφέλιμο λόγο περίπου 0,55 — ακόμη κάτω από τη μονάδα. **Ο ορίζοντας δεν επαρκεί** για εκτιμητή ενός σημείου πάνω σε simplex 25 διαστάσεων.

Η μία θεμιτή διόρθωση δοκιμάστηκε και δεν αλλάζει τίποτα. Το επιχείρημα της διασποράς υπαγορεύει μια συγκεκριμένη παρέμβαση: συσσώρευση της εκτίμησης για m γύρους πριν το βήμα, που ανεβάζει τον ωφέλιμο λόγο κατά $\sqrt{m}$ και κρατά το σημείο στο εσωτερικό του simplex, ώστε η προβολή να μην αποκόπτει ασύμμετρα τον θόρυβο. Σαρώθηκε m σε $\{1, 20, 100, 500\}$ επί πέντε τάξεις μεγέθους του βήματος. *Κανένας* συνδυασμός δεν παράγει εσωτερικό βέλτιστο: κάθε κελί είναι είτε πάνω στο οροπέδιο είτε χειρότερο, και το batching κάνει ακριβώς ό,τι προβλέπει η θεωρία — ανέχεται μεγαλύτερο βήμα χωρίς ζημιά — χωρίς ποτέ να παράγει κέρδος. Το σήμα δεν υπάρχει για να ενισχυθεί.

Μια επιφύλαξη για τον εκτιμητή δύο σημείων. Η παράμετρος συρρίκνωσής του οδηγήθηκε από την επιλογή στο κάτω όριο του επιτρεπτού διαστήματος. Αυτό δεν είναι ατύχημα αλλά το αναμενόμενο: καθώς $\delta \rightarrow 0$ η πεπερασμένη διαφορά συγκλίνει στην ακριβή κατευθυντική παράγωγο, οπότε ο εκτιμητής δύο σημείων *παύει να είναι bandit*. Το 21,9% του Πίνακα 7.14 πρέπει επομένως να διαβάζεται ως άνω φράγμα του τι πετυχαίνει η προσέγγιση με δύο ερωτήματα, όχι ως επίδοση σε γνήσιο bandit περιβάλλον. Ο εκτιμητής ενός σημείου είναι το ειλικρινές πείραμα, και η απάντησή του είναι μηδέν.

Τι μένει από το πείραμα. Δύο πράγματα, και κανένα τους δεν είναι αυτό που αναζητούσε. Πρώτον, ότι η ανάδραση ενός σημείου είναι ανεπαρκής σε αυτόν τον ορίζοντα, με ποσοτική εξήγηση του γιατί και με την προφανή διόρθωση δοκιμασμένη και απορριφθείσα. Δεύτερον, και πιο χρήσιμο για την υπόλοιπη εργασία, ότι **το 41% του περιθωρίου του μείγματος έναντι του ομοιόμορφου μέσου δεν προέρχεται από μάθηση καθόλου**, αλλά από την επαναπροβολή που επιβάλλει η μεταβαλλόμενη σύνθεση του panel. Αυτό είναι ανεξάρτητο εύρημα για τη δυναμική των Sleeping Experts και συμφωνεί

με τη μέτρηση του §7.8, όπου η κίνηση των βαρών στα τελευταία στάδια αποδείχθηκε ότι κυριαρχείται από την προβολή και όχι από το βήμα της κλίσης.

Ένα παράπλευρο εύρημα υπέρ της γραμμικοποίησης. Ο έλεγχος πλήρους πληροφόρησης με την *ακριβή* κλίση της μη γραμμικής απώλειας ισοπαλεί με τον υλοποιημένο, γραμμικοποιημένο OGD ($+0,000002$, $p = 0,934$). Η απλοποίηση του Λήμματος 3.9, δηλαδή, δεν κοστίζει τίποτα μετρήσιμο στα δεδομένα αυτά — επιβεβαίωση σχεδιαστικής επιλογής που ως τώρα στηριζόταν μόνο στο θεωρητικό επιχείρημα ότι το γραμμικό πρόβλημα είναι δυσκολότερο.

7.11 Μαρκοβιανή εναλλαγή καθεστώτων αγοράς

Η μαρκοβιανή αλυσίδα πάνω στο *διάνυσμα βαρών* έχει ήδη δοκιμαστεί και απορριφθεί: κάθε πυρήνας μετάβασης επιλέγει $\alpha = 0$ στο *train*, δηλαδή καταρρέει στον απλό OGD. Εδώ η αλυσίδα τρέχει πάνω σε άλλο αντικείμενο — σε *καταστάσεις της αγοράς*. Διατηρούνται K λανθάνοντα καθεστώτα, ένα διάνυσμα βαρών ανά καθεστώς υπό *Sleeping Experts*, και μια πεποίθηση που ενημερώνεται με την μπροστινή αναδρομή κρυφού μαρκοβιανού μοντέλου· κάθε καθεστώς βηματίζει ανάλογα με την ευθύνη του. Το $K = 1$ αναπαράγει ακριβώς τον `run_ogd_sleeping`.

Το κίνητρο είναι μετρημένο και όχι υποθετικό: το §7.3 και η ανάλυση άφιξης πληροφορίας δείχνουν ότι το πλεονέκτημα των τιμών κλεισίματος ποικίλλει κατά 26 φορές ανάλογα με το πόσο κινήθηκε η γραμμή. Υπάρχει επομένως πραγματική λανθάνουσα κατάσταση στα δεδομένα. Το καθεστώς αφήνεται σκόπιμα *λανθάνον*, ώστε να μπορεί να ελεγχθεί εκ των υστέρων αν η αλυσίδα την ανακαλύπτει μόνη της.


Η πρώτη εκδοχή απέτυχε με διαγνώσιμο τρόπο. Η μέση πεποίθηση έμεινε στο 0,500 ακριβώς και για τα δύο καθεστώτα. Τα καθεστώτα *δεν διαφοροποιήθηκαν ποτέ*: λαμβάνουν το ίδιο διάνυσμα απωλειών, οπότε από συμμετρική αφετηρία ακολουθούν πανομοιότυπες τροχιές και οι πιθανοφάνειές τους μένουν ίσες. Το αποτέλεσμα ήταν απλώς OGD με βήμα διαιρεμένο διά K , και έχανε σημαντικά ($+0,000128$, $p < 0,001$). Η συμμετρική λύση είναι σταθερό σημείο της δυναμικής, και χρειάζεται ρητός μηχανισμός διαφοροποίησης.

Μετά τη διόρθωση: ισοπαλία. Προστέθηκαν οξύτητα πεποίθησης β , λήθη γ , και ρολόι ανά καθεστώς. Η επιλογή στο *train* δίνει $K = 3$, $\beta = 30$, $\gamma = 0$, $\tau = 0$, με βαθμονομημένο $\log\text{-loss}$ 0,996909 έναντι 0,996926 του OGD: διαφορά $-0,000016$, $p = 0,211$, **ισοπαλία**. Το $\beta = 30$ είναι γνήσιο εσωτερικό βέλτιστο — το πλέγμα επεκτάθηκε ως το 1000 και οι τιμές 100, 300, 1000 είναι όλες χειρότερες στο *train*.

Δύο ευρήματα που ακυρώνουν κάθε ισχυρισμό ότι «λειτουργεί η αλυσίδα». Πρώτον, η ουρά είναι *επίπεδη*: από $\beta = 3$ ως $\beta = 1000$ κινείται μεταξύ 0,997647 και 0,997649, εύρος δύο εκατομμυριοστών σε τρεις τάξεις μεγέθους της παραμέτρου, ενώ οι διαφορές στο *train* που οδηγούν την επιλογή είναι δεκαπλάσιες. Η επιλογή προσαρμόζεται σε θόρυβο, όπως ακριβώς στην από κοινού σάρωση βήματος και ρυθμού βαθμονόμησης (§7.12). Δεύτερον, και πιο αποφασιστικό, επιλέγεται $\tau = 0$ — καμία μετάβαση — και η τυπική απόκλιση της πεποίθησης είναι 0,0000: παγώνει νωρίς και δεν ξανακινείται. Δεν υπάρχει επομένως μαρκοβιανή εναλλαγή. Ό,τι απομένει είναι σταθερός κυρτός συνδυασμός τριών

OGD με διαφορετική αρχικοποίηση, δηλαδή *ensembling*, και το μικρό σημειακό κέρδος πρέπει να αποδοθεί σε αυτό.

Και η αλυσίδα δεν ανακαλύπτει τίποτα. Η συσχέτιση της πεποίθησης με τη μετρημένη κίνηση της γραμμής είναι μη ορίσιμη, ακριβώς επειδή η πεποίθηση είναι σταθερή. Το λανθάνον καθεστώς δεν αντιστοιχεί σε καμία μετρήσιμη ιδιότητα της αγοράς. Η απάντηση στο ερώτημα που έθεσε το πείραμα — ανακαλύπτει ένα μοντέλο χωρίς πλευρική πληροφορία τη δομή που μετρήθηκε άμεσα; — είναι αρνητική και καθαρή.



Σχήμα 7.11: Αριστερά, η σάρωση της οξύτητας πεποίθησης. Δεξιά, ο έλεγχος αν το λανθάνον καθεστώς αντιστοιχεί στη μετρημένη άφιξη πληροφορίας.

Πρόκειται για το τρίτο ανεξάρτητο παράδειγμα του ισχυρότερου μοτίβου της εργασίας: μόλις συντονιστεί το βήμα, καμία μετακίνηση μάζας πάνω στους experts δεν προσφέρει τίποτα μετρήσιμο. Fixed-Share, πυρήνες μετάβασης, τώρα και εναλλαγή καθεστώτων. Η διαφορά εδώ είναι ότι η αποτυχία *διαγνώστηκε* αντί απλώς να παρατηρηθεί.

7.12 Αρνητικά αποτελέσματα

Μια σειρά εύλογων υποθέσεων ελέγχθηκε και απορρίφθηκε. Τις αναφέρουμε ρητά, καθώς η καθεμία περιορίζει το πεδίο εφαρμογής της μεθόδου.

Η εξειδίκευση ανά πρωτάθλημα δεν βοηθάει. Ένα ξεχωριστό μοντέλο ανά λίγκα χάνει από το ενιαίο σε *κάθε* μία από τις έξι λίγκες που δοκιμάστηκαν. Δύο εύλογες αιτίες: κάθε λίγκα διαθέτει μόνο 2.231–3.800 αγώνες, πολύ λίγους για να συγκλίνει ο online αλγόριθμος αυτόνομα, και οι ειδικοί καταλήγουν να εμπιστεύονται σε μεγάλο βαθμό τους *ιδιους* experts με το ενιαίο μοντέλο, δηλαδή δεν ανακαλύπτουν κάτι τοπικό.

Το Fixed-Share δεν βοηθάει. Κάθε $\alpha > 0$ χειροτερεύει το log-loss (0,99842 στο $\alpha = 0$ έναντι 0,99885 και πάνω). Σάρωση του α από κοινού με το βήμα δείχνει γιατί: το α βοηθούσε μόνο όταν το βήμα ήταν πολύ μεγάλο. Και τα δύο ελέγχουν την ίδια ποσότητα — πόσο γρήγορα ξεχνάει ο αλγόριθμος — και το βήμα είναι το αποδοτικότερο από τα δύο εργαλεία.

Το βήμα ανά expert χειροτερεύει σημαντικά. Αντικαθιστώντας το καθολικό t με τον αριθμό των γύρων όπου κάθε expert ήταν ξύπνιος — που είναι κυριολεκτικά το μέγεθος για το οποίο μιλά η εγγύηση των Sleeping Experts — το αποτέλεσμα είναι *καλύτερο στο train αλλά* $-0,00073$ *στην ουρά*. Ένας expert με κάλυψη 6,9% λαμβάνει βήμα περίπου 14 φορές μεγαλύτερο, και το μείγμα κυνηγά τους σπάνιους bookmakers, των οποίων η φαινομενική ποιότητα είναι συγχυσμένη με τη δυσκολία της μίας σεζόν όπου εμφανίζονται. Πρόκειται για την καθαρότερη επίδειξη υπερπροσαρμογής στην εργασία.

Η από κοινού επιλογή βήματος και ρυθμού βαθμονόμησης δεν προσφέρει τίποτα. Οι δύο παράμετροι δεν αλληλεπιδρούν: ο βέλτιστος ρυθμός βαθμονόμησης είναι 0,15 σε 11 από 11 γραμμές. Η από κοινού επιλογή στο train διαλέγει μάλιστα χειρότερη τιμή για το OGD, καθώς το πλέγμα είναι εκεί σχεδόν επίπεδο και η επιλογή προσαρμόζεται στον θόρυβο.

Οι μαρκοβιανοί πυρήνες μετάβασης δεν προσφέρουν τίποτα. Και οι τρεις πυρήνες του §3.11(α) — ομοιόμορφος, προς τον opening/closing δίδυμο, προς την ίδια φάση αγοράς — επιλέγουν $\alpha = 0$ στο χρονολογικό πρόθεμα, δηλαδή καταρρέουν στον απλό OGD. Οι ζευγαρωμένοι έλεγχοι το επιβεβαιώνουν με μέση διαφορά 0,000000 *ακριβώς* και $p = 1,000$, όχι κατά προσέγγιση. Το εύρημα συμφωνεί με το Fixed-Share: από τη στιγμή που το ίδιο το βήμα είναι συντονισμένο, καμία εκ των υστέρων μετακίνηση μάζας δεν έχει τι να διορθώσει, γιατί και τα δύο ελέγχουν την ίδια ποσότητα. Αξίζει πάντως να σημειωθεί ότι σε *μεγάλα* α οι δομημένοι πυρήνες βλάπτουν μετρήσιμα λιγότερο από τον ομοιόμορφο, δηλαδή η δομή του panel είναι πραγματική και ανιχνεύσιμη — απλώς περιττή.

Η μπεϋζιανή εκδοχή του Kelly δεν ξεπερνά το σταθερό κλάσμα. Η διατύπωση του §3.17 είναι θεωρητικά ελκυστικότερη, αφού η συρρίκνωση προκύπτει από την αβεβαιότητα αντί να επιβάλλεται. Ζευγαρωμένη με το σταθερό $\frac{1}{4}$ πάνω στα ίδια στοιχήματα, για τέσσερις στόχους και δύο επίπεδα ποντίσματος, δίνει **6 ισοπαλίες και 2 σημαντικές ήττες** (PSC και στα δύο επίπεδα, $p = 0,003$ και $p = 0,049$), με *καμία* σημαντική νίκη. Η επιλεγμένη παράμετρος συγκέντρωσης κ είναι επιπλέον ασταθής μεταξύ στόχων χωρίς εμφανές μοτίβο, ένδειξη ότι η επιλογή προσαρμόζεται σε θόρυβο. Η πιθανότερη εξήγηση είναι ότι το μοντέλο Dirichlet δεν περιγράφει σωστά τον μηχανισμό που παράγει τις διαφορές των bookmakers: οι διαφορές τους δεν είναι ανεξάρτητος θόρυβος γύρω από μια κοινή αλήθεια αλλά συστηματικές διαφορές τιμολόγησης, οπότε η εκ των υστέρων κατανομή είναι λάθος κατανομή και η συρρίκνωση που παράγει δεν αντιστοιχεί στην πραγματική αβεβαιότητα.

Οι ισοπαλίες είναι πρακτικά απρόβλεπτες ως κύρια πρόβλεψη. Παρότι αποτελούν $\sim 26\%$ των αγώνων, ο καλύτερος αλγόριθμος τις επιλέγει ως πιθανότερο ενδεχόμενο στο 0,4% των περιπτώσεων. Πρόκειται για γνωστό φαινόμενο της ποδοσφαιρικής πρόβλεψης, που εδώ επιβεβαιώνεται ποσοτικά.

Κεφάλαιο 8

Συζήτηση

8.1 Τι έδειξε η εργασία

Συνοψίζοντας τα ευρήματα του Κεφαλαίου 7, προκύπτουν τρεις απαντήσεις σε διαφορετικά επίπεδα.

Στο επίπεδο της **μεθόδου**, το πλαίσιο δουλεύει, αλλά λιγότερο από όσο δείχνει η πρώτη ανάγνωση. Ένα online μείγμα από δημοσιευμένες αποδόσεις, χωρίς κανένα δεδομένο πέρα από τις ίδιες τις τιμές, ξεπερνά σταθερά και σημαντικά τόσο την ομοιόμορφη μέση τιμή όσο και τη συντριπτική πλειονότητα των μεμονωμένων εταιρειών. Το γεγονός ότι αυτό επιτυγχάνεται χωρίς καμία στατιστική υπόθεση για την κατανομή των δεδομένων, και με προβλέψεις που είναι εξ ορισμού εκτός δείγματος, είναι το κύριο μεθοδολογικό κέρδος της online προσέγγισης έναντι μιας κλασικής batch. Ο περιορισμός προέκυψε από το πείραμα του §7.10: με ρητό control μηδενικού βήματος φαίνεται ότι το 41% του περιθωρίου έναντι της ομοιόμορφης μέσης τιμής παράγεται από την επαναλαμβανόμενη προβολή στο simplex, δηλαδή από τη γεωμετρία της αναγωγής και όχι από τη μάθηση. Η στάθμιση προσθέτει πραγματικά κάτι, αλλά λιγότερο από ό,τι θα συμπεράινε κανείς συγκρίνοντάς την απευθείας με τον μέσο όρο.

Στο επίπεδο της **σύγκρισης με την αγορά**, η απάντηση είναι πιο συγκρατημένη. Στην πλήρη δεκαετία και στο πλήρες panel ο σκληρότερος bookmaker παραμένει σημαντικά μπροστά. Στη διαμόρφωση που επιλέγεται τελικά η διαφορά παύει να είναι σημαντική, και στον έλεγχο ανάπτυξης το μείγμα κερδίζει κάθε τιμή ανοίγματος και ισοπαλεί με τις τιμές κλεισίματος των bookmakers. Το πραγματικό όριο δεν είναι bookmaker: το Betfair Exchange, που είναι ανταλλακτήριο και άρα τιμή αγοράς χωρίς περιθώριο διαχειριστή, μας ξεπερνά σημαντικά. Η τίμια διατύπωση είναι ότι *φτάνουμε* την αιχμή της αγοράς των bookmakers, όχι ότι την ξεπερνάμε, και ότι η αγορά χωρίς μεσάζοντα παραμένει μπροστά.

Στο επίπεδο της **οικονομικής αξιοποίησης**, η απάντηση είναι αρνητική. Το βελτιωμένο log-loss δεν μεταφράζεται σε κερδοφορία, γιατί η διαφορά ποιότητας που κερδίζεται είναι μικρότερη από το περιθώριο που χρεώνει η αγορά. Η διάκριση αυτή — ανάμεσα στο να είσαι καλύτερος προγνώστης και στο να μπορείς να το εκμεταλλευτείς — είναι, κατά τη γνώμη μας, το πρακτικότερα χρήσιμο συμπέρασμα. Το τρίτο στάδιο OCO δεν αναιρεί το συμπέρασμα αυτό, αλλά διευκρινίζει τι μπορεί και τι δεν μπορεί να κάνει το μέγεθος του στοιχήματος: ο μαθαίνόμενος πολλαπλασιαστής πολλαπλασιάζει το τελικό κεφάλαιο εκεί όπου άκρη υπάρχει και συρρικνώνεται μόνος του εκεί όπου δεν υπάρχει, χωρίς ποτέ να δημιουργεί άκρη. Η επιλογή αντιπάλου παραμένει πολύ σημαντικότερη από την επιλογή πονταρίσματος.

8.2 Πότε αποδίδει η μάθηση: η ανομοιογένεια ως προϋπόθεση

Το επαναλαμβανόμενο μοτίβο σε ολόκληρη την εργασία είναι ότι η μαθημένη στάθμιση αποδίδει όταν, και μόνο όταν, οι experts διαφέρουν ουσιωδώς σε ποιότητα. Το εύρημα εμφανίζεται ανεξάρτητα σε τρία σημεία:

- Στο πλήρες panel, που περιέχει 13 καλούς closing και 13 συστηματικά χειρότερους opening experts, και οι τρεις αλγόριθμοι κερδίζουν σημαντικά τον απλό μέσο όρο.
- Στα ομοιογενή panel (μόνο opening ή μόνο closing) οι Hedge και FTRL *χάνουν* από τον μέσο όρο, σε 8 από 8 τεστ.
- Αφαιρώντας την Pinnacle από το *opening* panel, ακόμη και το OGD πέφτει πίσω από τον μέσο όρο (0,99999 έναντι 0,99990) και χάνει σημαντικά από τον VC_BV.

Η τέταρτη περίπτωση — το closing panel χωρίς την Pinnacle — δεν στηρίζει πλέον το μοτίβο και αναφέρεται γι' αυτόν ακριβώς τον λόγο. Εκεί το OGD κατατάσσεται πρώτο (0,99919) με τον μέσο όρο δεύτερο (0,99921). Η διαφορά είναι 0,00002, δηλαδή πρακτικά μηδενική, οπότε η σωστή ανάγνωση δεν είναι «η στάθμιση κερδίζει εδώ» αλλά «οι δύο είναι αδιάκριτοι» — πράγμα που εξακολουθεί να συμφωνεί με το γενικό συμπέρασμα, αφού σε ομοιογενές panel η στάθμιση δεν έχει τι να μάθει.

Η ερμηνεία είναι ότι το κέρδος δεν προέρχεται πρωτίστως από τον αλγόριθμο αλλά από τη δομή του panel. Όταν υπάρχει πραγματική ποιοτική διαφορά, η στάθμιση τη βρίσκει και την εκμεταλλεύεται. Όταν δεν υπάρχει, η προσαρμογή είναι καθαρό κόστος: ο αλγόριθμος πληρώνει θόρυβο εκτίμησης χωρίς αντίστοιχο όφελος, και ο μέσος όρος — που δεν εκτιμά τίποτα — αποδεικνύεται ανθεκτικότερος.

Το συμπέρασμα αυτό έχει άμεση πρακτική αξία για όποιον θα εφάρμοζε το πλαίσιο σε άλλο πεδίο. Το κριτήριο για ένα καλό σύνολο experts δεν είναι το πλήθος τους, ούτε το πόσο διαφέρουν οι αριθμοί τους, αλλά το αν *παράγονται από διαφορετικές διαδικασίες*.

8.3 Η υλική βάση των διαφορών

Είναι εύκολο να διαβαστούν τα βάρη ως αφηρημένες παραμέτρους. Στην πραγματικότητα κάθε expert εδώ είναι μια επιχείρηση, με δικό της κόστος, δική της ανοχή στο ρίσκο και δικό της επιχειρηματικό μοντέλο, και οι διαφορές που μαθαίνει ο αλγόριθμος είναι διαφορές ανάμεσα σε αυτά. Τρία στοιχεία από τα ίδια μας τα αποτελέσματα το υποστηρίζουν.

Η Pinnacle βρίσκεται μπροστά όχι επειδή διαθέτει κατ' ανάγκην καλύτερο μοντέλο πρόβλεψης, αλλά επειδή λειτουργεί με χαμηλό περιθώριο και υψηλό τζίρο και δεν περιορίζει τους κερδισμένους παίκτες. Το μοντέλο αυτό σημαίνει ότι την τιμή της τη διορθώνουν συνεχώς οι ίδιοι οι πληροφορημένοι στοιχηματιστές, αντί να αποκλείονται. Δεν πρόκειται για τεχνολογική υπεροχή αλλά για διαφορετική σχέση με την πληροφορία.

Στο παράθυρο 2025–26 ο καλύτερος προγνώστης δεν είναι καν bookmaker αλλά το Betfair Exchange, δηλαδή ένα ανταλλακτήριο όπου οι παίκτες στοιχηματίζουν μεταξύ τους. Η τιμή εκεί δεν περιέχει περιθώριο διαχειριστή, και αυτό ακριβώς την κάνει καθαρότερη εκτίμηση.

Τέλος, σε δέκα σεζόν η αγορά δεν έγινε πιο ακριβής — το log-loss δεν παρουσιάζει σημαντική τάση — αλλά έγινε πιο ακριβή, με τη γκανιότα να αυξάνεται από 4,42% σε 6,00% ($p = 0,0007$). Η δεκαετής εξέλιξη των τιμών είναι δηλαδή εμπορική απόφαση, όχι βελτίωση πρόβλεψης.

Τα τρία στοιχεία χωριστά είναι παρατηρήσεις· μαζί στηρίζουν συγκεκριμένο ισχυρισμό. Η μικροδομή του §3.4 προβλέπει ότι το περιθώριο παρακολουθεί την εκτιμώμενη αναλογία πληροφορημένων. Αν αυτό ήταν όλη η ιστορία, άνοδος 158 μονάδων βάσης σε μια δεκαετία θα σήμαινε αγορά ολοένα πιο εκτεθειμένη σε πληροφορημένο χρήμα — και τότε η ακρίβειά της θα όφειλε να έχει μετακινηθεί. Δεν έχει: καμία σειρά δεν εμφανίζει σημαντική τάση ούτε σε log-loss ούτε σε ECE (p από 0,21 ως 1,00), ενώ η γκανιότα ανεβαίνει με $p = 0,0007$. Η εγκάρσια εικόνα λέει το ίδιο: ο μόνος τρόπος χωρίς διαχειριστή είναι ο καλύτερος προγνώστης της περιόδου, και οι μόνοι δύο νικήσιμοι οίκοι είναι εκείνοι που απευθύνονται σε ερασιτέχνες παίκτες. Αυτό που χωρίζει τους οίκους, δηλαδή, δεν φαίνεται να είναι πόσο καλά προβλέπουν αλλά *ποιον αφήνουν να στοιχηματίσει και σε ποια τιμή* — ακριβώς η παρατήρηση του Levitt (2004) ότι οι αγορές στοιχηματισμού οργανώνονται γύρω από τον παίκτη και όχι γύρω από την τιμή. Τα δεδομένα δεν λένε *γιατί* επιτράπηκε η άνοδος — ρύθμιση, συγκέντρωση της αγοράς, μεταβολή της ζήτησης — και η εργασία δεν το ισχυρίζεται.

Η παρατήρηση δεν είναι διακοσμητική: δένει άμεσα με το §8.2. Το μείγμα καταρρέει στον απλό μέσο όρο ακριβώς όταν οι experts παύουν να διαφέρουν ως προς τον τρόπο με τον οποίο παράγονται.

8.4 Ο χαρακτήρας της μεθόδου

Αξιίζει να σημειωθεί μια ιδιότητα του πλαισίου που δεν είναι πάντα ρητή. Το μοντέλο δεν εκπαιδεύεται και έπειτα εφαρμόζεται· δεν υπάρχει στιγμή όπου «γνωρίζει» και στη συνέχεια δρα. Σε κάθε αγώνα διατυπώνει έναν ισχυρισμό, το αποτέλεσμα τον διαψεύδει σε κάποιον βαθμό, και ο ισχυρισμός αναθεωρείται. Η διάψευση *είναι* το υλικό της μάθησης, κυριολεκτικά: η κλίση που ενημερώνει τα βάρη ισούται με την απώλεια της πρόβλεψης απέναντι στο τι συνέβη. Χωρίς σφάλμα δεν μαθαίνεται τίποτα, και τα βάρη σε κάθε στιγμή δεν αποτελούν την απάντηση αλλά την τρέχουσα κατάσταση μιας διαφωνίας που δεν έχει λυθεί.

Η ιδιότητα αυτή επιβεβαιώθηκε και εμπειρικά, εκεί που δεν την περιμέναμε. Εξετάσαμε αν το μείγμα τελικά «καταλήγει» κάπου και ησυχάζει, δεδομένου ότι το βήμα φθίνει ως $1/\sqrt{t}$. Δεν καταλήγει. Το βήμα όντως πέφτει κατά παράγοντα 277 από τον πρώτο ως τον τελευταίο γύρο, αλλά η μέση κίνηση του διανύσματος βαρών ανά γύρο είναι 0,0353, 0,0226, 0,0227, 0,0284 στα τέσσερα τεταρτημόρια: το τελευταίο κινείται *περισσότερο* από το δεύτερο και το τρίτο, τη στιγμή που το βήμα εκεί είναι διακοσιοεβδομήντα φορές μικρότερο. Ο λόγος είναι ότι η κίνηση κυριαρχείται από την προβολή στο simplex κάθε φορά που αλλάζει το σύνολο των ξύπνιων experts, όχι από το βήμα — το ίδιο φαινόμενο που το §7.10 απομονώνει ποσοτικά, δείχνοντας ότι η προβολή από μόνη της, χωρίς καμία μάθηση, παράγει το 41% του περιθωρίου του μείγματος έναντι της ομοιόμορφης μέσης τιμής.

Σχετικά, η θεωρητικά ανώτερη εναλλακτική — ο Aggregating Algorithm, που εκμεταλλεύεται την exp-concavity του log-loss και επιτυγχάνει $\text{regret} \leq \ln N$ με σταθερό $\eta = 1$ — αποδίδει στην πράξη χειρότερα από την ομοιόμορφη μέση τιμή. Η εξήγηση είναι ακριβώς ότι

το φράγμα του αφορά *στατικό comparator*, ενώ το panel δεν είναι στατικό: η κάλυψη της Pinnacle καταρρέει προς το τέλος της περιόδου, και ένας αλγόριθμος που συγκεντρώνεται γρήγορα σε λίγους experts τιμωρείται ακριβώς από έναν expert που εξαφανίζεται.

8.5 Περιορισμοί

Οι ακόλουθοι περιορισμοί αναφέρονται ρητά.

Η επιλογή παραθύρου είναι μορφή επιλογής. Εξετάστηκαν τρία χρονικά παράθυρα και το αποτέλεσμα βελτιωνόταν υπέρ μας σε κάθε στένεμα. Αυτό είναι ακριβώς το μοτίβο που παράγει ψευδή ευρήματα, και γι' αυτό αναφέρονται και τα τρία, με τα λιγότερο ευνοϊκά μαζί με τα ευνοϊκά.

Στατιστική ισχύς στα στενά παράθυρα. Ο έλεγχος ανάπτυξης στηρίζεται σε 8.151 αγώνες έναντι 71.818 της πλήρους σύγκρισης. Τα διαστήματα εμπιστοσύνης είναι αντίστοιχα φαρδύτερα, οπότε η «ισοπαλία» σημαίνει εν μέρει «λιγότερα δεδομένα» και όχι μόνο «ίδια ποιότητα».

Η συγχώνευση ταυτοτήτων είναι συναγωγή. Η συγχώνευση VC/BetVictor στηρίζεται στη μη επικαλυπτόμενη χρονική παρουσία, όχι σε επίσημη πηγή. Δεν αποκλείεται να υπάρχουν αντίστοιχες μετονομασίες που δεν εντοπίστηκαν.

Η προσομοίωση αγνοεί τη ρευστότητα. Δεν μοντελοποιούνται όρια λογαριασμού, περιορισμοί ποντίσματος ή διαθέσιμη ρευστότητα — ακριβώς οι μηχανισμοί με τους οποίους οι εταιρείες περιορίζουν στην πράξη τους κερδισμένους παίκτες. Η προσομοίωση δείχνει *στατιστική ύπαρξη* άκρης, όχι βιώσιμη κερδοφορία.

Ο έλεγχος αιτιότητας δεν είναι εξαντλητικός. Εντοπίστηκε και διορθώθηκε ένα κανάλι διαρροής στον σχεδιασμό leave-one-out, αλλά δεν αποκλείεται να υπάρχουν άλλα σε λιγότερο προφανή σημεία.

Οι αιτιώδεις ερμηνείες είναι εύλογες, όχι αποδεδειγμένες. Η εξήγηση, για παράδειγμα, της αύξησης του περιθωρίου ως εμπορικής απόφασης είναι συμβατή με τα δεδομένα αλλά δεν ελέγχεται άμεσα από αυτά.

Κεφάλαιο 9

Συμπεράσματα και επεκτάσεις

9.1 Συμπεράσματα

1. Το πλαίσιο OCO εφαρμόζεται επιτυχώς σε αγορές στοιχηματισμού. Ένα online μείγμα από δημοσιευμένες αποδόσεις ξεπερνά σημαντικά την ομοιόμορφη μέση τιμή και τη συντριπτική πλειονότητα των μεμονωμένων εταιρειών, χωρίς καμία υπόθεση για την κατανομή των δεδομένων.
2. Το μείγμα φτάνει αλλά δεν ξεπερνά την αιχμή της αγοράς. Στη διαμόρφωση που επιλέγεται, η διαφορά από τον σκληρότερο bookmaker παύει να είναι στατιστικά σημαντική. Στον έλεγχο ανάπτυξης κερδίζει σημαντικά κάθε τιμή ανοίγματος και ισοπαλεί με τις τιμές κλεισίματος των bookmakers. Το όριο τίθεται από το Betfair Exchange, που δεν είναι bookmaker αλλά ανταλλακτήριο, δηλαδή τιμή αγοράς χωρίς περιθώριο διαχειριστή: αυτό μας ξεπερνά σημαντικά.
3. Ένα σημαντικό μέρος της φαινομενικής υπεροχής δεν είναι μάθηση. Υπό την αναγωγή Sleeping Experts το διάνυσμα βαρών κινείται ακόμη και με μηδενικό βήμα, γιατί η προβολή επαναλαμβάνεται σε simplex άλλης διάστασης κάθε φορά που αλλάζει το σύνολο των ξύπνιων experts. Με ρητό control μηδενικού βήματος, το 41% του περιθωρίου έναντι της ομοιόμορφης μέσης τιμής αποδίδεται σε αυτή τη γεωμετρία και όχι στον αλγόριθμο. Κάθε μελλοντική σύγκριση με τον ομοιόμορφο μέσο οφείλει να φέρει τον ίδιο έλεγχο.
4. Η ανομοιογένεια του panel είναι προϋπόθεση, όχι λεπτομέρεια. Η μαθημένη στάθμιση αποδίδει μόνο όταν οι experts διαφέρουν ουσιαστικά: σε ομοιογενές σύνολο ο απλός μέσος όρος είναι τουλάχιστον εξίσου ανθεκτικός. Το εύρημα επιβεβαιώνεται ανεξάρτητα σε τρία σημεία, ενώ σε ένα τέταρτο — το closing panel χωρίς την Pinnacle — οι δύο καταλήγουν αδιάκριτοι (§8.2).
5. Τα worst-case θεωρητικά βήματα δεν είναι βέλτιστα στην πράξη, και μάλιστα αστοχούν προς αντίθετες κατευθύνσεις ανά αλγόριθμο. Προστατεύουν από έναν αντίπαλο που οι αποδόσεις στοιχήματος δεν είναι. Η μόνη εξαίρεση είναι το τρίτο στάδιο OCO, όπου ο αλγόριθμος που εκμεταλλεύεται τη δομή της απώλειας δέχεται τη θεωρητική σταθερά αδιόρθωτη.
6. Καλύτερη πρόβλεψη δεν σημαίνει κέρδος. Η διαφορά ποιότητας που κερδίζεται

υπολείπεται του περιθωρίου της αγοράς, και όποια άκρη υπάρχει αφορά συγκεκριμένες εταιρείες, όχι γενική στρατηγική.

7. **Στο τρίτο στάδιο OCO, το τι μαθαίνεται κρίνει το αποτέλεσμα.** Η μάθηση του πονταρίσματος κατευθείαν αποτυγχάνει συστηματικά, επειδή ο comparator «καλύτερο σταθερό ποντάρισμα» δεν περιέχει τον κλειστό τύπο και επειδή πετά την πιθανότητα που τα δύο προηγούμενα στάδια μόλις παρήγαγαν. Η μάθηση του *πολλαπλασιαστή* πάνω στον κλειστό τύπο ισοπαλεί με τον σταθερό συντελεστή και τον ξεπερνά σημειακά όπου υπάρχει πραγματική άκρη, ανακαλύπτοντας διαφορετική διάθεση ρίσκου ανά αντίπαλο. Είναι επίσης το μόνο σημείο της εργασίας όπου η *a-priori* σταθερά της θεωρίας βγήκε σωστή χωρίς διόρθωση, ακριβώς επειδή ο αλγόριθμος που την αξιοποιεί εκμεταλλεύεται τη δομή της απώλειας.
8. **Η μεθοδολογική πειθαρχία στις συγκρίσεις είναι καθοριστική.** Αρκετά ενδιάμεσα «ευρήματα» αποδείχθηκαν τεχνουργήματα σύγκρισης πάνω σε διαφορετικά σύνολα αγώνων ή επιλογής σε επίπεδο πλέγμα. Η απαίτηση κοινών γύρων και η αναφορά ουράς ελέγχου είναι αυτό που τα εντόπισε.

9.2 Επεκτάσεις

Ζωντανή ροή αποδόσεων. Ό,τι υπολογίζεται εδώ γίνεται πάνω σε ιστορικό αρχείο, που σημαίνει ότι κάθε αποτέλεσμα είναι ισχυρισμός για το τι θα *είχε* κάνει η μέθοδος. Το πλαίσιο δεν το απαιτεί αυτό: τα τρία στάδια είναι online και αιτιώδη, κάθε γύρος κοστίζει $O(N \log N)$, και η κατάσταση είναι ένα διάνυσμα βαρών συν δύο βαθμωτά μεγέθη, οπότε ολόκληρη η αλυσίδα τρέχει σε πραγματικό χρόνο απέναντι σε ένα API αποδόσεων. Αυτό που θα πρόσθετε μια τέτοια υλοποίηση δεν είναι ταχύτητα αλλά τα δύο πράγματα που ένα αρχείο δεν μπορεί να δώσει. Πρώτον, οι τιμές θα ήταν εκείνες που ήταν όντως διαθέσιμες για στοιχηματισμό και όχι εκείνες που καταγράφηκαν εκ των υστέρων — ακριβώς το κενό που εντοπίζει το §8.5 ανάμεσα σε στατιστική και αξιοποιήσιμη άκρη: όρια λογαριασμού, περιορισμοί ποντίσματος και ρευστότητα γίνονται παρατηρήσιμα αντί να αγνοούνται. Δεύτερον, η διάκριση ανοίγματος–κλεισίματος, που εδώ μπορεί να αντιμετωπιστεί μόνο ως δύο στατικά στιγμιότυπα, γίνεται το συνεχές αντικείμενο που πραγματικά είναι — και η μέτρηση του §7.4, ότι το πλεονέκτημα του κλεισίματος συγκεντρώνεται στο άνω πεμπτημόριο της κίνησης της γραμμής, υποδεικνύει ότι το ενδιαφέρον μέγεθος δεν είναι η τελική τιμή αλλά η *τροχιά*, την οποία μόνο μια ζωντανή ροή καταγράφει.

Δεύτερο άθλημα. Η επέκταση σε μπάσκετ ή τένις θα έδειχνε αν το πλαίσιο γενικεύεται πέρα από το ποδόσφαιρο. Το κόστος είναι κυρίως νέος αγωγός δεδομένων, αφού οι αλγόριθμοι δεν αλλάζουν. Ιδιαίτερο ενδιαφέρον έχει ένα άθλημα δύο εκβάσεων, όπου η δομή του προβλήματος απλοποιείται.

Bayesian Model Averaging ως baseline. Ένα πλήρες BMA baseline θα έδινε εμπειρικό σημείο σύγκρισης απέναντι στους online αλγόριθμους, και θα φώτιζε περαιτέρω την αποτυχία του Aggregating Algorithm.

Παράρτημα Α΄

Πλήρεις πίνακες αποτελεσμάτων

Το παράρτημα αυτό παραθέτει σε πλήρη μορφή τους πίνακες που τα κεφάλαια του κυρίως κειμένου παρουσιάζουν συνοπτικά. Παράγεται αυτόματα από τα αρχεία αποτελεσμάτων, ώστε να μην αποκλίνει από αυτά.

Α.1 Κατάταξη και στατιστική σημαντικότητα

Πίνακας Α΄.1: Πλήρης κατάταξη Tier-A, δέκα σεζόν.

Γύροι	log-loss (cal.)	Brier (raw)	Brier (cal.)	raw_rps	calibrated_rps	Acc. (raw)	Acc.
71.818	0,99685	0,59592	0,59577	0,20263	0,20256	0,50611	0,50611
76.584	0,99693	0,59612	0,59586	0,20270	0,20257	0,50662	0,50662
76.584	0,99773	0,59674	0,59637	0,20297	0,20278	0,50649	0,50649
76.584	0,99774	0,59674	0,59638	0,20297	0,20279	0,50653	0,50653
76.584	0,99813	0,59703	0,59665	0,20311	0,20291	0,50593	0,50593
68.397	1,0003	0,59833	0,59806	0,20372	0,20359	0,50355	0,50355
65.470	1,0005	0,59860	0,59818	0,20387	0,20368	0,50309	0,50309
71.284	1,0005	0,59838	0,59824	0,20376	0,20369	0,50309	0,50309
57.185	1,0006	0,59899	0,59826	0,20412	0,20379	0,50214	0,50214
72.752	1,0007	0,59873	0,59833	0,20381	0,20360	0,50355	0,50355
76.438	1,0007	0,59852	0,59832	0,20373	0,20362	0,50377	0,50377

Πίνακας Α΄.2: Όλες οι σειρές του panel, χωρίς κατώφλι κάλυψης.

n_seasons_active	single_season	hedge_weight_last_awake	Γύροι	log-loss	Brier	RPS	Acc.
10	όχι	0,00000	71.818	0,99714	0,59592	0,20263	0,50611
1	ναι	0,16631	7.680	0,99730	0,59594	0,20251	0,51029
10	όχι	—	76.584	0,99745	0,59612	0,20270	0,50662
2	όχι	0,04504	14.885	0,99783	0,59656	0,20253	0,50890
1	ναι	0,16620	7.681	0,99786	0,59605	0,20253	0,50814
3	όχι	0,00005	20.972	0,99797	0,59682	0,20303	0,50644
1	ναι	0,14584	5.587	0,99819	0,59667	0,20317	0,50743
10	όχι	—	76.584	0,99842	0,59674	0,20297	0,50649
10	όχι	—	76.584	0,99843	0,59674	0,20297	0,50653
10	όχι	—	76.584	0,99886	0,59703	0,20311	0,50593
1	ναι	0,15156	5.257	0,99906	0,59732	0,20323	0,50409
7	όχι	0,00009	53.267	0,99953	0,59732	0,20314	0,50705
1	ναι	0,11580	7.508	0,99955	0,59776	0,20303	0,50759
6	όχι	0,00024	45.424	0,99973	0,59757	0,20326	0,50590
7	όχι	0,00014	49.755	0,99998	0,59769	0,20316	0,50624
6	όχι	0,00043	42.366	1,0002	0,59787	0,20349	0,50555
1	ναι	0,16597	7.673	1,0004	0,59809	0,20354	0,50541
9	όχι	0,00000	68.397	1,0007	0,59833	0,20372	0,50355

(συνέχεια)

n_seasons_active	single_season	hedge_weight_last_awake	Γόροι	log-loss	Brier	RPS	Acc.
10	όχι	0,00000	71.284	1,0008	0,59838	0,20376	0,50309
1	ναι	0,11542	7.524	1,0009	0,59874	0,20326	0,50704
5	όχι	0,18974	34.038	1,0009	0,59820	0,20376	0,50385
10	όχι	0,00000	76.438	1,0011	0,59852	0,20373	0,50377
9	όχι	0,00000	65.470	1,0012	0,59860	0,20387	0,50309
10	όχι	0,00000	72.752	1,0014	0,59873	0,20381	0,50355
8	όχι	0,00001	57.185	1,0019	0,59899	0,20412	0,50214
1	ναι	0,11836	7.309	1,0021	0,59938	0,20381	0,50581
1	ναι	0,16922	7.505	1,0027	0,59958	0,20402	0,50393
1	ναι	0,11393	7.619	1,0027	0,59991	0,20390	0,50532
1	ναι	0,14862	5.393	1,0044	0,60099	0,20444	0,50028
2	όχι	0,04495	14.763	1,0072	0,60309	0,20526	0,49604

Πίνακας Α'.3: Πλήρης μπαταρία ελέγχων σημαντικότητας.

Σύγκριση	n	M. διαφορά	CI κάτω	CI άνω	p
OGD vs PSC (raw)	71.818	0,00065	0,00044	0,00086	0,00000
OGD vs PSC (calibrated)	71.818	0,00043	0,00020	0,00064	0,00000
OGD vs B365C (raw)	53.267	-0,00063	-0,00093	-0,00034	0,00000
OGD vs Hedge (raw)	76.584	-0,00097	-0,00118	-0,00075	0,00000
OGD vs FTRL (raw)	76.584	-0,00098	-0,00120	-0,00077	0,00000
OGD vs Uniform average (raw)	76.584	-0,00141	-0,00167	-0,00115	0,00000
Hedge vs Uniform average (raw)	76.584	-0,00044	-0,00062	-0,00026	0,00000
FTRL vs Uniform average (raw)	76.584	-0,00043	-0,00061	-0,00025	0,00000
Hedge: raw vs calibrated	76.584	0,00069	0,00040	0,00096	0,00000
OGD: raw vs calibrated	76.584	0,00053	0,00027	0,00078	0,00000
FTRL: raw vs calibrated	76.584	0,00069	0,00040	0,00096	0,00000
Uniform average: raw vs calibrated	76.584	0,00073	0,00044	0,00101	0,00000

Α.2 Panel και μέθοδος de-vig

Πίνακας Α'.4: Panel × αλγόριθμος — Αναλογική κανονικοποίηση.

Panel	Αλγόριθμος	n_bookmakers	Γόροι	log-loss	Brier	RPS	Acc.	De-vig
closing	FTRL	13	76.521	0,99761	0,59621	0,20272	0,50658	Basic
full	FTRL	26	76.584	0,99843	0,59674	0,20297	0,50653	Basic
opening	FTRL	13	76.557	1,0009	0,59842	0,20375	0,50394	Basic
closing	Hedge	13	76.521	0,99762	0,59622	0,20272	0,50659	Basic
full	Hedge	26	76.584	0,99842	0,59674	0,20297	0,50649	Basic
opening	Hedge	13	76.557	1,0009	0,59842	0,20375	0,50402	Basic
closing	OGD	13	76.521	0,99722	0,59598	0,20263	0,50648	Basic
full	OGD	26	76.584	0,99745	0,59612	0,20270	0,50662	Basic
opening	OGD	13	76.557	1,0008	0,59832	0,20370	0,50391	Basic
closing	Uniform average	13	76.521	0,99748	0,59612	0,20269	0,50672	Basic
full	Uniform average	26	76.584	0,99886	0,59703	0,20311	0,50593	Basic
opening	Uniform average	13	76.557	1,0008	0,59836	0,20373	0,50398	Basic

Πίνακας Α'.5: Panel × αλγόριθμος — Κανονικοποίηση Shin.

Panel	Αλγόριθμος	n_bookmakers	Γόροι	log-loss	Brier	RPS	Acc.	De-vig
closing	FTRL	13	76.521	0,99714	0,59596	0,20260	0,50659	Shin
full	FTRL	26	76.584	0,99782	0,59642	0,20282	0,50646	Shin

(συνέχεια)

Panel	Αλγόριθμος	n_bookmakers	Γύροι	log-loss	Brier	RPS	Acc.	De-vig
opening	FTRL	13	76.557	1,0003	0,59812	0,20361	0,50385	Shin
closing	Hedge	13	76.521	0,99714	0,59596	0,20260	0,50659	Shin
full	Hedge	26	76.584	0,99781	0,59641	0,20282	0,50645	Shin
opening	Hedge	13	76.557	1,0003	0,59812	0,20361	0,50387	Shin
closing	OGD	13	76.521	0,99689	0,59581	0,20255	0,50658	Shin
full	OGD	26	76.584	0,99709	0,59595	0,20262	0,50682	Shin
opening	OGD	13	76.557	1,0002	0,59804	0,20357	0,50389	Shin
closing	Uniform average	13	76.521	0,99703	0,59589	0,20258	0,50674	Shin
full	Uniform average	26	76.584	0,99824	0,59670	0,20295	0,50598	Shin
opening	Uniform average	13	76.557	1,0002	0,59805	0,20358	0,50393	Shin

Πίνακας Α'.6: Κάθε αλγόριθμος έναντι του απλού μέσου όρου, αναλογική.

Panel	Αλγόριθμος	Μετρική	lower_is_better	n	De-vig	M. διαφορά	CI κάτω	CI άνω	p
opening	Hedge	log_loss	ναι	76.557	Basic	0,00008	0,00001	0,00014	0,01900
opening	Hedge	brier	ναι	76.557	Basic	0,00006	0,00002	0,00009	0,00000
opening	Hedge	accuracy	όχι	76.557	Basic	0,00004	-0,00021	0,00027	0,81700
opening	OGD	log_loss	ναι	76.557	Basic	-0,00004	-0,00013	0,00006	0,43300
opening	OGD	brier	ναι	76.557	Basic	-0,00004	-0,00010	0,00001	0,14000
opening	OGD	accuracy	όχι	76.557	Basic	-0,00007	-0,00043	0,00033	0,75900
opening	FTRL	log_loss	ναι	76.557	Basic	0,00008	0,00002	0,00014	0,01500
opening	FTRL	brier	ναι	76.557	Basic	0,00006	0,00002	0,00010	0,00200
opening	FTRL	accuracy	όχι	76.557	Basic	-0,00004	-0,00027	0,00020	0,78200
closing	Hedge	log_loss	ναι	76.521	Basic	0,00014	0,00010	0,00018	0,00000
closing	Hedge	brier	ναι	76.521	Basic	0,00009	0,00007	0,00012	0,00000
closing	Hedge	accuracy	όχι	76.521	Basic	-0,00013	-0,00046	0,00018	0,42300
closing	OGD	log_loss	ναι	76.521	Basic	-0,00026	-0,00036	-0,00016	0,00000
closing	OGD	brier	ναι	76.521	Basic	-0,00014	-0,00021	-0,00008	0,00000
closing	OGD	accuracy	όχι	76.521	Basic	-0,00025	-0,00071	0,00022	0,29700
closing	FTRL	log_loss	ναι	76.521	Basic	0,00013	0,00009	0,00018	0,00000
closing	FTRL	brier	ναι	76.521	Basic	0,00009	0,00006	0,00012	0,00000
closing	FTRL	accuracy	όχι	76.521	Basic	-0,00014	-0,00046	0,00017	0,36700
full	Hedge	log_loss	ναι	76.584	Basic	-0,00044	-0,00062	-0,00026	0,00000
full	Hedge	brier	ναι	76.584	Basic	-0,00030	-0,00042	-0,00017	0,00000
full	Hedge	accuracy	όχι	76.584	Basic	0,00056	-0,00014	0,00125	0,12300
full	OGD	log_loss	ναι	76.584	Basic	-0,00141	-0,00167	-0,00115	0,00000
full	OGD	brier	ναι	76.584	Basic	-0,00091	-0,00108	-0,00074	0,00000
full	OGD	accuracy	όχι	76.584	Basic	0,00069	-0,00025	0,00162	0,15600
full	FTRL	log_loss	ναι	76.584	Basic	-0,00043	-0,00061	-0,00025	0,00000
full	FTRL	brier	ναι	76.584	Basic	-0,00029	-0,00041	-0,00017	0,00000
full	FTRL	accuracy	όχι	76.584	Basic	0,00060	-0,00010	0,00131	0,10800

Πίνακας Α'.7: Κάθε αλγόριθμος έναντι του απλού μέσου όρου, Shin.

Panel	Αλγόριθμος	Μετρική	lower_is_better	n	De-vig	M. διαφορά	CI κάτω	CI άνω	p
opening	Hedge	log_loss	ναι	76.557	Shin	0,00011	0,00004	0,00018	0,00000
opening	Hedge	brier	ναι	76.557	Shin	0,00008	0,00003	0,00012	0,00000
opening	Hedge	accuracy	όχι	76.557	Shin	-0,00005	-0,00029	0,00018	0,69700
opening	OGD	log_loss	ναι	76.557	Shin	0,00002	-0,00008	0,00013	0,73600
opening	OGD	brier	ναι	76.557	Shin	-0,00001	-0,00006	0,00005	0,82600
opening	OGD	accuracy	όχι	76.557	Shin	-0,00004	-0,00042	0,00035	0,89600
opening	FTRL	log_loss	ναι	76.557	Shin	0,00011	0,00004	0,00019	0,00000
opening	FTRL	brier	ναι	76.557	Shin	0,00008	0,00003	0,00012	0,00000
opening	FTRL	accuracy	όχι	76.557	Shin	-0,00008	-0,00033	0,00017	0,55900
closing	Hedge	log_loss	ναι	76.521	Shin	0,00011	0,00007	0,00016	0,00000
closing	Hedge	brier	ναι	76.521	Shin	0,00008	0,00005	0,00010	0,00000
closing	Hedge	accuracy	όχι	76.521	Shin	-0,00014	-0,00046	0,00017	0,37900
closing	OGD	log_loss	ναι	76.521	Shin	-0,00014	-0,00023	-0,00004	0,00500
closing	OGD	brier	ναι	76.521	Shin	-0,00007	-0,00013	-0,00001	0,01600
closing	OGD	accuracy	όχι	76.521	Shin	-0,00016	-0,00060	0,00029	0,51300
closing	FTRL	log_loss	ναι	76.521	Shin	0,00011	0,00006	0,00015	0,00000

(συνέχεια)

Panel	Αλγόριθμος	Μετρική	lower_is_better	<i>n</i>	De-vig	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
closing	FTRL	brier	ναι	76.521	Shin	0,00007	0,00004	0,00010	0,00000
closing	FTRL	accuracy	όχι	76.521	Shin	-0,00014	-0,00046	0,00017	0,37900
full	Hedge	log_loss	ναι	76.584	Shin	-0,00043	-0,00062	-0,00023	0,00000
full	Hedge	brier	ναι	76.584	Shin	-0,00029	-0,00042	-0,00016	0,00000
full	Hedge	accuracy	όχι	76.584	Shin	0,00047	-0,00025	0,00116	0,21900
full	OGD	log_loss	ναι	76.584	Shin	-0,00115	-0,00140	-0,00090	0,00000
full	OGD	brier	ναι	76.584	Shin	-0,00075	-0,00092	-0,00059	0,00000
full	OGD	accuracy	όχι	76.584	Shin	0,00084	-0,00010	0,00175	0,07900
full	FTRL	log_loss	ναι	76.584	Shin	-0,00042	-0,00061	-0,00023	0,00000
full	FTRL	brier	ναι	76.584	Shin	-0,00028	-0,00041	-0,00015	0,00000
full	FTRL	accuracy	όχι	76.584	Shin	0,00048	-0,00024	0,00118	0,20300

Α.3 Διαμορφώσεις

Πίνακας Α'.8: Στοιβάξη διαμορφώσεων.

Διαμόρφωση	Στάδιο	full_log_loss	train	ουρά
baseline (full 26, basic)	raw	0,99779	0,99860	0,99536
baseline (full 26, basic)	calibrated	0,99728	0,99801	0,99508
closing only, basic	raw	0,99733	0,99801	0,99528
closing only, basic	calibrated	0,99693	0,99756	0,99506
full 26, Shin	raw	0,99745	0,99822	0,99512
full 26, Shin	calibrated	0,99731	0,99804	0,99512
A: closing + Shin	raw	0,99702	0,99767	0,99506
A: closing + Shin	calibrated	0,99692	0,99754	0,99507
B: A minus single-season	raw	0,99702	0,99767	0,99509
B: A minus single-season	calibrated	0,99692	0,99754	0,99509
PSC alone	raw	0,99714	0,99776	0,99526
PSC alone	calibrated	0,99685	0,99746	0,99502

Πίνακας Α'.9: Ζευγαρωτοί έλεγχοι διαμορφώσεων.

Στάδιο	Έναντι	<i>n</i>	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
raw	PSC alone	71.818	0,00065	0,00044	0,00086	0,00000
calibrated	PSC alone	71.818	0,00043	0,00020	0,00064	0,00000
raw	PSC alone	71.818	0,00019	0,00009	0,00029	0,00000
raw	baseline (full 26, basic)	71.818	-0,00046	-0,00064	-0,00029	0,00000
calibrated	PSC alone	71.818	0,00009	-0,00003	0,00020	0,14300
calibrated	baseline (full 26, basic)	71.818	-0,00034	-0,00053	-0,00016	0,00000
raw	PSC alone	71.818	0,00031	0,00008	0,00054	0,01100
raw	baseline (full 26, basic)	71.818	-0,00034	-0,00046	-0,00022	0,00000
calibrated	PSC alone	71.818	0,00046	0,00021	0,00069	0,00000
calibrated	baseline (full 26, basic)	71.818	0,00004	-0,00002	0,00009	0,18100
raw	PSC alone	71.818	-0,00012	-0,00025	0,00000	0,05700
raw	baseline (full 26, basic)	71.818	-0,00077	-0,00100	-0,00056	0,00000
calibrated	PSC alone	71.818	0,00007	-0,00004	0,00018	0,23400
calibrated	baseline (full 26, basic)	71.818	-0,00036	-0,00056	-0,00016	0,00000
raw	PSC alone	71.818	-0,00011	-0,00024	0,00001	0,07200

(συνέχεια)

Στάδιο	Έναντι	n	Μ. διαφορά	CI κάτω	CI άνω	p
raw	baseline (full 26, basic)	71.818	-0,00077	-0,00099	-0,00055	0,00000
calibrated	PSC alone	71.818	0,00008	-0,00003	0,00018	0,18100
calibrated	baseline (full 26, basic)	71.818	-0,00035	-0,00055	-0,00015	0,00000

Α.4 Χωρίς την Pinnacle

Πίνακας Α.10: Κατάταξη χωρίς Pinnacle, τρία panel.

rank	Σειρά	Τύπος	Κάλυψη %	log-loss (raw)	log-loss (cal.)	train	ουρά
1	FTRL	algorithm	100,0000	0,99854	0,99771	1,0011	0,98747
2	Hedge	algorithm	100,0000	0,99854	0,99771	1,0011	0,98747
3	OGD	algorithm	100,0000	0,99858	0,99782	1,0013	0,98735
4	Uniform average	algorithm	100,0000	0,99927	0,99837	1,0016	0,98862
5	VC_BV	bookmaker	89,3098	1,0004	0,99987	1,0028	0,99113
6	WH	bookmaker	85,4878	1,0012	1,0003	1,0031	0,99191
7	BW	bookmaker	94,9963	1,0011	1,0004	1,0032	0,99187
8	B365	bookmaker	99,8094	1,0008	1,0004	1,0033	0,99173
9	IW	bookmaker	74,6696	1,0017	1,0005	1,0035	0,99146
1	OGD	algorithm	69,5916	0,99997	0,99919	1,0041	0,98459
2	Uniform average	algorithm	69,5916	1,0000	0,99921	1,0041	0,98462
3	FTRL	algorithm	69,5916	1,0000	0,99921	1,0041	0,98463
4	Hedge	algorithm	69,5916	1,0000	0,99921	1,0041	0,98463
5	VC_BVC	bookmaker	59,3127	0,99981	0,99929	1,0043	0,98426
6	B365C	bookmaker	69,5537	1,0001	0,99955	1,0044	0,98493
7	IWC	bookmaker	44,4453	1,0007	0,99957	1,0042	0,98558
8	BWC	bookmaker	64,9679	1,0005	0,99968	1,0047	0,98463
9	WHC	bookmaker	55,3196	1,0008	1,0002	1,0050	0,98579
1	VC_BV	bookmaker	89,3098	1,0004	0,99987	1,0028	0,99113
2	Uniform average	algorithm	99,9647	1,0007	0,99990	1,0028	0,99130
3	FTRL	algorithm	99,9647	1,0007	0,99991	1,0028	0,99131
4	Hedge	algorithm	99,9647	1,0007	0,99991	1,0028	0,99131
5	OGD	algorithm	99,9647	1,0007	0,99999	1,0029	0,99136
6	WH	bookmaker	85,4878	1,0012	1,0003	1,0031	0,99191
7	BW	bookmaker	94,9963	1,0011	1,0004	1,0032	0,99187
8	B365	bookmaker	99,8094	1,0008	1,0004	1,0033	0,99173
9	IW	bookmaker	74,6696	1,0017	1,0005	1,0035	0,99146

Πίνακας Α.11: Ζευγαρωτοί έλεγχοι χωρίς Pinnacle.

Bookmaker	n	Έκβαση	Μ. διαφορά	CI κάτω	CI άνω	p
IW	54.877	OGD better	-0,00315	-0,00366	-0,00262	0,00000
WH	54.877	OGD better	-0,00259	-0,00311	-0,00208	0,00000
BW	54.877	OGD better	-0,00255	-0,00309	-0,00205	0,00000
B365	54.877	OGD better	-0,00223	-0,00273	-0,00176	0,00000
VC_BV	54.877	OGD better	-0,00181	-0,00230	-0,00134	0,00000
WHC	32.210	OGD better	-0,00088	-0,00135	-0,00039	0,00000
IWC	32.210	OGD better	-0,00077	-0,00108	-0,00047	0,00000
BWC	32.210	OGD better	-0,00051	-0,00085	-0,00017	0,00700
B365C	32.210	tie (not significant)	-0,00011	-0,00040	0,00021	0,50500
VC_BVC	32.210	tie (not significant)	0,00016	-0,00015	0,00043	0,28400
IW	54.877	OGD better	-0,00105	-0,00130	-0,00076	0,00000
WH	54.877	OGD better	-0,00048	-0,00074	-0,00019	0,00200
BW	54.877	OGD better	-0,00045	-0,00070	-0,00020	0,00000

(συνέχεια)

Bookmaker	n	Έκβαση	Μ. διαφορά	CI κάτω	CI άνω	p
B365	54.877	tie (not significant)	-0,00012	-0,00033	0,00007	0,20300
VC_BV	54.877	VC_BV better	0,00030	0,00009	0,00050	0,00400

Α.5 Πρόσφατο παράθυρο και έλεγχος ανάπτυξης

Πίνακας Α'.12: Κατάταξη, πέντε σεζόν.

Φάση	Κάλυψη %	Γύροι	log-loss (raw)	log-loss (cal.)	Brier (raw)	Brier (cal.)	Acc.
closing	87,9119	34.065	0,99471	0,99439	0,59424	0,59410	0,50976
—	100,0000	38.749	0,99556	0,99495	0,59482	0,59452	0,51090
closing	79,6975	30.882	0,99554	0,99498	0,59483	0,59456	0,50955
closing	72,1361	27.952	0,99575	0,99502	0,59490	0,59450	0,51009
closing	91,9353	35.624	0,99609	0,99504	0,59513	0,59460	0,51039
closing	99,9974	38.748	0,99602	0,99543	0,59500	0,59471	0,51107
—	100,0000	38.749	0,99677	0,99591	0,59559	0,59516	0,50920
—	100,0000	38.749	0,99689	0,99604	0,59567	0,59524	0,50956
—	100,0000	38.749	0,99692	0,99607	0,59569	0,59526	0,50954
opening	71,9090	27.864	0,99848	0,99771	0,59677	0,59634	0,50660
opening	87,6952	33.981	0,99831	0,99794	0,59665	0,59649	0,50552
opening	79,0833	30.644	0,99870	0,99801	0,59696	0,59660	0,50702
opening	91,5327	35.468	0,99981	0,99885	0,59765	0,59716	0,50665
opening	99,8400	38.687	0,99951	0,99896	0,59736	0,59709	0,50660

Πίνακας Α'.13: Έλεγχοι σημαντικότητας, πέντε σεζόν.

Σύγκριση	n	Μ. διαφορά	CI κάτω	CI άνω	p
OGD vs PSC (raw)	34.065	0,00065	0,00037	0,00097	0,00000
OGD vs PSC (calibrated)	34.065	0,00036	0,00008	0,00067	0,01400
OGD vs B365C (raw)	38.748	-0,00047	-0,00086	-0,00012	0,01400
OGD vs Hedge (raw)	38.749	-0,00133	-0,00166	-0,00102	0,00000
OGD vs FTRL (raw)	38.749	-0,00136	-0,00169	-0,00104	0,00000
OGD vs Uniform average (raw)	38.749	-0,00121	-0,00151	-0,00092	0,00000
Hedge vs Uniform average (raw)	38.749	0,00012	0,00004	0,00019	0,00600
FTRL vs Uniform average (raw)	38.749	0,00015	0,00006	0,00023	0,00200
Hedge: raw vs calibrated	38.749	0,00085	0,00036	0,00133	0,00100
OGD: raw vs calibrated	38.749	0,00061	0,00021	0,00100	0,00100
FTRL: raw vs calibrated	38.749	0,00086	0,00037	0,00134	0,00100
Uniform average: raw vs calibrated	38.749	0,00086	0,00036	0,00135	0,00100

Πίνακας Α'.14: Η αγορά της ουράς, πέντε σεζόν.

rank	Φάση	Κάλυψη %	log-loss	Bookmaker	n	Μ. διαφορά	CI κάτω	CI άνω	p
1,0000	—	100,0000	1,0001	—	—	—	—	—	—
2,0000	closing	85,0674	1,0002	—	—	—	—	—	—
3,0000	closing	77,7447	1,0003	—	—	—	—	—	—
4,0000	closing	75,5458	1,0003	—	—	—	—	—	—
5,0000	closing	100,0000	1,0007	—	—	—	—	—	—
6,0000	—	100,0000	1,0008	—	—	—	—	—	—
7,0000	—	100,0000	1,0009	—	—	—	—	—	—
8,0000	—	100,0000	1,0009	—	—	—	—	—	—
9,0000	opening	75,2847	1,0026	—	—	—	—	—	—

(συνέχεια)

rank	Φάση	Κάλυψη %	log-loss	Bookmaker	<i>n</i>	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
10,0000	opening	99,8485	1,0030	—	—	—	—	—	—
11,0000	opening	84,7697	1,0032	—	—	—	—	—	—
12,0000	opening	77,1075	1,0081	—	—	—	—	—	—
—	opening	—	—	BFE	7.699	-0,00796	-0,01093	-0,00527	0,00000
—	opening	—	—	BW	7.699	-0,00306	-0,00479	-0,00141	0,00100
—	opening	—	—	B365	7.699	-0,00283	-0,00454	-0,00118	0,00100
—	opening	—	—	PS	7.699	-0,00244	-0,00406	-0,00094	0,00200
—	closing	—	—	B365C	7.699	-0,00057	-0,00146	0,00031	0,20500
—	closing	—	—	PSC	7.699	-0,00015	-0,00056	0,00029	0,50300
—	closing	—	—	BFEC	7.699	-0,00013	-0,00092	0,00074	0,79700
—	closing	—	—	BWC	7.699	-0,00009	-0,00082	0,00064	0,81500

Πίνακας Α'.15: Έλεγχος ανάπτυξης 2025–26.

rank	Σειρά	Τύπος	Κάλυψη %	log-loss
1	BFEC	closing	96,1811	1,0004
2	OGD closing-only, online	αλγόριθμος	100,0000	1,0011
3	OGD πλήρες panel, online	αλγόριθμος	100,0000	1,0013
4	BWC	closing	75,5400	1,0015
5	OGD closing-only, παγωμένο	αλγόριθμος	100,0000	1,0015
6	B365C	closing	100,0000	1,0017
7	OGD πλήρες panel, παγωμένο	αλγόριθμος	100,0000	1,0018
8	B365	opening	99,7840	1,0037
9	BW	opening	75,1253	1,0042
10	BFE	opening	95,3171	1,0076

Πίνακας Α'.16: Ζευγαρωτοί έλεγχοι, ανάπτυξη 2025–26.

Bookmaker	Φάση	<i>n</i>	Έκβαση	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
B365	opening	8.151	αλγόριθμος	-0,00241	-0,00382	-0,00102	0,00100
B365C	closing	8.151	ισοπαλία	-0,00036	-0,00121	0,00054	0,39000
BFE	opening	8.151	αλγόριθμος	-0,00629	-0,00878	-0,00386	0,00000
BFEC	closing	8.151	BFEC	0,00089	0,00016	0,00166	0,01300
BW	opening	8.151	αλγόριθμος	-0,00287	-0,00431	-0,00141	0,00000
BWC	closing	8.151	ισοπαλία	-0,00017	-0,00087	0,00058	0,68500
PS	opening	6.857	αλγόριθμος	-0,00228	-0,00408	-0,00058	0,00700
PSC	closing	6.892	ισοπαλία	-0,00013	-0,00058	0,00030	0,56800
B365	opening	8.151	αλγόριθμος	-0,00188	-0,00313	-0,00066	0,00500
B365C	closing	8.151	ισοπαλία	0,00018	-0,00080	0,00122	0,75100
BFE	opening	8.151	αλγόριθμος	-0,00575	-0,00821	-0,00337	0,00000
BFEC	closing	8.151	BFEC	0,00143	0,00046	0,00238	0,00200
BW	opening	8.151	αλγόριθμος	-0,00233	-0,00358	-0,00112	0,00000
BWC	closing	8.151	ισοπαλία	0,00037	-0,00043	0,00123	0,34200
PS	opening	6.857	αλγόριθμος	-0,00219	-0,00407	-0,00042	0,01500
PSC	closing	6.892	ισοπαλία	-0,00004	-0,00038	0,00030	0,79600
B365	opening	8.151	αλγόριθμος	-0,00260	-0,00417	-0,00106	0,00200
B365C	closing	8.151	ισοπαλία	-0,00055	-0,00137	0,00030	0,19300
BFE	opening	8.151	αλγόριθμος	-0,00647	-0,00904	-0,00389	0,00000
BFEC	closing	8.151	ισοπαλία	0,00070	-0,00000	0,00138	0,05200
BW	opening	8.151	αλγόριθμος	-0,00306	-0,00466	-0,00140	0,00100

(συνέχεια)

Bookmaker	Φάση	<i>n</i>	Έκβαση	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
BWC	closing	8.151	ισοπαλία	-0,00036	-0,00107	0,00042	0,36100
PS	opening	6.857	αλγόριθμος	-0,00223	-0,00418	-0,00036	0,01900
PSC	closing	6.892	ισοπαλία	-0,00009	-0,00038	0,00021	0,53200
B365	opening	8.151	αλγόριθμος	-0,00220	-0,00374	-0,00068	0,00700
B365C	closing	8.151	ισοπαλία	-0,00014	-0,00097	0,00076	0,71400
BFE	opening	8.151	αλγόριθμος	-0,00607	-0,00860	-0,00353	0,00000
BFEC	closing	8.151	BFEC	0,00111	0,00028	0,00192	0,00300
BW	opening	8.151	αλγόριθμος	-0,00265	-0,00419	-0,00110	0,00000
BWC	closing	8.151	ισοπαλία	0,00005	-0,00061	0,00076	0,85000
PS	opening	6.857	αλγόριθμος	-0,00223	-0,00422	-0,00035	0,01900
PSC	closing	6.892	ισοπαλία	-0,00009	-0,00031	0,00013	0,44400

A.6 Value betting

Πίνακας Α'.17: Πλήρης σάρωση panel εκπαίδευσης $\times$ στόχου $\times$ κανονικοποίησης.

De-vig	Panel εκπ.	Φάση	Bookmaker	Στάδιο	Στοιχ.	log-growth	CI κάτω	CI άνω	<i>p</i>
Basic	closing-trained	closing	PSC	raw	20.580	-0,00012	-0,00019	-0,00005	0,00100
Basic	closing-trained	closing	PSC	calibrated	19.497	-0,00003	-0,00010	0,00004	0,36800
Basic	closing-trained	closing	B365C	raw	7.941	0,00000	-0,00012	0,00012	0,99100
Basic	closing-trained	closing	B365C	calibrated	7.643	0,00001	-0,00013	0,00014	0,96800
Basic	closing-trained	closing	BWC	raw	3.134	0,00022	-0,00004	0,00049	0,09100
Basic	closing-trained	closing	BWC	calibrated	6.920	0,00016	0,00001	0,00033	0,04200
Basic	closing-trained	closing	VC_BVC	raw	5.142	0,00000	-0,00015	0,00018	0,93600
Basic	closing-trained	closing	VC_BVC	calibrated	4.561	0,00010	-0,00010	0,00030	0,33900
Basic	closing-trained	closing	WHC	raw	6.633	0,00055	0,00026	0,00082	0,00000
Basic	closing-trained	closing	WHC	calibrated	7.253	0,00061	0,00028	0,00088	0,00000
Basic	mixed-trained	opening	B365	raw	34.022	0,00060	0,00046	0,00072	0,00000
Basic	mixed-trained	opening	B365	calibrated	35.894	0,00072	0,00057	0,00086	0,00000
Basic	mixed-trained	opening	BW	raw	24.313	0,00074	0,00060	0,00090	0,00000
Basic	mixed-trained	opening	BW	calibrated	29.845	0,00082	0,00066	0,00098	0,00000
Basic	mixed-trained	closing	PSC	raw	42.881	-0,00028	-0,00038	-0,00019	0,00000
Basic	mixed-trained	closing	PSC	calibrated	39.997	-0,00021	-0,00033	-0,00009	0,00000
Basic	mixed-trained	opening	PS	raw	45.926	0,00053	0,00042	0,00064	0,00000
Basic	mixed-trained	opening	PS	calibrated	48.919	0,00068	0,00056	0,00080	0,00000
Basic	mixed-trained	opening	VC_BV	raw	25.631	0,00061	0,00046	0,00075	0,00000
Basic	mixed-trained	opening	VC_BV	calibrated	29.112	0,00072	0,00057	0,00087	0,00000
Basic	mixed-trained	opening	WH	raw	22.036	0,00071	0,00055	0,00088	0,00000
Basic	mixed-trained	opening	WH	calibrated	27.493	0,00077	0,00061	0,00094	0,00000
Basic	mixed-trained	opening	IW	raw	16.562	0,00088	0,00070	0,00108	0,00000
Basic	mixed-trained	opening	IW	calibrated	21.808	0,00096	0,00076	0,00117	0,00000
Basic	mixed-trained	closing	B365C	raw	9.570	-0,00011	-0,00023	0,00002	0,09300
Basic	mixed-trained	closing	B365C	calibrated	7.970	-0,00007	-0,00020	0,00008	0,32800
Basic	mixed-trained	closing	BWC	raw	3.694	0,00008	-0,00014	0,00032	0,52000
Basic	mixed-trained	closing	BWC	calibrated	6.607	0,00009	-0,00006	0,00024	0,24700
Basic	mixed-trained	closing	VC_BVC	raw	6.521	-0,00012	-0,00025	0,00003	0,10600
Basic	mixed-trained	closing	VC_BVC	calibrated	4.653	-0,00006	-0,00025	0,00012	0,45500
Basic	mixed-trained	closing	WHC	raw	6.852	0,00044	0,00016	0,00068	0,00000
Basic	mixed-trained	closing	WHC	calibrated	6.565	0,00056	0,00027	0,00083	0,00000
Basic	opening-trained	opening	B365	raw	15.836	-0,00009	-0,00017	-0,00001	0,04100
Basic	opening-trained	opening	B365	calibrated	10.829	-0,00008	-0,00017	0,00001	0,10100
Basic	opening-trained	opening	BW	raw	4.611	-0,00008	-0,00021	0,00006	0,24800
Basic	opening-trained	opening	BW	calibrated	7.841	0,00001	-0,00010	0,00011	0,82000
Basic	opening-trained	closing	PSC	raw	57.078	-0,00049	-0,00061	-0,00036	0,00000
Basic	opening-trained	closing	PSC	calibrated	56.645	-0,00044	-0,00057	-0,00031	0,00000
Basic	opening-trained	opening	PS	raw	29.835	-0,00012	-0,00018	-0,00007	0,00000
Basic	opening-trained	opening	PS	calibrated	26.675	-0,00005	-0,00010	0,00000	0,05500
Basic	opening-trained	opening	VC_BV	raw	9.508	-0,00015	-0,00026	-0,00005	0,00700
Basic	opening-trained	opening	VC_BV	calibrated	8.083	-0,00006	-0,00018	0,00005	0,24500

(συνέχεια)

De-vig	Panel εκπ.	Φάση	Bookmaker	Στάδιο	Στοιχ.	log-growth	CI κάτω	CI άνω	p
Basic	opening-trained	opening	WH	raw	5.793	-0,00007	-0,00024	0,00010	0,42500
Basic	opening-trained	opening	WH	calibrated	5.931	0,00005	-0,00012	0,00024	0,54500
Basic	opening-trained	opening	IW	raw	3.101	0,00042	0,00015	0,00067	0,00400
Basic	opening-trained	opening	IW	calibrated	7.443	0,00028	0,00006	0,00048	0,00800
Basic	opening-trained	closing	B365C	raw	27.138	-0,00066	-0,00084	-0,00049	0,00000
Basic	opening-trained	closing	B365C	calibrated	27.203	-0,00061	-0,00079	-0,00042	0,00000
Basic	opening-trained	closing	BWC	raw	19.475	-0,00075	-0,00094	-0,00058	0,00000
Basic	opening-trained	closing	BWC	calibrated	20.931	-0,00071	-0,00092	-0,00051	0,00000
Basic	opening-trained	closing	VC_BVC	raw	22.741	-0,00066	-0,00085	-0,00046	0,00000
Basic	opening-trained	closing	VC_BVC	calibrated	22.708	-0,00061	-0,00082	-0,00041	0,00000
Basic	opening-trained	closing	WHC	raw	16.306	-0,00067	-0,00087	-0,00045	0,00000
Basic	opening-trained	closing	WHC	calibrated	16.588	-0,00065	-0,00086	-0,00042	0,00000
Shin	closing-trained	closing	PSC	raw	13.136	0,00000	-0,00008	0,00008	0,94700
Shin	closing-trained	closing	PSC	calibrated	18.398	-0,00000	-0,00008	0,00007	0,97400
Shin	closing-trained	closing	B365C	raw	5.198	0,00007	-0,00008	0,00022	0,42000
Shin	closing-trained	closing	B365C	calibrated	7.374	0,00003	-0,00010	0,00016	0,68700
Shin	closing-trained	closing	BWC	raw	2.535	0,00039	0,00008	0,00074	0,01400
Shin	closing-trained	closing	BWC	calibrated	6.511	0,00018	0,00002	0,00036	0,02900
Shin	closing-trained	closing	VC_BVC	raw	2.900	0,00016	-0,00009	0,00042	0,20400
Shin	closing-trained	closing	VC_BVC	calibrated	4.097	0,00013	-0,00008	0,00036	0,24500
Shin	closing-trained	closing	WHC	raw	4.980	0,00083	0,00042	0,00117	0,00100
Shin	closing-trained	closing	WHC	calibrated	6.675	0,00065	0,00032	0,00095	0,00000
Shin	mixed-trained	opening	B365	raw	31.621	0,00068	0,00055	0,00081	0,00000
Shin	mixed-trained	opening	B365	calibrated	34.959	0,00070	0,00056	0,00084	0,00000
Shin	mixed-trained	opening	BW	raw	23.893	0,00083	0,00068	0,00099	0,00000
Shin	mixed-trained	opening	BW	calibrated	28.919	0,00083	0,00067	0,00099	0,00000
Shin	mixed-trained	closing	PSC	raw	35.750	-0,00024	-0,00035	-0,00013	0,00000
Shin	mixed-trained	closing	PSC	calibrated	39.367	-0,00021	-0,00032	-0,00009	0,00000
Shin	mixed-trained	opening	PS	raw	44.003	0,00062	0,00051	0,00073	0,00000
Shin	mixed-trained	opening	PS	calibrated	48.190	0,00066	0,00054	0,00078	0,00000
Shin	mixed-trained	opening	VC_BV	raw	23.908	0,00073	0,00057	0,00088	0,00000
Shin	mixed-trained	opening	VC_BV	calibrated	28.218	0,00072	0,00056	0,00086	0,00000
Shin	mixed-trained	opening	WH	raw	21.430	0,00080	0,00063	0,00098	0,00000
Shin	mixed-trained	opening	WH	calibrated	26.564	0,00075	0,00059	0,00093	0,00000
Shin	mixed-trained	opening	IW	raw	17.465	0,00094	0,00074	0,00112	0,00000
Shin	mixed-trained	opening	IW	calibrated	21.369	0,00096	0,00076	0,00114	0,00000
Shin	mixed-trained	closing	B365C	raw	6.413	-0,00008	-0,00023	0,00006	0,25300
Shin	mixed-trained	closing	B365C	calibrated	7.786	-0,00005	-0,00019	0,00009	0,46700
Shin	mixed-trained	closing	BWC	raw	2.740	0,00016	-0,00012	0,00046	0,28100
Shin	mixed-trained	closing	BWC	calibrated	6.132	0,00013	-0,00003	0,00031	0,12000
Shin	mixed-trained	closing	VC_BVC	raw	3.871	-0,00010	-0,00029	0,00010	0,30000
Shin	mixed-trained	closing	VC_BVC	calibrated	4.216	-0,00003	-0,00023	0,00016	0,66800
Shin	mixed-trained	closing	WHC	raw	4.774	0,00073	0,00037	0,00105	0,00100
Shin	mixed-trained	closing	WHC	calibrated	5.914	0,00059	0,00028	0,00089	0,00000
Shin	opening-trained	opening	B365	raw	8.796	-0,00008	-0,00017	0,00003	0,18800
Shin	opening-trained	opening	B365	calibrated	10.578	-0,00010	-0,00019	-0,00000	0,04900
Shin	opening-trained	opening	BW	raw	2.315	0,00006	-0,00011	0,00029	0,40000
Shin	opening-trained	opening	BW	calibrated	7.441	0,00004	-0,00007	0,00015	0,44200
Shin	opening-trained	closing	PSC	raw	55.765	-0,00046	-0,00058	-0,00033	0,00000
Shin	opening-trained	closing	PSC	calibrated	56.441	-0,00044	-0,00057	-0,00030	0,00000
Shin	opening-trained	opening	PS	raw	18.357	-0,00006	-0,00011	-0,00000	0,03800
Shin	opening-trained	opening	PS	calibrated	24.953	-0,00006	-0,00011	0,00000	0,05400
Shin	opening-trained	opening	VC_BV	raw	4.268	-0,00002	-0,00015	0,00012	0,72200
Shin	opening-trained	opening	VC_BV	calibrated	7.333	-0,00006	-0,00018	0,00005	0,26500
Shin	opening-trained	opening	WH	raw	2.996	0,00020	-0,00007	0,00051	0,15500
Shin	opening-trained	opening	WH	calibrated	6.418	0,00002	-0,00014	0,00021	0,73700
Shin	opening-trained	opening	IW	raw	3.579	0,00048	0,00020	0,00074	0,00000
Shin	opening-trained	opening	IW	calibrated	7.179	0,00032	0,00011	0,00052	0,00100
Shin	opening-trained	closing	B365C	raw	26.159	-0,00063	-0,00081	-0,00045	0,00000
Shin	opening-trained	closing	B365C	calibrated	27.097	-0,00061	-0,00081	-0,00042	0,00000
Shin	opening-trained	closing	BWC	raw	19.224	-0,00074	-0,00093	-0,00055	0,00000
Shin	opening-trained	closing	BWC	calibrated	20.970	-0,00071	-0,00091	-0,00051	0,00000
Shin	opening-trained	closing	VC_BVC	raw	21.857	-0,00064	-0,00084	-0,00043	0,00000
Shin	opening-trained	closing	VC_BVC	calibrated	22.573	-0,00061	-0,00081	-0,00041	0,00000
Shin	opening-trained	closing	WHC	raw	15.400	-0,00066	-0,00088	-0,00044	0,00000
Shin	opening-trained	closing	WHC	calibrated	16.333	-0,00064	-0,00086	-0,00041	0,00000

Πίνακας Α'.18: Σάρωση όλων των bookmakers.

Bookmaker	Στάδιο	Στοιχ.	Κεφάλαιο	log-growth	CI κάτω	CI άνω	<i>p</i>
B365	raw	15.836	0,24472	-0,00009	-0,00017	-0,00001	0,04100
B365	calibrated	10.829	0,41079	-0,00008	-0,00017	0,00001	0,10100
BW	raw	4.611	0,67602	-0,00008	-0,00021	0,00006	0,24800
BW	calibrated	7.841	1,0913	0,00001	-0,00010	0,00011	0,82000
PSC	raw	42.881	0,00000	-0,00028	-0,00038	-0,00019	0,00000
PSC	calibrated	39.997	0,00021	-0,00021	-0,00033	-0,00009	0,00000
PS	raw	29.835	0,02460	-0,00012	-0,00018	-0,00007	0,00000
PS	calibrated	26.675	0,26030	-0,00005	-0,00010	0,00000	0,05500
VC_BV	raw	9.508	0,23716	-0,00015	-0,00026	-0,00005	0,00700
VC_BV	calibrated	8.083	0,59737	-0,00006	-0,00018	0,00005	0,24500
WH	raw	5.793	0,68312	-0,00007	-0,00024	0,00010	0,42500
WH	calibrated	5.931	1,3757	0,00005	-0,00012	0,00024	0,54500
IW	raw	3.101	3,7046	0,00042	0,00015	0,00067	0,00400
IW	calibrated	7.443	7,8901	0,00028	0,00006	0,00048	0,00800
B365C	raw	9.570	0,36496	-0,00011	-0,00023	0,00002	0,09300
B365C	calibrated	7.970	0,58286	-0,00007	-0,00020	0,00008	0,32800
BWC	raw	3.694	1,3448	0,00008	-0,00014	0,00032	0,52000
BWC	calibrated	6.607	1,8050	0,00009	-0,00006	0,00024	0,24700
VC_BVC	raw	6.521	0,46013	-0,00012	-0,00025	0,00003	0,10600
VC_BVC	calibrated	4.653	0,75253	-0,00006	-0,00025	0,00012	0,45500
WHC	raw	6.852	19,7908	0,00044	0,00016	0,00068	0,00000
WHC	calibrated	6.565	38,5182	0,00056	0,00027	0,00083	0,00000

Πίνακας Α'.19: Value betting, πέντε σεζόν.

Bookmaker	Φάση	Στάδιο	Στοιχ.	Κεφάλαιο	log-growth	CI κάτω	CI άνω	<i>p</i>
B365	opening	raw	5.183	0,68039	-0,00007	-0,00023	0,00005	0,21600
B365	opening	calibrated	4.493	0,61559	-0,00011	-0,00028	0,00005	0,17800
B365C	closing	raw	4.621	0,87490	-0,00003	-0,00018	0,00015	0,73300
B365C	closing	calibrated	5.537	0,77807	-0,00005	-0,00021	0,00014	0,65000
B365C	closing	raw	6.305	0,22316	-0,00024	-0,00040	-0,00006	0,01500
B365C	closing	calibrated	7.362	0,32589	-0,00015	-0,00032	0,00002	0,08800
BW	opening	raw	1.108	0,85016	-0,00015	-0,00041	0,00020	0,44000
BW	opening	calibrated	4.546	1,1965	0,00004	-0,00011	0,00019	0,64500
BWC	closing	raw	1.377	2,0538	0,00052	0,00006	0,00099	0,01900
BWC	closing	calibrated	5.751	2,6509	0,00017	-0,00000	0,00036	0,05100
BWC	closing	raw	2.307	1,0231	0,00001	-0,00030	0,00037	0,93100
BWC	closing	calibrated	6.674	1,2275	0,00003	-0,00013	0,00020	0,69800
IW	opening	raw	562	1,0875	0,00015	-0,00028	0,00071	0,52200
IW	opening	calibrated	4.645	1,4991	0,00009	-0,00010	0,00027	0,33500
IWC	closing	raw	1.332	2,6726	0,00074	0,00025	0,00122	0,00200
IWC	closing	calibrated	5.092	8,5053	0,00042	0,00016	0,00068	0,00000
IWC	closing	raw	1.981	1,3847	0,00016	-0,00020	0,00056	0,42100
IWC	closing	calibrated	5.947	5,7760	0,00029	0,00006	0,00054	0,01000
PS	opening	raw	13.103	0,09545	-0,00018	-0,00026	-0,00009	0,00000
PS	opening	calibrated	12.643	0,20826	-0,00012	-0,00022	-0,00003	0,01100
PSC	closing	raw	14.512	0,15081	-0,00013	-0,00022	-0,00004	0,00400
PSC	closing	calibrated	15.306	0,61266	-0,00003	-0,00012	0,00006	0,49900
PSC	closing	raw	17.953	0,04992	-0,00017	-0,00026	-0,00007	0,00000
PSC	closing	calibrated	18.526	0,21303	-0,00008	-0,00019	0,00002	0,13400

(συνέχεια)

Bookmaker	Φάση	Στάδιο	Στοιχ.	Κεφάλαιο	log-growth	CI κάτω	CI άνω	<i>p</i>
VC_BV	opening	raw	2.408	0,46501	-0,00032	-0,00049	-0,00014	0,00000
VC_BV	opening	calibrated	1.503	0,83650	-0,00012	-0,00041	0,00017	0,41800
VC_BVC	closing	raw	3.094	1,0480	0,00002	-0,00019	0,00023	0,90100
VC_BVC	closing	calibrated	3.283	1,0843	0,00002	-0,00022	0,00026	0,90500
VC_BVC	closing	raw	4.523	0,22559	-0,00033	-0,00052	-0,00012	0,00100
VC_BVC	closing	calibrated	4.722	0,34505	-0,00023	-0,00042	-0,00003	0,02000
WH	opening	raw	2.023	1,4058	0,00017	-0,00020	0,00056	0,35900
WH	opening	calibrated	2.817	1,6474	0,00018	-0,00012	0,00052	0,25600
WHC	closing	raw	4.327	17,0701	0,00066	0,00026	0,00101	0,00100
WHC	closing	calibrated	5.517	33,6750	0,00064	0,00029	0,00096	0,00000
WHC	closing	raw	4.352	4,7664	0,00036	0,00004	0,00064	0,02900
WHC	closing	calibrated	5.471	8,5626	0,00039	0,00008	0,00070	0,01800

Α.7 Επεκτάσεις και αρνητικά αποτελέσματα

Πίνακας Α'.20: Fixed-Share ανά α .

α	Γύροι	log-loss	Brier	RPS	Acc.
0,00000	76.584	0,99842	0,59674	0,20297	0,50649
0,00500	76.584	0,99885	0,59702	0,20310	0,50597
0,01000	76.584	0,99885	0,59702	0,20310	0,50595
0,02000	76.584	0,99885	0,59703	0,20311	0,50595
0,05000	76.584	0,99886	0,59703	0,20311	0,50594

Πίνακας Α'.21: Βάρη ανά expert και α (τελευταία ξύπνια στιγμή).

Bookmaker	0.0	0.005	0.01	0.02	0.05
1XB	0,16922	0,09999	0,09999	0,09999	0,09999
1XBC	0,16620	0,10000	0,10000	0,10000	0,10000
BF	0,16597	0,09998	0,09999	0,09999	0,09999
BFC	0,16631	0,10000	0,10000	0,10000	0,10000
BFD	0,11393	0,06232	0,06244	0,06247	0,06248
BFDC	0,11542	0,06236	0,06246	0,06248	0,06249
BMGM	0,11836	0,06235	0,06245	0,06247	0,06248
BMGMC	0,11580	0,06234	0,06246	0,06249	0,06249
CL	0,14862	0,06293	0,06264	0,06258	0,06254
CLC	0,15156	0,06345	0,06278	0,06263	0,06258
LBC	0,14584	0,06243	0,06246	0,06248	0,06249

Πίνακας Α'.22: Εξειδίκευση ανά πρωτάθλημα.

Λίγκα	Πρωτάθλημα	Αγώνες	Ενιαίο	Ειδικός	Νίκη ειδ.	top3_trusted_bookmakers
SC0	Scotland Premiership	2.231	0,93590	0,93635	όχι	CLC, BFEC, BFD

(συνέχεια)

Λίγκα	Πρωτάθλημα	Αγώνες	Ενιαίο	Ειδικός	Νίκη ειδ.	top3_trusted_bookmakers
I1	Italy Serie A	3.800	0,94636	0,94692	όχι	CL, BF, LBC
E0	England Premier League	3.800	0,94928	0,94978	όχι	BFEC, WHC, CLC
SP1	Spain La Liga	3.800	0,96476	0,96534	όχι	LBC, BFC, PSC
D1	Germany Bundesliga	3.060	0,97734	0,97823	όχι	BMGMC, LBC, 1XBC
F1	France Ligue 1	3.477	0,98084	0,98132	όχι	LBC, 1XBC, BFC

Πίνακας Α'.23: Επίδοση ανά κατηγορία αποτελέσματος.

Σειρά	Τύπος	Έκβαση	n	Acc.	log-loss	Brier
Hedge	algorithm	1 (Home win)	33.280	0,82058	0,76764	0,43084
Hedge	algorithm	X (Draw)	20.080	0,00249	1,3149	0,83571
Hedge	algorithm	2 (Away win)	23.224	0,49216	1,0555	0,62784
OGD	algorithm	1 (Home win)	33.280	0,81830	0,76463	0,42884
OGD	algorithm	X (Draw)	20.080	0,00418	1,3134	0,83548
OGD	algorithm	2 (Away win)	23.224	0,49440	1,0579	0,62889
FTRL	algorithm	1 (Home win)	33.280	0,82061	0,76769	0,43088
FTRL	algorithm	X (Draw)	20.080	0,00249	1,3150	0,83570
FTRL	algorithm	2 (Away win)	23.224	0,49225	1,0554	0,62781
Uniform average	algorithm	1 (Home win)	33.280	0,82263	0,76722	0,43061
Uniform average	algorithm	X (Draw)	20.080	0,00159	1,3159	0,83603
Uniform average	algorithm	2 (Away win)	23.224	0,48816	1,0567	0,62887
B365	bookmaker	1 (Home win)	33.216	0,82557	0,76485	0,42878
B365	bookmaker	X (Draw)	20.050	0,00165	1,3235	0,84164
B365	bookmaker	2 (Away win)	23.172	0,47695	1,0609	0,63147
BW	bookmaker	1 (Home win)	31.644	0,82755	0,76947	0,43235
BW	bookmaker	X (Draw)	19.102	0,00162	1,3208	0,83778
BW	bookmaker	2 (Away win)	22.006	0,47333	1,0576	0,63048
IW	bookmaker	1 (Home win)	24.912	0,82671	0,78010	0,43964
IW	bookmaker	X (Draw)	14.973	0,00147	1,3050	0,82684
IW	bookmaker	2 (Away win)	17.300	0,46809	1,0589	0,63125
PS	bookmaker	1 (Home win)	30.943	0,81944	0,76503	0,42925
PS	bookmaker	X (Draw)	18.694	0,00332	1,3182	0,83832
PS	bookmaker	2 (Away win)	21.647	0,48247	1,0638	0,63295
PSC	bookmaker	1 (Home win)	31.186	0,81668	0,76231	0,42734
PSC	bookmaker	X (Draw)	18.837	0,00695	1,3127	0,83592
PSC	bookmaker	2 (Away win)	21.795	0,49314	1,0604	0,62971
VC_BV	bookmaker	1 (Home win)	29.698	0,82480	0,76751	0,43096
VC_BV	bookmaker	X (Draw)	17.933	0,00112	1,3178	0,83746
VC_BV	bookmaker	2 (Away win)	20.766	0,47799	1,0605	0,63120
WH	bookmaker	1 (Home win)	28.469	0,82528	0,77363	0,43519
WH	bookmaker	X (Draw)	17.150	0,00146	1,3108	0,83259
WH	bookmaker	2 (Away win)	19.851	0,47438	1,0600	0,63078

Πίνακας Α'.24: Βαθμονόμηση ανά σεζόν.

Σειρά	Σύγκριση	n	Μ. διαφορά	CI κάτω	CI άνω	p
Hedge	per-season vs raw	76.584	-0,00056	-0,00081	-0,00030	0,00000
Hedge	per-season vs global	76.584	0,00013	-0,00003	0,00031	0,10800
OGD	per-season vs raw	76.584	-0,00041	-0,00064	-0,00017	0,00100
OGD	per-season vs global	76.584	0,00012	-0,00005	0,00030	0,15800

(συνέχεια)

Σειρά	Σύγκριση	<i>n</i>	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
FTRL	per-season vs raw	76.584	-0,00056	-0,00082	-0,00030	0,00000
FTRL	per-season vs global	76.584	0,00013	-0,00003	0,00031	0,10900
Uniform average	per-season vs raw	76.584	-0,00059	-0,00087	-0,00032	0,00000
Uniform average	per-season vs global	76.584	0,00014	-0,00004	0,00032	0,13700
B365	per-season vs raw	76.438	-0,00031	-0,00054	-0,00007	0,00700
B365	per-season vs global	76.438	0,00009	-0,00008	0,00026	0,28300
BW	per-season vs raw	72.752	-0,00061	-0,00091	-0,00031	0,00000
BW	per-season vs global	72.752	0,00014	-0,00005	0,00032	0,14900
IW	per-season vs raw	57.185	-0,00110	-0,00150	-0,00069	0,00000
IW	per-season vs global	57.185	0,00016	-0,00006	0,00039	0,14600
PS	per-season vs raw	71.284	-0,00017	-0,00039	0,00005	0,14000
PS	per-season vs global	71.284	0,00011	-0,00009	0,00030	0,24600
PSC	per-season vs raw	71.818	-0,00016	-0,00033	0,00001	0,08200
PSC	per-season vs global	71.818	0,00013	-0,00003	0,00028	0,10800
VC_BV	per-season vs raw	68.397	-0,00039	-0,00066	-0,00013	0,00000
VC_BV	per-season vs global	68.397	0,00009	-0,00009	0,00028	0,30500
WH	per-season vs raw	65.470	-0,00061	-0,00095	-0,00026	0,00000
WH	per-season vs global	65.470	0,00010	-0,00011	0,00033	0,37300

Πίνακας Α'.25: Βαθμονόμηση με warm start.

Σειρά	<i>n</i>	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
Hedge	76.584	-0,00066	-0,00093	-0,00037	0,00000
Hedge	76.584	0,00003	-0,00005	0,00012	0,47600
Hedge	76.584	-0,00010	-0,00021	0,00001	0,08500
OGD	76.584	-0,00048	-0,00070	-0,00026	0,00000
OGD	76.584	0,00005	-0,00001	0,00011	0,13600
OGD	76.584	-0,00008	-0,00023	0,00007	0,31300
FTRL	76.584	-0,00066	-0,00094	-0,00038	0,00000
FTRL	76.584	0,00003	-0,00005	0,00012	0,47900
FTRL	76.584	-0,00010	-0,00021	0,00001	0,08600
Uniform average	76.584	-0,00069	-0,00097	-0,00040	0,00000
Uniform average	76.584	0,00004	-0,00005	0,00013	0,41800
Uniform average	76.584	-0,00010	-0,00024	0,00004	0,15700
B365	76.438	-0,00036	-0,00061	-0,00011	0,00500
B365	76.438	0,00004	-0,00009	0,00016	0,54800
B365	76.438	-0,00005	-0,00015	0,00004	0,27000
BW	72.752	-0,00071	-0,00106	-0,00039	0,00000
BW	72.752	0,00004	-0,00011	0,00018	0,60100
BW	72.752	-0,00010	-0,00020	0,00001	0,06400
IW	57.185	-0,00122	-0,00161	-0,00082	0,00000
IW	57.185	0,00004	-0,00004	0,00012	0,38800
IW	57.185	-0,00012	-0,00031	0,00005	0,17900
PS	71.284	-0,00022	-0,00044	0,00000	0,05600
PS	71.284	0,00006	-0,00009	0,00021	0,38900
PS	71.284	-0,00005	-0,00015	0,00004	0,32200
PSC	71.818	-0,00022	-0,00038	-0,00005	0,00900
PSC	71.818	0,00007	-0,00001	0,00014	0,07400

(συνέχεια)

Σειρά	<i>n</i>	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
PSC	71.818	-0,00006	-0,00016	0,00004	0,25400
VC_BV	68.397	-0,00043	-0,00066	-0,00020	0,00000
VC_BV	68.397	0,00006	-0,00001	0,00013	0,10700
VC_BV	68.397	-0,00004	-0,00021	0,00013	0,63800
WH	65.470	-0,00067	-0,00100	-0,00035	0,00000
WH	65.470	0,00003	-0,00009	0,00016	0,57100
WH	65.470	-0,00006	-0,00023	0,00009	0,44400

Πίνακας Α'.26: Έλεγχοι τάσης Mann–Kendall.

Σειρά	Μετρική	S	Z	<i>p</i>	trend
Algorithm average	ece	-9	-0,71554	0,47427	decreasing
B365	ece	-3	-0,17889	0,85803	decreasing
BW	ece	5	0,35777	0,72051	increasing
Bookmaker average	ece	7	0,53666	0,59151	increasing
FTRL	ece	-11	-0,89443	0,37109	decreasing
Hedge	ece	-11	-0,89443	0,37109	decreasing
OGD	ece	-15	-1,2522	0,21050	decreasing
PS	ece	3	0,17889	0,85803	increasing
PSC	ece	-3	-0,17889	0,85803	decreasing
Uniform average	ece	-11	-0,89443	0,37109	decreasing
Algorithm average	log_loss	1	0,00000	1,0000	increasing
B365	log_loss	9	0,71554	0,47427	increasing
BW	log_loss	7	0,53666	0,59151	increasing
Bookmaker average	log_loss	7	0,53666	0,59151	increasing
FTRL	log_loss	1	0,00000	1,0000	increasing
Hedge	log_loss	1	0,00000	1,0000	increasing
OGD	log_loss	3	0,17889	0,85803	increasing
PS	log_loss	3	0,17889	0,85803	increasing
PSC	log_loss	1	0,00000	1,0000	increasing
Uniform average	log_loss	1	0,00000	1,0000	increasing
B365	overround_pct	31	2,6833	0,00729	increasing
BW	overround_pct	23	1,9677	0,04910	increasing
Bookmaker average	overround_pct	39	3,3988	0,00068	increasing
PS	overround_pct	31	2,6833	0,00729	increasing
PSC	overround_pct	33	2,8622	0,00421	increasing

Πίνακας Α'.27: Σάρωση συντελεστή βήματος.

family	setting	full_log_loss	ουρά	Σειρά
Hedge x mult	0,00100	0,99885	0,99881	—
Hedge x mult	0,00500	0,99879	0,99877	—
Hedge x mult	0,01000	0,99873	0,99873	—
Hedge x mult	0,02000	0,99862	0,99867	—

(συνέχεια)

family	setting	full_log_loss	ουρά	Σειρά
Hedge x mult	0,05000	0,99845	0,99866	—
Hedge x mult	0,10000	0,99840	0,99873	—
Hedge x mult	0,25000	0,99842	0,99883	—
Hedge x mult	0,50000	0,99844	0,99891	—
Hedge x mult	0,75000	0,99845	0,99894	—
Hedge x mult	1,0000	0,99845	0,99896	—
Hedge x mult	1,5000	0,99846	0,99899	—
Hedge x mult	2,0000	0,99847	0,99901	—
Hedge x mult	5,0000	0,99854	0,99916	—
Hedge x mult	10,0000	0,99864	0,99934	—
Hedge x mult	25,0000	0,99881	0,99969	—
Hedge x mult	50,0000	0,99896	1,0002	—
Hedge x mult	100,0000	0,99907	1,0005	—
Hedge x mult	200,0000	0,99914	1,0007	—
Hedge x mult	500,0000	0,99919	1,0008	—
Hedge x mult	1.000	0,99922	1,0008	—
OGD x mult	1,0000	0,99826	0,99803	—
OGD x mult	2,0000	0,99822	0,99800	—
OGD x mult	5,0000	0,99814	0,99794	—
OGD x mult	10,0000	0,99804	0,99789	—
OGD x mult	25,0000	0,99784	0,99780	—
OGD x mult	50,0000	0,99761	0,99770	—
OGD x mult	75,0000	0,99749	0,99766	—
OGD x mult	90,0000	0,99747	0,99765	—
OGD x mult	100,0000	0,99745	0,99765	—
OGD x mult	110,0000	0,99745	0,99765	—
OGD x mult	125,0000	0,99745	0,99766	—
OGD x mult	150,0000	0,99748	0,99769	—
OGD x mult	200,0000	0,99758	0,99778	—
OGD x mult	500,0000	0,99822	0,99858	—
OGD x mult	1.000	0,99852	0,99895	—
Hedge const eta	0,10000	0,99913	1,0007	—
Hedge const eta	0,50000	0,99927	1,0008	—
Hedge const eta	1,0000	0,99932	1,0010	—
Hedge const eta	2,0000	0,99934	1,0011	—
FTRL x mult	0,00100	0,99881	0,99879	—
FTRL x mult	0,00500	0,99865	0,99872	—
FTRL x mult	0,01000	0,99852	0,99879	—
FTRL x mult	0,02000	0,99841	0,99878	—
FTRL x mult	0,05000	0,99843	0,99889	—
FTRL x mult	0,10000	0,99845	0,99895	—
FTRL x mult	0,25000	0,99845	0,99896	—
FTRL x mult	0,50000	0,99846	0,99899	—
FTRL x mult	0,75000	0,99848	0,99903	—
FTRL x mult	1,0000	0,99850	0,99907	—
FTRL x mult	1,5000	0,99853	0,99915	—
FTRL x mult	2,0000	0,99854	0,99920	—
FTRL x mult	5,0000	0,99867	0,99946	—
FTRL x mult	10,0000	0,99889	0,99976	—
FTRL x mult	25,0000	0,99913	1,0005	—
FTRL x mult	50,0000	0,99920	1,0006	—
FTRL x mult	100,0000	0,99923	1,0007	—
FTRL x mult	200,0000	0,99926	1,0008	—
FTRL x mult	500,0000	0,99930	1,0009	—

(συνέχεια)

family	setting	full_log_loss	ουρά	Σειρά
FTRL x mult	1.000	0,99932	1,0010	—
OGD honest M	4,6052	0,99819	0,99797	M=log(100)=4.61
OGD honest M	3,7630	0,99817	0,99796	M=3.76 (observed max)
OGD adaptive	—	0,99781	0,99842	AdaGrad per-expert
OGD adaptive	—	0,99815	0,99795	AdaGrad scalar
shipped	—	0,99842	0,99883	Hedge (shipped)
shipped	—	0,99745	0,99765	OGD (shipped)
shipped	—	0,99843	0,99889	FTRL (shipped)
shipped	—	0,99886	0,99882	Uniform average

Πίνακας Α'.28: Σύγκριση χρονικών παραθύρων.

Σειρά	Τύπος	Κάλυψη %	Γύροι	log-loss (raw)	log-loss (cal.)	window
PSC	bookmaker	87,9119	34.065	0,99471	0,99439	5yr
OGD	algorithm	100,0000	38.749	0,99556	0,99495	5yr
VC_BVC	bookmaker	79,6975	30.882	0,99554	0,99498	5yr
WHC	bookmaker	72,1361	27.952	0,99575	0,99502	5yr
BWC	bookmaker	91,9353	35.624	0,99609	0,99504	5yr
B365C	bookmaker	99,9974	38.748	0,99602	0,99543	5yr
Uniform average	algorithm	100,0000	38.749	0,99677	0,99591	5yr
Hedge	algorithm	100,0000	38.749	0,99689	0,99604	5yr
FTRL	algorithm	100,0000	38.749	0,99692	0,99607	5yr
WH	bookmaker	71,9090	27.864	0,99848	0,99771	5yr
PS	bookmaker	87,6952	33.981	0,99831	0,99794	5yr
VC_BV	bookmaker	79,0833	30.644	0,99870	0,99801	5yr
BW	bookmaker	91,5327	35.468	0,99981	0,99885	5yr
B365	bookmaker	99,8400	38.687	0,99951	0,99896	5yr
PSC	bookmaker	93,7768	71.818	0,99714	0,99685	10yr
OGD	algorithm	100,0000	76.584	0,99745	0,99693	10yr
Hedge	algorithm	100,0000	76.584	0,99842	0,99773	10yr
FTRL	algorithm	100,0000	76.584	0,99843	0,99774	10yr
Uniform average	algorithm	100,0000	76.584	0,99886	0,99813	10yr
VC_BV	bookmaker	89,3098	68.397	1,0007	1,0003	10yr
WH	bookmaker	85,4878	65.470	1,0012	1,0005	10yr
PS	bookmaker	93,0795	71.284	1,0008	1,0005	10yr
IW	bookmaker	74,6696	57.185	1,0019	1,0006	10yr
BW	bookmaker	94,9963	72.752	1,0014	1,0007	10yr
B365	bookmaker	99,8094	76.438	1,0011	1,0007	10yr

Πίνακας Α'.29: Άφιξη πληροφορίας ανά πεμπτημόριο.

stratifier	stratum	n	Σύγκριση	M. διαφορά	CI κάτω	CI άνω	p
line movement	0	10.650	closing vs opening	-0,00044	-0,00084	0,00000	0,05200
line movement	1	10.649	closing vs opening	-0,00072	-0,00140	-0,00000	0,05000
line movement	2	10.649	closing vs opening	-0,00200	-0,00296	-0,00095	0,00000
line movement	3	10.649	closing vs opening	-0,00452	-0,00596	-0,00301	0,00000
line movement	4	10.649	closing vs opening	-0,01158	-0,01403	-0,00909	0,00000
Shin z anomaly	0	15.315	closing vs opening	-0,00295	-0,00397	-0,00187	0,00000
Shin z anomaly	1	15.311	closing vs opening	-0,00371	-0,00486	-0,00250	0,00000
Shin z anomaly	2	15.313	closing vs opening	-0,00281	-0,00401	-0,00169	0,00000
Shin z anomaly	3	15.303	closing vs opening	-0,00440	-0,00562	-0,00314	0,00000

(συνέχεια)

stratifier	stratum	<i>n</i>	Σύγκριση	Μ. διαφορά	CI κάτω	CI άνω	<i>p</i>
Shin z anomaly	4	15.252	closing vs opening	-0,00498	-0,00641	-0,00353	0,00000

Βιβλιογραφία

- [1] Agarwal, A., Dekel, O., & Xiao, L. (2010). Optimal algorithms for online convex optimization with multi-point bandit feedback. *COLT*, 28–40.
- [2] Blum, A., & Mansour, Y. (2007). From external to internal regret. *Journal of Machine Learning Research*, 8, 1307–1324.
- [3] Breiman, L. (1961). Optimal gambling systems for favorable games. *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 65–78.
- [4] Cesa-Bianchi, N., & Lugosi, G. (2006). *Prediction, Learning, and Games*. Cambridge University Press.
- [5] Cover, T. M. (1991). Universal portfolios. *Mathematical Finance*, 1(1), 1–29.
- [6] Duchi, J., Shalev-Shwartz, S., Singer, Y., & Chandra, T. (2008). Efficient projections onto the ℓ_1 -ball for learning in high dimensions. *ICML*.
- [7] Duchi, J., Hazan, E., & Singer, Y. (2011). Adaptive subgradient methods for online learning and stochastic optimization. *JMLR*, 12, 2121–2159.
- [8] Freund, Y., Schapire, R. E., Singer, Y., & Warmuth, M. K. (1997). Using and combining predictors that specialize. *STOC*, 334–343.
- [9] Flaxman, A. D., Kalai, A. T., & McMahan, H. B. (2005). Online convex optimization in the bandit setting: gradient descent without a gradient. *SODA*, 385–394.
- [10] Glosten, L. R., & Milgrom, P. R. (1985). Bid, ask and transaction prices in a specialist market with heterogeneously informed traders. *Journal of Financial Economics*, 14(1), 71–100.
- [11] Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.
- [12] Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. *ICML*.
- [13] Hall, P., Horowitz, J. L., & Jing, B.-Y. (1995). On blocking rules for the bootstrap with dependent data. *Biometrika*, 82(3), 561–574.
- [14] Hazan, E., Agarwal, A., & Kale, S. (2007). Logarithmic regret algorithms for online convex optimization. *Machine Learning*, 69(2–3), 169–192.

- [15] Hazan, E. (2016). Introduction to online convex optimization. *Foundations and Trends in Optimization*, 2(3–4), 157–325.
- [16] Herbster, M., & Warmuth, M. K. (1998). Tracking the best expert. *Machine Learning*, 32(2), 151–178.
- [17] Kelly, J. L. (1956). A new interpretation of information rate. *Bell System Technical Journal*, 35(4), 917–926.
- [18] Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 17(3), 1217–1241.
- [19] Kyle, A. S. (1985). Continuous auctions and insider trading. *Econometrica*, 53(6), 1315–1335.
- [20] Levitt, S. D. (2004). Why are gambling markets organised so differently from financial markets? *The Economic Journal*, 114(495), 223–246.
- [21] Littlestone, N., & Warmuth, M. K. (1994). The weighted majority algorithm. *Information and Computation*, 108(2), 212–261.
- [22] Murphy, A. H. (1973). A new vector partition of the probability score. *Journal of Applied Meteorology*, 12(4), 595–600.
- [23] Shin, H. S. (1992). Prices of state contingent claims with insider traders, and the favourite-longshot bias. *The Economic Journal*, 102(411), 426–435.
- [24] Shin, H. S. (1993). Measuring the incidence of insider trading in a market for state-contingent claims. *The Economic Journal*, 103(420), 1141–1153.
- [25] Sun, T., Sun, Y., & Yin, W. (2018). On Markov chain gradient descent. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.
- [26] Štrumbelj, E. (2014). On determining probability forecasts from betting odds. *International Journal of Forecasting*, 30(4), 934–943.
- [27] Vovk, V. G. (1990). Aggregating strategies. *COLT*, 371–386.
- [28] Zinkevich, M. (2003). Online convex programming and generalized infinitesimal gradient ascent. *ICML*, 928–936.